

ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ  
ФГАОУ ВО НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ  
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет компьютерных наук  
Образовательная программа «Прикладная математика и информатика»

**ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА**

**Программный проект на тему:**

**SEO-оптимизация карточки товара на маркетплейсе**

**Выполнили студенты:**

группы МОВС 2022  
Бузаева Софья Михайловна  
Куликов Дмитрий Алексеевич

**Принял руководитель ВКР:**

Кантонистова Елена Олеговна  
Доцент факультета компьютерных наук НИУ ВШЭ

**Соруководитель:**

Хажгериев Мурат Анзорович  
Консультант стартапов по построению  
инфраструктуры для Large Language models

Москва, 2024

# Содержание

<b>Аннотация</b>	<b>4</b>
<b>Введение</b>	<b>9</b>
<b>1 Цель и задачи работы</b>	<b>10</b>
<b>2 Постановка задачи</b>	<b>11</b>
<b>3 Обзор существующих решений</b>	<b>12</b>
3.1 TurboText.Pro . . . . .	12
3.2 Gerwin . . . . .	13
3.3 CopyMonkey . . . . .	14
3.4 Сравнительный анализ существующих решений . . . . .	16
<b>4 Данные</b>	<b>17</b>
4.1 Этап 1 . . . . .	19
4.2 Этап 2 . . . . .	21
<b>5 Теоретические основы</b>	<b>27</b>
5.1 Задача многоклассовой классификации изображений . . . . .	27
5.2 Обзор классификаторов изображения . . . . .	27
5.2.1 ResNet . . . . .	27
5.2.2 MobileNet . . . . .	28
5.2.3 EfficientNet . . . . .	30
5.2.4 Vision Transformers . . . . .	33
5.3 Метрики качества в задаче классификации . . . . .	35
5.4 Задача создания подписей к изображениям . . . . .	42
5.5 Обзор моделей для генерации текста . . . . .	46
5.5.1 Рекуррентные нейронные сети . . . . .	46
5.5.2 Модели генеративного предварительно обученного трансформера . . . . .	50
5.6 Генерация предсказаний в задаче создания подписей к изображениям . . . . .	53
5.6.1 Схема генерации текста . . . . .	53
5.6.2 Описание популярных подходов . . . . .	54
5.7 Метрики качества в задаче создания подписей к изображениям . . . . .	56
5.8 Вывод . . . . .	57

<b>6 Эксперименты</b>	<b>60</b>
6.1 Общие принципы обучения . . . . .	60
6.2 Решение задачи классификации . . . . .	62
6.2.1 Х3 КАК НАЗВАТЬ4 (Результаты классификации ?) . . . . .	67
6.3 Х3 КАК НАЗВАТЬ5 (Image captioning) . . . . .	77
<b>7 Проектирование архитектуры программного продукта</b>	<b>84</b>
7.1 Стек технологий . . . . .	84
7.2 Демонстрация работы приложения . . . . .	86
<b>Заключение</b>	<b>89</b>
<b>Распределение работ</b>	<b>91</b>
<b>Список литературы</b>	<b>92</b>
<b>A Приложение 1</b>	<b>96</b>
<b>B Приложение 2</b>	<b>107</b>
<b>C Приложение 3</b>	<b>118</b>

## **Аннотация**

Выпускная квалификационная работа посвящена разработке эффективного и простого в использовании приложения, которое позволит пользователям легко и быстро подбирать категорию товара для маркетплейса по его фотографии, а также составлять к нему SEO-описание. В работе проведен анализ существующих решений, рассмотрены различные архитектуры нейронных сетей, описаны задачи классификации и создания подписей к изображениям, разработаны решения для реализации моделей нейронной сети для SEO-оптимизации карточки товара, учитывающие специфику данных. Особое внимание уделено использованным метрикам и методам сбора данных. Результатом работы является разработанный сервис, в основе которого реализована нейронная сеть, способная классифицировать товары на маркетплейсе на основе их фотографий и генерировать соответствующие к ним описания. Дальнейшие исследования в этой области могут включать улучшения качества результатов, а также расширение функциональности за счет генерации описания с помощью ключевых слов.

# **Abstract**

The final qualification work is devoted to the development of an effective and easy-to-use application that will allow users to easily and quickly select a product category for a marketplace based on its photo, as well as create an SEO description for it. The paper analyzes existing solutions, examines various architectures of neural networks, describes the tasks of classifying and creating captions to images, and develops solutions for implementing neural network models for SEO optimization of product cards, taking into account the specifics of the data. Special attention is paid to the metrics and data collection methods used. The result of the work is a developed service based on a neural network capable of classifying products on the marketplace based on their photos and generating descriptions corresponding to them. Further research in this area may include improvements in the quality of results, as well as expanding functionality by generating a description using keywords.

## Ключевые слова

**Маркетплейс** (от англ. *marketplace*; электронная торговая площадка) — платформа электронной коммерции, интернет-магазин электронной торговли, предоставляющий информацию о продукте или услуге третьих лиц.

**SEO-оптимизация карточек товара** — это процесс улучшения информации о товаре на маркетплейсе, чтобы она была более привлекательной и доступной для поисковых систем и пользователей. Цель состоит в том, чтобы повысить видимость товара в результатах поиска, привлечь больше потенциальных покупателей и увеличить конверсию.

**Искусственный интеллект (ИИ)** (от англ. *Artificial Intelligence*, AI) — свойство интеллектуальных компьютерных систем, обладающих возможностями выполнять творческие задачи, которые считаются прерогативой человека [19].

**Машинное обучение** (от англ. *Machine Learning*, ML) — область искусственного интеллекта, изучающий различные способы построения обучающихся алгоритмов. Среди множества парадигм и подходов в машинном обучении выделяются нейронные сети [21].

**Компьютерное зрение** (от англ. *Computer Vision*, CV) — область искусственного интеллекта, которое занимается задачами, связанными с анализом изображений и видео [20].

**Обработка естественного языка** (от англ. *Natural Language Processing*, NLP) — это направление в машинном обучении, посвящённое распознаванию, генерации и обработке устной и письменной человеческой речи [39].

**Нейронная сеть** (от англ. *Neural Network*) — математическая модель, а также ее программное или аппаратное воплощение, построенная по принципу организации и функционирования биологических нейронных сетей, используемая для решения задач ИИ [22].

Сокращения названий архитектур нейронных сетей:

- сверточная нейронная сеть (от англ. *Convolutional Neural Network*, CNN);
- рекуррентная нейронная сеть (от англ. *Recurrent Neural Network*, RNN);
- рекуррентная нейронная сеть с долгой краткосрочной памятью (от англ. *Long Short-Term Memory*, LSTM);
- управляемый рекуррентный блок (от англ. *Gated Recurrent Unit*, GRU);
- генеративный предварительно обученный трансформер, (от англ. *Generative Pre-trained Transformer*, GPT).

# Введение

В современном мире маркетплейсы стали неотъемлемой частью электронной коммерции, предоставляя платформы для продажи товаров и услуг различным производителям и ритейлерам. В 2023 году маркетплейсы оставались основной движущей силой российской онлайн-торговли. Объем расходов на этих платформах вырос в 1.5 раза по сравнению с предыдущим годом, что говорит о продолжающемся росте интереса потребителей к онлайн-покупкам. Этому способствуют общерыночные факторы: развитие альтернативных каналов поставок продукции вместо ушедших брендов, улучшение условий доставки, повышение удобства использования платформ и расширение сети пунктов выдачи.

Согласно исследованиям «Tinkoff Ecommerce»[8], за год количество транзакций на маркетплейсах увеличилось на 63% (см. рисунок 0.1). Наибольший рост числа покупок показали платформы «Мегамаркет» (рост в 4.3 раза), «Wildberries» (увеличение в 2 раза) и «Ozon» (рост в 1.6 раза).



Рис. 0.1: Динамика покупок на маркетплейсах в регионах [8].

В российских регионах наблюдается рост популярности маркетплейсов. В 2023 году жители российских городов стали значительно активнее совершать покупки на онлайн-платформах, что привело к увеличению как количества транзакций, так и их общей суммы (см. рисунок 0.2). Особенно заметен рост числа транзакций в таких городах, как Омск (+91%), Красноярск (+88%), Новосибирск (+79%), Челябинск (+79%) и Волгоград (+75%). В Москве прирост числа транзакций составил всего 41%. Увеличение интереса к маркетплейсам в регионах связано с расширением географического охвата платформ, развитием сетей пунктов выдачи заказов, а также улучшением условий доставки и логистики.

## Динамика покупок на маркетплейсах в регионах

2023-й год против 2022-го, изменение в %



Рис. 0.2: Динамика покупок на маркетплейсах в регионах [8].

Вместе с тем выросло количество селлеров на 8%. Рынок приобретает большую зрелость: менее опытные продавцы уступают место более профессиональным. Эти предприниматели ведут бизнес уверенно, укрепляют свои позиции на площадках и одновременно торгуют на нескольких платформах. За год число селлеров, работающих на двух и более маркетплейсах, выросло на 17%. Наиболее привлекательной платформой для начала бизнеса стала «Wildberries»: в конце 2023 года ее выбирали в качестве первой площадки 63% продавцов (см. рисунок 0.3).

## Какой маркетплейс выбирают первым для начала торговли, %

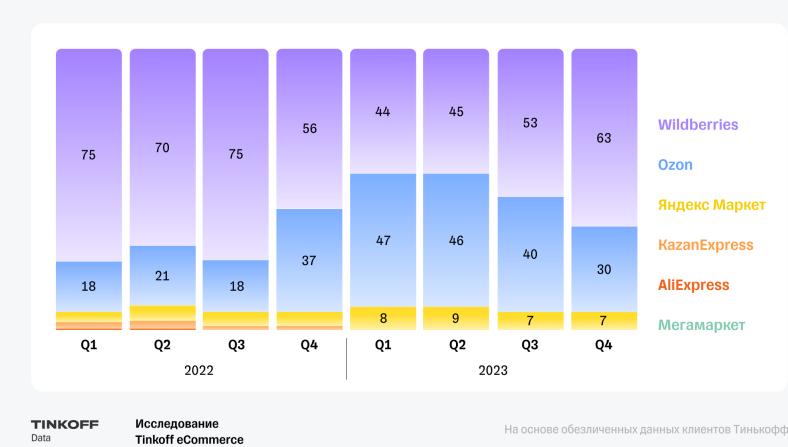


Рис. 0.3: Популярность маркетплейсов за 2023 год [8].

С увеличением конкуренции продавцы все чаще обращаются к системам, которые могут помочь им в продажах, а также автоматизировать процесс работы. Одним из ключевых факторов успешной продажи становится эффективная SEO-оптимизация карточек товаров.

Подбор наиболее подходящей категории и создание продаваемого описания, содержащего ключевые слова, позволяет улучшить видимость товаров в результатах поиска как на самом маркетплейсе, так и в поисковых системах, что напрямую влияет на увеличение продаж.

На данный момент существуют несколько сервисов (например, TurboTextPro, Gerwin, CopyMonkey, подробнее можно ознакомиться в пункте [3](#)), позволяющих генерировать описание товаров по характеристикам, ключевым словам или фотографии. Однако, качество генерированных описаний не всегда позволяют использовать их в системах автономного управления. В настоящее время российский рынок не предлагает специальных технологий и решений для подбора наиболее подходящей категории товара на маркетплейсе. Таким образом, задача создания качественного инструмента для эффективной SEO-оптимизации карточек товаров является актуальной.

# 1 Цель и задачи работы

Цель данной работы — разработать сервис, в основе которого будет реализована модель нейронной сети, способная классифицировать товары на маркетплейсе на основе их фотографий и генерировать соответствующие к ним описания.

Для достижения поставленной цели необходимо решить следующие задачи:

- подготовить набор данных, содержащий изображения товаров и соответствующие им категории и текстовые описания;
- провести исследование текущих решений, используемых для классификации изображений и генерации текста, и на основе этого исследования создать наиболее подходящую архитектуру модели для решения поставленной задачи;
- обучить спроектированную архитектуру на подготовленных данных, оптимизировать и настроить параметры модели для повышения её производительности и качества результатов, а затем оценить эффективность реализованной архитектуры;
- интегрировать модель в программное обеспечение.

## 2 Постановка задачи

В соответствии с заданием на выпускную квалификационную работу необходимо разработать программное обеспечение, на вход которого подаются фотографии товара. Выходом являются наиболее подходящая категория товара для маркетплейса и его SEO-описание.

Допущения:

- рассматривается только маркетплейс «Wildberries»;
- глубина подбора категории — второй уровень вложенности.

Постановка задачи в виде IDEF0-диаграммы представлена на рисунке 2.1.

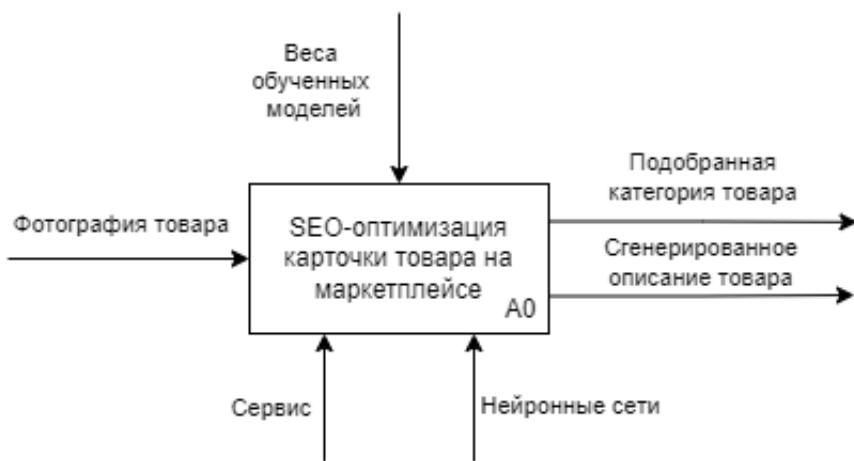


Рис. 2.1: Постановка задачи.

Для достижения целей и задач проекта требуется решить задачу многоклассовой классификации изображений (от англ. multiclass image classification) для подбора наиболее подходящей категории по фотографии товара, а также решить задачу создания подписей к изображениям (от англ. image captioning). Для успешной реализации проекта необходимо выбрать подходящие модели и определить метрики, которые будут использоваться для оценки их эффективности.

### 3 Обзор существующих решений

На данный момент существуют несколько сервисов, позволяющих сгенерировать описание товаров по характеристикам, ключевым словам или фотографии. Однако нет сервисов для подбора наиболее подходящей категории товара на маркетплейсе по фотографии. Для продавцов было бы крайне полезно иметь эти функциональности одновременно. Это значительно упростило бы процесс подготовки и публикации товаров, а также повысило эффективность и точность их работы.

#### 3.1 TurboText.Pro

TurboText.Pro — это сервис, который создает описания по фотографии или характеристикам товара [43]. Во втором случае текст будет более качественным, так как ИИ генерирует описание на основе заданных параметров. Нейросеть создает три описания для одного товара, что позволяет выбрать лучший вариант и разместить его в карточке товара или использовать все варианты на разных платформах. Также можно заказать улучшение текста или SEO-оптимизацию для продвижения товара на «Wildberries» у опытных копирайтеров.

Преимущества данного сервисы:

- высокая скорость генерации (1-2 секунды);
- развернутое описание товара;
- все функции доступны бесплатно;
- возможность сгенерировать описание товара по фотографии или характеристикам;
- возможность заказать SEO-оптимизацию описания товара.

Недостатки:

- генерация только на русском языке;
- качество описания по фото ниже, чем описания по характеристикам товара;
- ограничение при генерации описания по характеристикам — от 30 символов.

На рисунках 3.1 и 3.2 представлен интерфейс данного сервиса.

**VESVEN 400 г/кв.м, 104 см, Молния**

**Вариант 1** 17 октября, 13:31

Зимнее пальто прямого силуэта. Выполнено из плотной плащевой ткани с водоотталкивающей пропиткой, из подкладке. Модель имеет два кармана на молнии и один нагрудный карман с клапаном на кнопках. Рукава втачные длинные на манжетах. Воротник-стойка. Наполнитель: полизифирное волокно, плотностью 400 г/кв.м. рассчитано на температурный режим до -20 градусов. Ткань верха: 100% полиэстер. Утеплитель: 400 г/кв.м. Рекомендованный температурный режим от 0 до -30 градусов.

[Скопировать описание](#)

**Вариант 2** 17 октября, 13:31

Теплая куртка-пуховик выполнена из водоотталкивающего материала. Модель застегивается на молнию с двумя бегунками, также имеется один карман в боковом шве. Воротник стойка, два прорезных кармана на молнии. Рукава втачные со шлицами, с трикотажными манжетами и регулировкой объема по низу изделия. Низ куртки по линии талии регулируется кулиской. Подкладка капюшона, полочек и спинки выполнена из хлопковой ткани. Ткань верха — плащевая ткань с водоотталкивающим покрытием.

[Скопировать описание](#)

**Вариант 3** 17 октября, 13:31

Зимняя верхняя одежда VESVEN изготовлена из высококачественной водоотталкивающей ткани, которая обеспечивает 100% защиту от влаги и ветра. Утеплитель нового поколения (400 г/кв.м) сохраняет тепло до -30С. Удобный крой позволяет надеть куртку на любой тип фигуры. Подкладка изделия выполнена из мягкого трикотажа. На куртке имеются боковые карманы, а также один внутренний карман. В рукавах предусмотрена резинка для плотного прилегания к телу.

[Скопировать описание](#)

### Описание для товара

**Бренд** VESVEN

**Категории** Верхняя одежда, Пуховики

**Характеристики**

Плотность синтетического утеплителя	400 г/кв.м
Длина изделия по спинке	104 см
Вид застежки	Молния
Сезон	зима

[Изменить продукт](#)

**Улучшите описание товара**

Закажите SEO-оптимизацию описания товара или его доработку на бирже копирайтинга TurboText. Десятки опытных копирайтеров готовы приступить к заказу прямо сейчас.

[Улучшить описание](#)

Рис. 3.1: Генерация описание товара по характеристикам с помощью сервиса TurboText.Pro.

## 3.2 Gerwin

Gerwin — создает описания для товара по ключевым словам [10].

Преимущества данного сервисы:

- высокая скорость генерации (1-2 секунды);
- есть варианты генерации на разных языках;
- разные описания к одному товару на выбор;
- можно протестировать сервис бесплатно по промокоду.

Недостатки:

- ограничение по количеству ключевых слов — не больше 3-х;
- из-за ограничений исходных данных нельзя сделать более развернутое описание товара;
- нет возможности сгенерировать описание товара по фотографии;
- чтобы протестировать сервис бесплатно, нужно «добыть» промокод через Telegram-бота. Время ожидания — в течение 8 часов.

На рисунке 3.3 представлен интерфейс данного сервиса.

The screenshot shows a product description page for a pink quilted jacket. At the top, there are tabs for 'TURBO TEXT' (selected), 'Контент от нейросетей' (Content from neural networks), 'Контент от профессионалов' (Content from professionals), and 'Проверка контента' (Content verification). A 'Вход или регистрация' (Login or registration) button is also present.

**Описание товара по фото**

**Вариант 1** 1 июня в 09:49

Эта стильная и удобная женская стеганая куртка идеально подойдет для прохладной погоды. Она изготовлена из высококачественного полиэстера, который не пропускает ветер и влагу, а также из современного утеплителя, который сохраняет тепло даже в самые холодные дни. Куртка имеет прямой край, воротник-стойку и застегивается на молнию. Два боковых кармана на молнии согреют ваши руки, а внутренний карман на молнии позволит вам хранить важные мелочи. Куртка имеет легкий вес и не сковывает движений, что делает ее идеальной для активного отдыха и повседневной носки.

**Характеристики:**

- \* Материал: полиэстер
- \* Утеплитель: синтепон
- \* Подкладка: полиэстер
- \* Цвет: фуксия
- \* Размер: 42-48
- \* Длина: 60 см
- \* Рукав: 65 см
- \* Плечо: 40 см
- \* Грудь: 96 см
- \* Талия: 84 см
- \* Бедра: 98 см

**Уход:**

- \* Стирать в стиральной машине при температуре не выше 30 градусов
- \* Не отбеливать
- \* Сушить в расправленном виде
- \* Гладить при температуре не выше 110 градусов

[Скопировать описание](#)

Созданы 1 июня в 09:49 [Проверить](#) на TURBOCHECK

Рис. 3.2: Генерация описания товара по фотографии с помощью сервиса TurboText.Pro.

The screenshot shows a product listing for a 'VESVEN Пуховик женский зимний, куртка зимняя. нейлон 100%' on Wildberries. The listing includes fields for 'Название товара' (Product name), 'Ключевые слова' (Keywords), 'Язык' (Language), and a text area for 'Описание товара для Wildberries' (Product description for Wildberries).

**Описание товара для Wildberries**

Создание убедительных описаний товаров для использования на веб-сайтах, в электронных письмах и социальных сетях

**Название товара \*** 0/80  
VESVEN Пуховик женский зимний, куртка зимняя. нейлон 100%

**Ключевые слова** 0/3  
Плотность синтетического утеплителя 400 г/кв.м ×  
Длина изделия по спинке 104 см. × Вид застежки молния ×

**Язык**  
Русский

**Описание товара для Wildberries**

несколько секунд назад ★ 171  
Этот женский зимний пуховик изготовлен из 100% нейлона и имеет плотность синтетического утеплителя 400 г/кв.м. Он застегивается на молнию, а длина спины составляет 104 см.

2 минуты назад ★ 179  
Женский зимний пуховик vesven изготовлен из 100% нейлона и тканей утеплителем плотностью 400 г/кв.м. Изделие имеет высоту 104 см по спине и застегивается на молнию.

3 минуты назад ★ 131  
Это женская зимняя пуховая куртка, изготовленная из 100% нейлона. Это отличный выбор для встречи в холодные зимние месяцы.

Рис. 3.3: Сервис Gerwin.

### 3.3 CopyMonkey

CopyMonkey — создает описание для товара по его характеристикам и ключевым словам [5].

Преимущества данного сервисы:

- высокая скорость генерации (1-2 секунды);
- доступны бесплатные ежедневные попытки;
- разные описания к одному товару на выбор.

Недостатки:

- низкое качество текста, нейросеть просто сгруппировала характеристики;

- есть логические несостыковки в тексте;
- один вариант описания товара без возможности выбора.

На рисунке 3.4 представлен интерфейс данного сервиса.

The screenshot shows the CopyMonkey service interface for generating product descriptions. The main sections include:

- Название товара \***: Пуховик женский зимний (22/350 characters used).
- Детали товара**: Плотность синтетического утеплителя - 400 г/кв.м, Длина изделия по спинке - 104 см, Вид застежки - молния, Длина одежды ниже колена, Комплектация пояс, Пол Женский, Сезон зима (163/2000 characters used).
- Ключевые слова**: Например, свитер в подарок (0/30 characters used), with suggestions Пуховик and Зимняя куртка.
- Результат**: Пуховик женский зимний – это плотный синтетический утеплитель, изделие длиной по спинке 104 см. Застежка – молния. Длина одежды – ниже колена. Комплектация – пояс. Пол – Женский. Сезон – зима.
- История**: Not visible in the screenshot.
- Buttons**: Очистить форму (Clear form) and Генерировать (Generate).

Рис. 3.4: Сервис CopyMonkey.

### 3.4 Сравнительный анализ существующих решений

TurboText.Pro генерирует более развернутое описание товара, но есть пара неточностей, которые легко поправить, потратив на это не больше минуты. После описание можно размещать в карточке товара интернет-магазина или на маркетплейсе. CopyMonkey и Gerwin справляются со своей задачей хуже. Все три сервиса можно протестировать бесплатно и выбрать тот, который подходит для работы лучше всего.

Сравнительный анализ существующих решений может быть представлен в таблице 3.1.

Сервис	Стоимость	Генерация по фотографии	Качество генерации
TurboText.Pro	Бесплатно	+	Высокое
Gerwin	Бесплатно	—	Среднее
Copymonkey	Бесплатно 3 попытки в день	—	Низкое

Таблица 3.1: Сравнение существующих решений по генерации SEO-описания товара.

## 4 Данные

Для достижения поставленной цели и задач проекта, данные должны удовлетворять следующим требованиям:

- данные должны быть достоверными и правильно отражать характеристики товаров;
- данные должны иметь четкую классификацию товаров по категориям и подкатегориям, соответствующих структуре категорий маркетплейсов в РФ (например, «Ozon» или «Wildberries»);
- данные должны быть структурированы в удобном для обработки формате, таком как CSV, JSON или в виде базы данных;
- данные должны включать фотографии товаров с разных ракурсов и в различных вариациях, а также иметь их текстовые описания;
- необходимо иметь достаточное количество данных для каждой категории товаров, чтобы обеспечить репрезентативность для анализа и обучения моделей;
- данные должны быть актуальными и регулярно обновляемыми для отражения текущих трендов и состояния рынка.

На данный момент существуют несколько датасетов для работы с товарами, взятых с интернет-магазинов электронной торговли:

- Fashion-MNIST — набор данных, используемый для категоризации товаров. Он содержит почти 60 000 обучающих изображений и 10 000 тестовых изображений одежды и аксессуаров, разделенных на 10 категорий: футболка, брюки, свитер, платье, пальто, сандалии, рубашка, кроссовки, сумка и ботинки. Каждое изображение имеет размер 28x28 пикселей и представлено в оттенках серого [11].
- Innerwear Data from Victoria's Secret and Others — набор данных, включающий информацию более чем о 600 000 товарах нижнего белья, собранных из популярных торговых точек. В этот набор входят описания продуктов, цены, категории и рейтинги [24].
- eCommerce Item Data — набор данных, включающий артикулы и соответствующие описания продуктов из каталога бренда верхней одежды. Эти данные отлично подходят для использования в рекомендательных системах [23].

- Fashion Products on Amazon — набор данных, созданный на основе извлеченной информации с Amazon. Он включает около 22 000 товаров и содержит описания продуктов, цены, категории и рейтинги [45].

Поскольку в открытых источниках не имеется удовлетворяющего всем требованиям датасета, данные для поставленной задачи собирались самостоятельно. Был проведен анализ на возможность парсинга наиболее популярных маркетплейсов в РФ «Ozon» и «Wildberries».

Анализ парсинга «Ozon»	Анализ парсинга «Wildberries»
Сильная защита, частая блокировка пользователей, смена userAgent не всегда помогает.	Слабая защита, не требуется смена userAgent.
Динамический контент страниц и ленивая подгрузка, что создает трудности при парсинге, вынуждая «прокручивать» экран вниз.	Динамический контент страниц и ленивая подгрузка, что создает трудности при парсинге, вынуждая «прокручивать» экран вниз.  Динамическая подгрузка отзывов, которая усложняет скачивание фотографий из них.
Огромное количество категорий и подкатегорий.	Приемлемое количество категорий и подкатегорий.
Большая вариативность описания, нет единого шаблона для парсинга. Так например, когда-то вместо текстов могут быть просто картинки или описание товара сопряжено с картинкой.	Единое оформление карточки товара, упрощает парсинг товара: его описание, характеристики, фотографии из seo и из отзывов.

Таблица 4.1: Сравнительный анализ маркетплейсов «Ozon» и «Wildberries»

Таким образом, было принято решение писать ВКР для продавцов, использующих «Wildberries», так как он является наиболее популярным среди продавцов, а также легче поддается парсингу. Данные собирались согласно особенностям структуры этого маркетплейса. Для удобства введем некоторые термины, которыми будем оперировать далее:

- **Карточка товара** – это страница продукта на маркетплейсе, где размещена информация о товаре, фотографии, описание цены и кнопка «Купить»
- **Конечная категория** – это категория, на которых располагаются карточки товаров
- **Материнская категория** – это категория, которая содержит конечные и материнские категории и на которой не располагаются карточки товаров

Каталог «Wildberries» разделен на категории, в которых размещены карточки товаров одного типа. Категории выстроены по принципу дерева. Есть основные «широкие» категории, такие как «Женщинам», «Дом», «Продукты», которые объединяют внутри себя более

мелкие подкатегории. Например, в разделе «Дом» имеются подкатегории «Ванная», «Кухня», «Спальня» и тд, которые в свою очередь могут подразделяться на еще более маленькие подкатегории.

Требуемые данные располагались на товарных карточках, в которые можно попасть только зная конечную категорию товара. Поэтому было принято решение разделить сбор данных на 2 этапа. На первом этапе был произведен сбор всех имеющихся на «Wildberries» конечных категорий. На втором – сбор необходимой информации с карточек товаров.

## 4.1 Этап 1

«Wildberries» предлагает 22 основные категории (см. рисунок 4.1), из которых одна является конечной категорией. Данные категории в дальнейшем будем называть категориями первой вложенности. Их подкатегории, соответственно, будут называться категориями второй вложенности. И так далее, спускаясь все ниже по дереву категорий. Экспериментальным путем была выявлена максимальная глубина вложенности – 5.

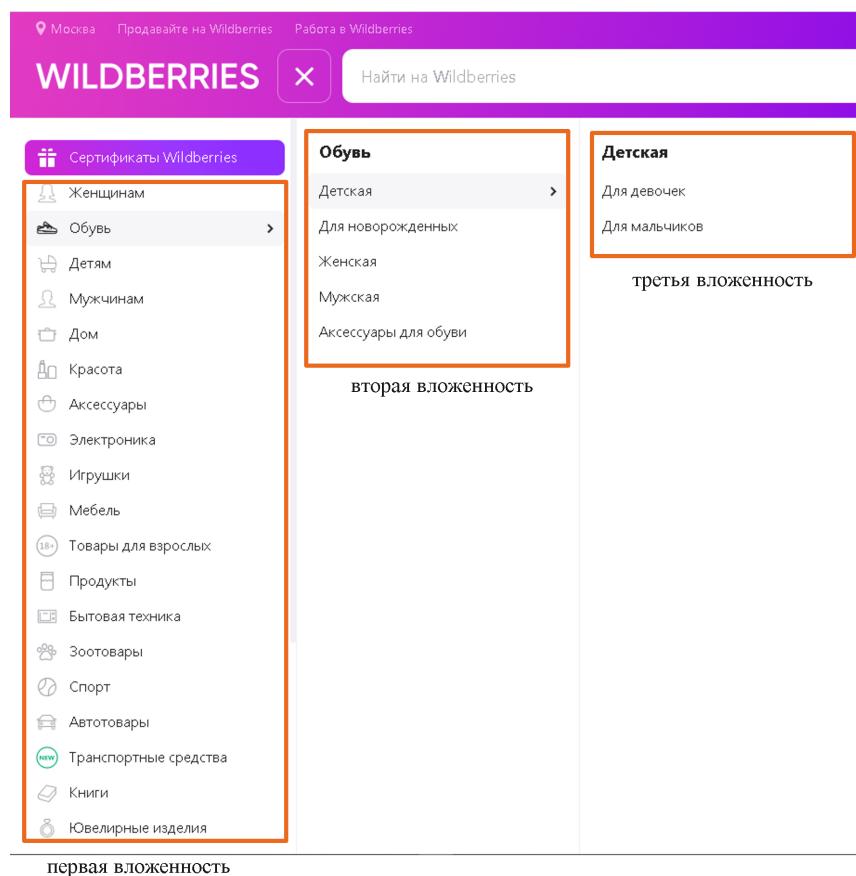


Рис. 4.1: Структура каталога «Wildberries» на примере категории «Обувь».

Для правильного формирования таргета для классификации при сохранении ссылки на конечную категорию нужно было учитывать весь путь по дереву категорий, начиная с

первой вложенности. Решением данной задачи стало создание таблицы, где отражалось какие категории было предшествовавшими конкретной конечной категории (см. таблицу 4.2). При отсутствии более глубокой вложенности на месте данных категорий ставились «NaN». Таким образом, было собрано 1668 конечных категорий.

Таблица 4.2: Фрагмент таблицы, полученной после первого этапа сбора данных.

	category1	category2	category3	category4	category5
437	Дом	Предметы интерьера	Фоторамки и фотоальбомы	Фотоальбомы	NaN
438	Дом	Предметы интерьера	Картинки и постеры	Рамы для постеров	NaN
439	Дом	Предметы интерьера	Картинки и постеры	Постеры	Детская тематика
440	Дом	Предметы интерьера	Картинки и постеры	Картинки	Арт и абстракция
441	Дом	Предметы интерьера	Картинки и постеры	Постеры	Фэнтези
url					
437	<a href="https://www.wildberries.ru/catalog/dlya-doma/predmety-interera/fotoramki-i-fotoalbomy/fotoalbomy">https://www.wildberries.ru/catalog/dlya-doma/predmety-interera/fotoramki-i-fotoalbomy/fotoalbomy</a>				
438	<a href="https://www.wildberries.ru/catalog/dlya-doma/predmety-interera/kartiny/ramy-dlya-posterov">https://www.wildberries.ru/catalog/dlya-doma/predmety-interera/kartiny/ramy-dlya-posterov</a>				
439	<a href="https://www.wildberries.ru/catalog/dlya-doma/predmety-interera/kartiny/postery/detskaya-tematika">https://www.wildberries.ru/catalog/dlya-doma/predmety-interera/kartiny/postery/detskaya-tematika</a>				
440	<a href="https://www.wildberries.ru/catalog/dlya-doma/predmety-interera/kartiny/kartiny/art-i-abstraktsiya">https://www.wildberries.ru/catalog/dlya-doma/predmety-interera/kartiny/kartiny/art-i-abstraktsiya</a>				
441	<a href="https://www.wildberries.ru/catalog/dlya-doma/predmety-interera/kartiny/postery/fentezi">https://www.wildberries.ru/catalog/dlya-doma/predmety-interera/kartiny/postery/fentezi</a>				

Составление данной таблицы производилось посредством парсинга данных с сайта «Wildberries» через Python с использованием библиотек selenium и BeautifulSoup. Блокировок со стороны маркетплейса замечено не было. Особенность и неудобством парсинга была динамическая подгрузка страниц, которая вынуждала выдерживать паузы в несколько секунд для удовлетворяющей загрузке страницы. Данное обстоятельство привело к значительному увеличению времени парсинга данных.

При анализе собранной таблицы были выявлены некоторые особенности категориальной политики «Wildberries». Во-первых, категории у данного маркетплейса не фиксированы. Например, было отмечено, что часть категорий активно перемещается из раздела в раздел, какие-то категории могут пропадать, также могут появляться новые категории. Данные, собранные в текущем датасете, актуальны на конец января 2024 года. Однако для поддержания списка категорий в актуальном состоянии необходимы механизмы регулярного обновления данных. Во-вторых, на маркетплейсе имеются конечные категории, ссылающиеся на одни и те же url страницы. Подобные категории будут называться дублирующими. Подобные дублики могли иметь разное происхождение: особенности маркетинга и неудачное время парсинга, выпавшее на перемещение категорий. С точки зрения маркетинга подобные дублирования оправданы, поскольку потенциальный покупатель может по своим соображениям относить одни и те же товары к разным категориям. Для примера, категория «Коврики» находилась в разделе «Автотовары\_Коврики» и «Электроника\_Автоэлектроника&и&навигация\_Коврики». Для корректной работы модели была напи-

сана отдельная процедура удаления подобных дублирующих категорий. Выбор, какой из дубликатов оставлять, производился вручную. Всего было найдено 69 дублирующих ссылок, которые могли встречаться 2 и более раза. Таким образом, после удаления в таблице осталось 1580 категорий.

Далее можно было переходить ко 2му этапу.

## 4.2 Этап 2

Второй этап сбора данных заключался в прохождении по собранному ранее списку конечных категорий и сбора из каждой из них информации с карточек товаров. Было принято решение брать по 20 товаров из каждой конечной категории. Из каждой карточки товара сохранялось первое фотография от продавца, первая фотография из отзыва и описание товара (см. рисунок 4.2). Первая фотография от продавца бралась по причине ее обязательного присутствия в карточке товара, а также гарантированного качественного изображения товара на ней. Однако поскольку разрабатываемый сервис рассчитан на работу в большинстве случаев с фотографиями от пользователей, все дефекты, присущие любительским фотографиям могут иметь место быть. Поэтому для стабильности предсказаний классификационной модели, было решено подавать в нее также фотографии из отзывов, которые максимально близко будут похожи на фотографии, с которыми будет работать в дальнейшем сервис. Описания товара были нужны для задачи генерации текстовых описаний к изображениям. В итоге при полном наборе для каждой конечной категории имелось 40 фотографий (20 фотографий от продавцов и 20 фотографий из отзывов) и 20 описаний.

При выполнении данного этапа было несколько трудностей. Во-первых, стандартная на «Wildberries» динамическая загрузка страниц, увеличивающая время парсинга более чем в 3 раза. Приходилось делать паузы при открытии страницы с карточкой товара, при открытии описания, лежащее в отдельной вкладке, и пролистывание страницы вниз для подгрузки информации об отзывах. Примерное время парсинга данных, затраченное на второй этап, равнялось 2м неделям. Во-вторых, имели товары с меткой «18+», для которых требовалось дополнительное нажатие кнопки, подтверждающее достижение указанного возраста. В-третьих, некоторые поля в карточке товара заключали в себе картинки, которые вынуждали в определенных случаях дополнительно пролистывать страницу вниз. В-четвертых, для нажатия кнопки с целью получения описание к товару, выдвигалось требование расположение кнопки в зоне видимости экрана. Это приводило к еще более тонкой настройке пролистывания страницы, подобранный под конкретный размер экрана компьютера.

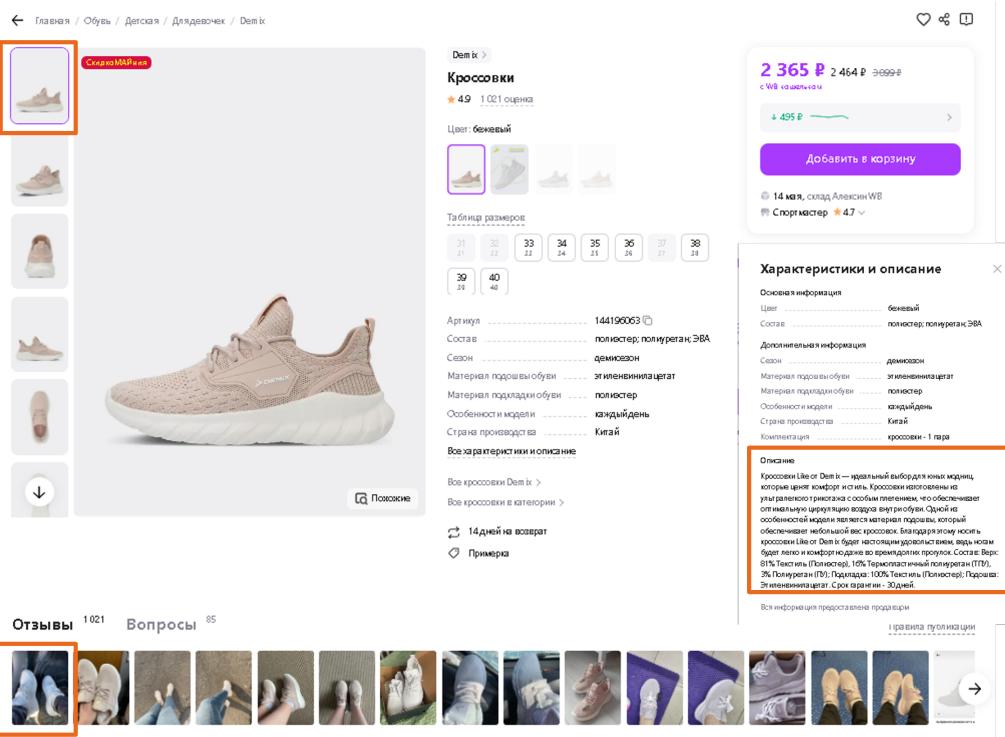


Рис. 4.2: Пример карточки товара на «Wildberries». Верхний левый прямоугольник – первая фотография от продавца. Нижний левый прямоугольник – первая фотография из отзыва. Правый прямоугольник – текстовое описание товара.

Для сохранения данных из карточек товара была придумана специальная структура с целью дальнейшего удобства использования в задаче классификации и генерации текста. Все товары, собранные из одной конечной категории, сохранялись в отдельную папку, содержащую следующие элементы:

- папку «card», куда складывались фотографии от продавцов
- папку «feedbacks», куда складывались фотографии из отзывов
- файл «descriptions.csv», где сохранялись описания к товарам

Название данной папки определялось посредство таблицы 1 и складывалось из всех материнских категорий, участвовавших в пути к конечной категории. Например, для конечной категории «Фотоальбомы» (см. таблицу 4.2) название папки было следующее: «Дом\_Предметы&интерьера\_Фоторамки&и&фотоальбомы\_Фотоальбомы», а для категории «Фэнтези» - «Дом\_Предметы&интерьера\_Картины&и&постеры\_Постеры\_Фэнтези». Более подробно об использовании подобной структуры ранения данных будет описание в разделе 6.2.

Первичный анализ собранных данных выявил, что не у всех товаров имелись отзывы с фотографиями и описания. Описания имелись в 99.8% процента случаев. В таблице 4.3

приведены некоторые статистические данные о собранных фотографиях от продавца и из отзыва. Можно заметить, что некоторые конечные категории были полностью без фотографий в отзывах. Однако, опираясь на перцентили, можно сделать вывод, что таких категорий было довольно мало. Касательно фотографий от продавцов можно сделать 2 вывода. Во-первых, есть категории, представленные менее чем 20ю товарами. Во-вторых, есть как минимум одна категория, в которой имеется только 1 товар. Подобные категории нас не устраивают, потому что далее будет производиться деление каждой категории на 2 части, и категории с одним товаром невозможно будет разделить.

Таблица 4.3: Описательная статистика по фотографиям от продавца (столбец «card») и фотографиям из отзыва (столбец «feedbacks»).

	card	feedbacks
count	1580	1580
mean	19.98	17.72
std	0.63	4.23
min	1	0
25%	20	18
50%	20	19
75%	20	20
max	20	20

Всего категорий, представленных менее 20 товарами, было выявлено 5 штук (см. таблицу 4.4). Из них представляли наибольший интерес \_\_ и \_\_, из-за чересчур малого количества товаров. Категорию с одним товаром было решено удалить. Таким образом, осталось 1579 конечных категорий, с которыми шла вся дальнейшая работа.

Таблица 4.4: Таблица с категориями, имеющими менее 20 товаров.

кол-во товаров	категория
18	Дом _Кухня _Кухонный&текстиль _Чехлы&для&ручек&холодильников
4	Дом _Освещение _Лифты&для&люстр
19	Мебель _Гардеробная&мебель _Ящики
1	Мебель _Офисная&мебель _Перегородки&офисные
19	Мебель _Офисная&мебель _Шкафы

При более детально рассмотрении собранных данных было замечено, что фотографии из отзывов довольно шумные (см. рисунок 4.3). Очень много одинаковых фотографий, фотографий, где не очень понятно, что изображено. Поэтому для дальнейшей работы использовались только фотографии товара от продавца.

Далее интересно было рассмотреть количество собранных данных в разрезе категорий первой вложенности (см. рисунок 4.4). Из круговой диаграммы можно заметить, что категории довольно несбалансированный. Например, категория «Дом» вмещает в себя порядка

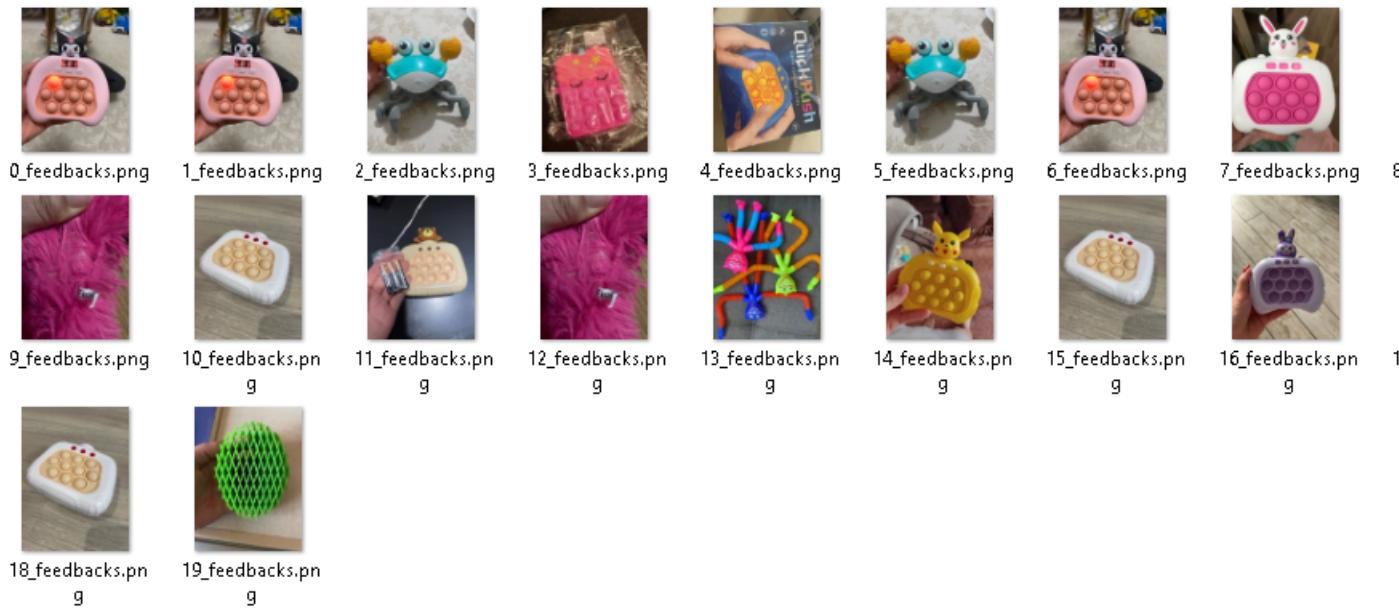


Рис. 4.3: Фотографии из отзывов в категории «Игрушки\_Антистресс».

6000 пример. В то время как в категории «Ювелирные&изделия» только 320 примеров.

Подобную картину можно наблюдать в категориях всех вложенностей (см. приложение А).

После появление базового понимания данных надо было приступить к их детальному изучению. Как правило, парсинг большого количества данных, тем более с постоянно меняющихся маркетплейсов, не проходит идеально. В сохранных данных могут быть оплошности, которые помешают грамотно решать задачу классификации и генерации текста. Приведем некоторые примеры, выявленных особенностей, требуемых принятие решений с нашей стороны:

- Встречаются категории, которые с точки зрения категорийного менеджмента, имеют место быть. Одна для классификационной модели машинного обучения такие категории будут не осиливаемыми. Например, в разделе «Женщинам» есть подкатегории «Женщинам\_Белье» и «Женщинам\_Большие&размеры\_Белье». Если детально изучить фотографии, которые в этих категориях присутствуют, можно сделать вывод, что особых различий между ними нет. Единственное, что было подмечено, что на очень немногих фотографиях стоит надпись «4XL» или что-то подобное, указывающее, что у данного товара имеются большие размеры. Более того, в обеих категориях присутствуют одинаковые товары.
- В данных попадались «мусорные» категории. Предположительно, подобное возникало из-за изменения url ссылок на категории со стороны «Wildberries». В подобных катего-

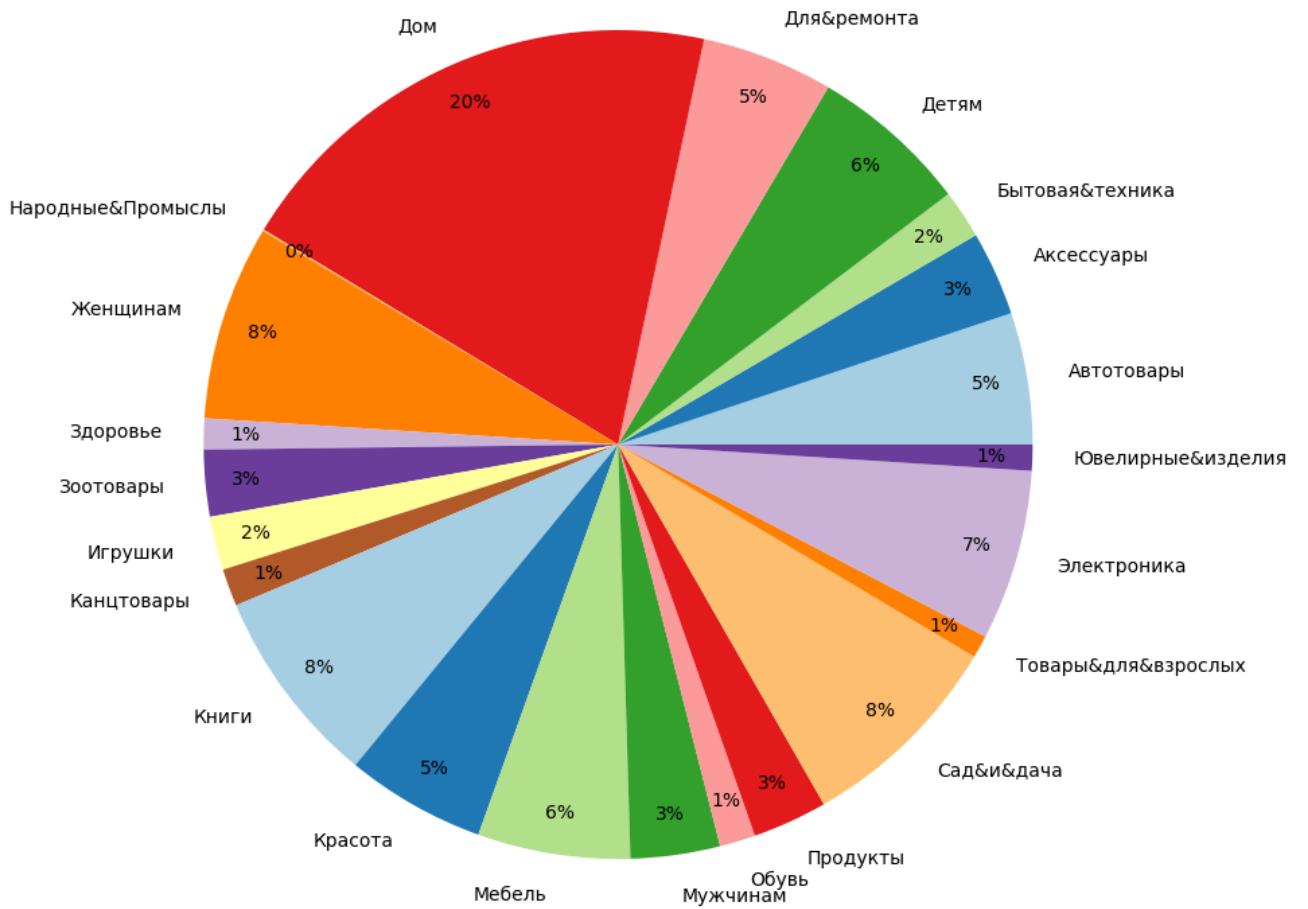


Рис. 4.4: Распределение данных по категориям первой вложенности.

риях находились товары, собранные случайным образом из всевозможных категорий с маркетплейса.

- Распределение товаров по категориям не очень четкая задача. В связи с этим встречались одинаковые товары, находящиеся в разных категориях. Например, одна и та же продукт мог находиться в категориях «Зоотовары\_Груминг&и&уход», «Зоотовары\_Для кошек\_Груминг&и&уход» и «Зоотовары\_Для собак\_Груминг&и&уход».
- В части материнских категорий встречались разделы «Подарки» (например, материнские категории «Мужчинам\_Подарки&мужчинам» и «Женщинам\_Подарки&женщинам»), куда были собраны товары из совершенно разных категорий, таких как «Аксессуары», «Дом», «Продукты» и тд.
- Поскольку при парсинге из каждой категории брались первые 20 товаров, появляется неконтролируемый фактор того, какие товары стоят вначале. Как правило, пользовате-

ли смотрят только на первые товары в выдаче. Поэтому на маркетплейсах существуют множество механизмов и правил отбора товаров, которые будут показаны пользователю в начале. В нашем случае было замечено, что некоторые категории стали более шумными из-за сезонных товаров. Например, в категории «Зоотовары \_Фермерство» были найдены пасхальные яйца.

- Бывали категории, которые по смыслу имели место быть как отдельные категории, однако в них были собраны не совсем подходящие товары. Например, в категории «Мужчинам \_Религиозная \_Православие» находились обычные рубашки и штаны, часть из которых присутствовала также в категории «Мужчинам \_Рубашки» и «Мужчинам \_Брюки».

Приведенные особенности сохраненных данных требовали ручной очистки датасета. Необходимо было применять следующие действия: полное удаление категории, удаление конкретной фотографии из отзыва, удаление товара полностью (фотографию от продавца, из отзыва и описание к нему) и произведение полного переноса товара (фотографию от продавца, из отзыва и описание к нему) из одной категории в другую. Для удобства и быстроты данной процедуры были написаны функции, позволяющие механизмами Python вносить изменения в собранные данные.

По окончании данной процедуры было подмечено, что категории требовали очистки в разной степени. Какие-то категории, как «Зоотовары», требовали практически полного переформирования. Другие категории обходились легкой очисткой, например «Продукты». Некоторые категории совсем не требовала вмешательства. Таким образом, финальный датасет стал состоять из 1459 конечных категорий (см. таблицу 4.4).

Таблица 4.5: Описательная статистика по фотографиям от продавца после очистки собранных данных. Примечание: статистика по фотографиям из отзывов не приведена, поскольку, как упоминалось ранее, решено было в дальнейшем работать только с фотографиями от продавца.

	card
count	1385
mean	20.31
std	3.95
min	4
25%	20
50%	20
75%	20
max	116

## 5 Теоретические основы

### 5.1 Задача многоклассовой классификации изображений

Задача многоклассовой классификации изображений заключается в том, чтобы отнести каждое изображение из набора данных к одной из заранее определенных категорий или классов. Для решения задачи необходимо использовать разнообразный набор изображений, каждый из которых должен быть помечен (аннотирован) соответствующим классом.

Для многоклассовой классификации часто используют сверточные нейронные сети, такие как ResNet, MobileNet или EfficientNet (подробнее см. в разделе 5.2). Для оценки качества модели обычно применяются следующие метрики: Accuracy, Precision, Recall и F1-score (подробнее см. в разделе 5.3).

Для повышения производительности модели можно использовать различные методы, например:

- тонкая настройка гиперпараметров — корректировка параметров обучения, таких как скорость обучения, размер батча и т.д.
- дополнительная аугментация данных — применение различных преобразований к изображениям, таких как повороты, сдвиги, масштабирование, для увеличения разнообразия обучающих данных.
- использование предобученных моделей — начинать обучение с модели, предварительно обученной на большом наборе данных, таком как ImageNet.

### 5.2 Обзор классификаторов изображения

В этом разделе будет дан обзор существующих классификаторов изображений, их архитектурные особенности, а также преимущества и недостатки.

#### 5.2.1 ResNet

ResNet (Residual Neural Network) — это семейство моделей нейронных сетей, разработанные для решения проблемы затухания градиента [15]. Модели получили широкое признание и стали основой для многих современных архитектур благодаря своей способности эффективно тренировать очень глубокие нейронные сети.

Ключевой инновацией ResNet является использование остаточных блоков (от англ. residual blocks), которые помогают бороться с проблемой затухания градиентов в очень глубоких сетях.

боких сетях. Основная идея заключается в том, чтобы добавить прямые связи (от англ. skip connections) через несколько слоев, что позволяет градиентам легче проходить через сеть.

Остаточный блок — это компонент архитектуры ResNet, который содержит «обходную связь идентичности», обходящую один или большее количество слоев. Остаточный блок состоит из двух или трех сверточных слоев с прямой связью, которая пропускает входы блока напрямую к его выходу. Это помогает сохранять информацию от предыдущих слоев и упрощает обучение. На рисунке 5.1 представлен пример остаточного блока.

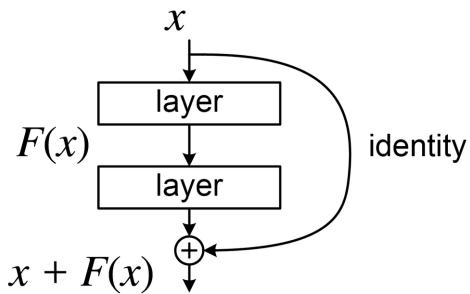


Рис. 5.1: Остаточный блок [15].

ResNet предлагает несколько версий моделей с различной глубиной: ResNet-18, ResNet-34, ResNet-50, ResNet-101, ResNet-152. Эти версии различаются количеством остаточных блоков и слоев, что позволяет выбрать модель, соответствующую конкретной задаче и доступным вычислительным ресурсам.

### 5.2.2 MobileNet

MobileNet — это семейство моделей нейронных сетей, специально разработанных для работы на мобильных и встраиваемых устройствах [17]. Они хорошо оптимизированы и обеспечивают высокую точность при низких вычислительных затратах. MobileNet широко используется в задачах компьютерного зрения, таких как классификация изображений, детекция объектов и сегментация.

Основной инновацией MobileNet является использование глубоких разделяемых сверточных слоев вместо стандартных. Глубокие разделяемые сверточные слои состоят из двух отдельных операций: глубинного свертывания (от англ. depthwise convolution) и точечного свертывания (от англ. pointwise convolution). Глубинное свертывание применяется отдельно к каждому каналу входного изображения, а точечное свертывание используется для объединения выходов глубинного свертывания.

MobileNet использует параметры разложения для управления шириной сети (от англ. width multiplier) и разрешением входного изображения (от англ. resolution multiplier).

Width multiplier уменьшает количество каналов в каждой сверточной операции, что снижает количество вычислений и параметров, а resolution multiplier уменьшает размер входного изображения, что дополнительно снижает вычислительные затраты.

Благодаря глубинным разделяемым сверточным слоям и параметрам разложения, MobileNet достигает хорошего баланса между производительностью и вычислительными затратами. На рисунке 5.2 представлена архитектура MobileNet слоя.

MobileNet Layer Architecture

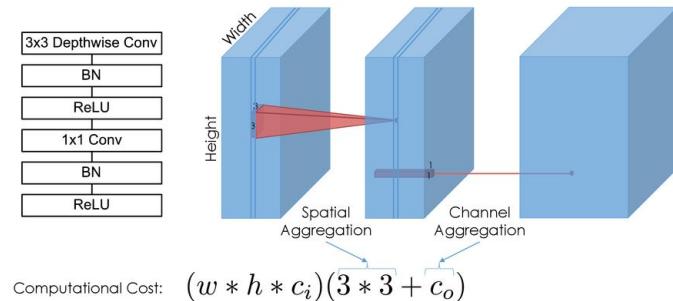


Рис. 5.2: Архитектура MobileNet слоя [17].

На данный момент существует несколько версий MobileNet, каждая из которых приносит свои улучшения и оптимизации.

MobileNetV2 — включает улучшения, такие как инвертированные остаточные блоки (от англ. inverted residuals) и линейные узкие слои (от англ. linear bottlenecks) [37]. Эти улучшения помогают сохранять более полезные характеристики признаков и обеспечивают лучшую производительность при тех же вычислительных затратах. Разница между остаточным и инвертированным остаточным блоком представлена на рисунке 5.3.

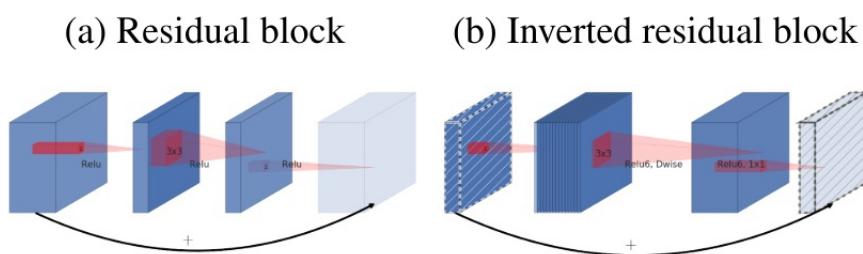


Рис. 5.3: Разница между остаточным и инвертированным остаточным блоком [37].

MobileNetV3 — включает дополнительные улучшения, такие как блоки сжатия и возбуждения (от англ. squeeze-and-excitation, SE) и расширенные функции активации [16], см. рисунок 5.4. Блоки SE позволяют сети лучше фиксировать канальные зависимости в дан-

ных, помогает повысить способность модели извлекать значимые функции из входных данных, что приводит к повышению производительности задач распознавания изображений. MobileNetV3 использует расширенные функции активации, такие как h-swish и h-sigmoid. Эти функции обеспечивают более плавные градиенты во время обучения, что может привести к более быстрой сходимости и повышению общей производительности. MobileNetV3 предоставляет две версии: MobileNetV3-Large и MobileNetV3-Small, предназначенные для различных требований производительности и эффективности.

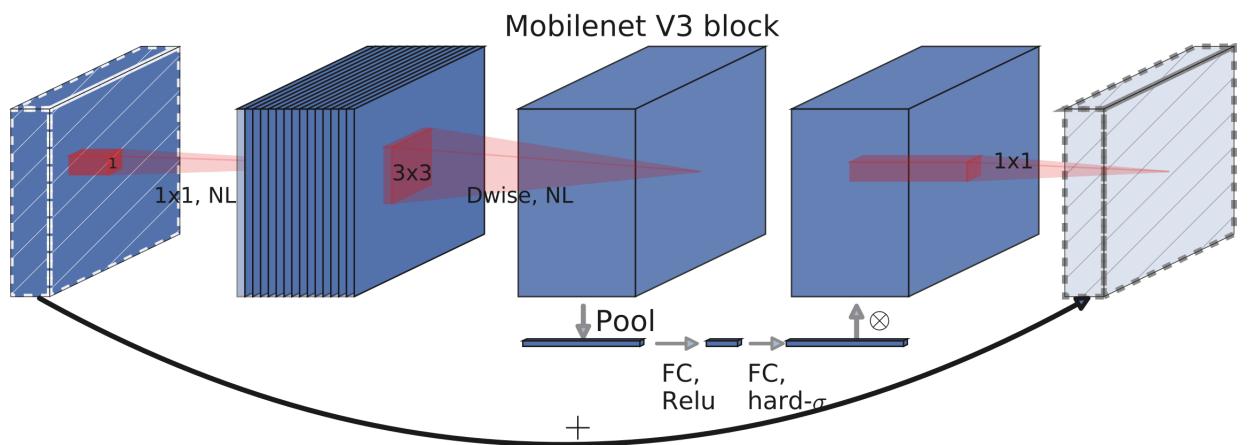


Рис. 5.4: MobileNetV3 блок [16].

Однако, несмотря на свою эффективность и компактность, MobileNet в сравнении с более крупными и сложными моделями, такими как EfficientNet, может не достигать такой же высокой точности на некоторых задачах компьютерного зрения.

### 5.2.3 EfficientNet

EfficientNet — архитектура нейронной сети, основанная на идее масштабирования моделей и сбалансированного изменения глубины, ширины (количество каналов) сети, а также разрешения изображений[40]. Применяется новый метод составного масштабирования (от англ. compound scaling method), который одновременно изменяет глубину, ширину и разрешение с фиксированными пропорциями между этими параметрами. Метод составного масштабирования показан на рисунке 5.5.

Архитектура EfficientNet состоит из следующих ключевых компонентов:

1. MBConv (англ., Mobile Inverted Bottleneck Convolution) — основной строительный блок EfficientNet, унаследованный из архитектуры MobileNetV2. MBConv включает в себя следующие элементы:

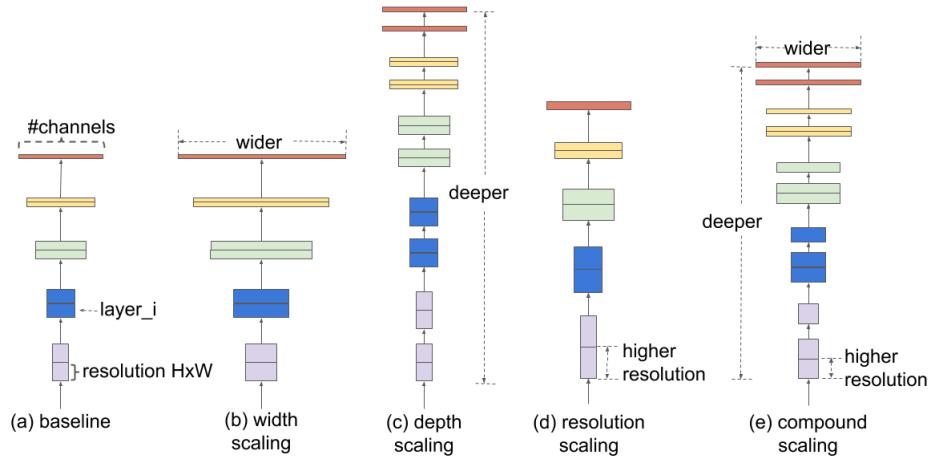


Рис. 5.5: Различные методы масштабирования по сравнению со составным[40].

- Pointwise Convolution ( $1 \times 1$ ) — уменьшает размерность каналов, улучшая вычислительную эффективность.
  - Depthwise Convolution ( $3 \times 3$  или  $5 \times 5$ ) — выполняет свертку по каждому каналу независимо, что значительно снижает количество параметров.
  - Squeeze-and-Excitation Block — улучшает представление важных характеристик путем адаптивного перенастройки каналов.
2. Использование функции активации Swish, которая демонстрирует лучшие результаты в глубоких сетях благодаря своей непрерывности и плавности.
3. Compound Scaling — ключевая концепция EfficientNet, включающая одновременное масштабирование трех аспектов модели:

- Глубина — увеличение количества слоев в сети.
- Ширина — увеличение количества каналов в каждом слое.
- Разрешение — увеличение разрешения входных изображений.

Подход compound scaling обеспечивает сбалансированное увеличение модели, что позволяет достигать высокой точности и производительности без чрезмерного увеличения вычислительных затрат, что делает EfficientNet особенно привлекательной для внедрения в мобильные устройства.

Существует несколько версий EfficientNet, каждая из которых разработана для различных применений и требований к вычислительным ресурсам. Оригинальные модели используют простой метод compound scaling, который включает масштабирование глубины,

ширины и разрешения изображений с помощью фиксированных коэффициентов. В то время как EfficientNetV2 улучшает этот метод, вводя динамическое масштабирование, которое позволяет более гибко адаптировать модель к различным задачам и условиям. Также EfficientNetV2 использует улучшенные блоки, такие как Fused-MBConv, которые объединяют традиционные MBConv и элементы из ResNet, что позволяет увеличить эффективность обучения и улучшить качество представления данных.

Оригинальные модели EfficientNet (B0 - B7):

- EfficientNet-B0 — базовая модель, на основе которой построены все остальные версии, использует минимальное количество параметров и вычислительных ресурсов. Архитектура сети представлена на рисунке 5.6
- EfficientNet-B1 - B7 — модели, которые последовательно масштабируются с использованием compound scaling, увеличивая глубину, ширину и разрешение. Каждая следующая версия обладает большей вычислительной мощностью и точностью по сравнению с предыдущей.

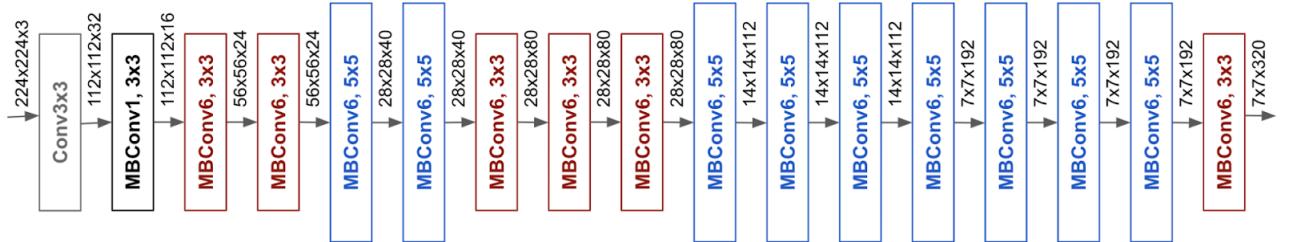


Рис. 5.6: Архитектура базовой сети EfficientNet-B0[42].

Модели EfficientNetV2 (S, M, L):

- EfficientNetV2-S — оптимизированная версия для мобильных устройств, характеризующаяся компактностью и высокой эффективностью. Подходит для приложений, где критичны вычислительные ресурсы и время отклика.
- EfficientNetV2-M — средняя версия, предлагающая баланс между производительностью и вычислительными затратами. Часто используется в серверных и облачных средах.
- EfficientNetV2-L — наиболее мощная версия, предназначенная для задач, требующих максимальной точности и производительности. Используется в высокопроизводительных системах и приложениях с большими объемами данных.

Благодаря продуманному подходу к масштабированию, все версии EfficientNet демонстрируют высокую точность на стандартных наборах данных, таких как ImageNet. Стоит отметить, что модели EfficientNetV2 значительно превосходят оригинальные модели EfficientNet. Так например, EfficientNetV2-M снижает параметры на 17 %, а количество операций ввода-вывода — на 37 %, но при этом работает в 4.1 раза быстрее при обучении и в 3.1 раза быстрее при выводе, чем EfficientNet-B7. Кроме того, EfficientNetV2 обеспечивает лучшую точность при значительно меньшем времени выполнения, чем предыдущие модели ConvNet и Vision Transformers на ImageNet [41]. Несмотря на высокую производительность, EfficientNetV2 не использует механизм внимания, как ViTs, что может быть недостатком в некоторых случаях.

#### 5.2.4 Vision Transformers

Визуальные трансформеры (от англ. Vision Transformers, ViTs) – класс моделей глубокого обучения, которые представляют собой архитектуру в области компьютерного зрения, адаптированную из трансформеров, широко используемых в обработке естественного языка [7]. Основная идея заключается в разделении изображения на небольшие патчи (части), которые затем обрабатываются как токены последовательности в модели трансформера. ViTs используют механизм самовнимания для анализа изображений, что позволяет моделям эффективно захватывать глобальные и локальные зависимости в данных. Vision Transformers достигли выдающихся результатов в задачах классификации изображений.

Архитектура Vision Transformers состоит из следующих этапов (см. рисунок 5.7):

1. Разделение на патчи. Изображение делится на небольшие патчи фиксированного размера (например, 16x16 пикселей), которые затем выравниваются в одномерные векторы. Каждый патч рассматривается как токен в последовательности.
2. Линейное преобразование патчей. Каждому патчу сопоставляется эмбеддинг фиксированной размерности с помощью линейного слоя. Этот шаг аналогичен созданию эмбеддингов для слов в задачах NLP.
3. Добавление позиционных эмбеддингов. Поскольку трансформеры изначально не содержат информации о позиции токенов, то к эмбеддингам патчей добавляются позиционные эмбеддинги, которые кодируют пространственное положение каждого патча в исходном изображении.
4. Последовательность патчей передается через многослойную трансформерную модель, состоящую из чередующихся слоев самовнимания (self-attention) и полносвязных слоев

(feed-forward), с целью учесть взаимосвязи между всеми патчами одновременно, эффективно захватывая глобальные и локальные зависимости в изображении.

5. К началу последовательности патчей добавляется специальный классификационный токен CLS, который предназначен для агрегирования информации от всех патчей и используется для финальной классификации. Выходной эмбеддинг CLS токена передается через несколько полносвязных слоев с функцией активации (например, ReLU), завершающихся слоем Softmax для получения вероятностей классов. Финальная классификационная голова преобразует выходной эмбеддинг в предсказание класса для всего изображения.

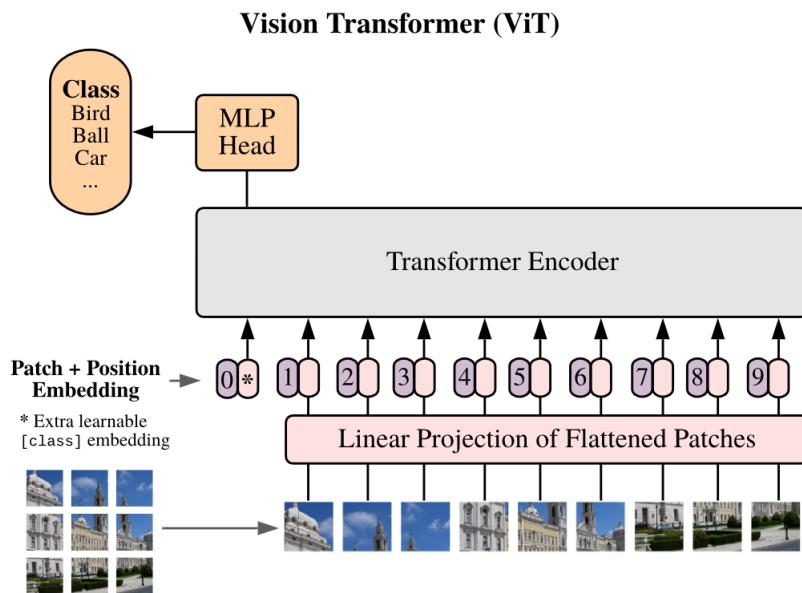


Рис. 5.7: Архитектура Vision Transformers[7].

Архитектура Vision Transformers достигла высоких показателей производительности в задаче классификации изображений на датасете ImageNet после предварительного обучения на JFT-300M [7]. Однако важно отметить, что эффективность моделей резко снижается при использовании небольших объемов данных для предварительного обучения. Более крупные модели чаще всего показывают лучшие результаты на больших наборах данных. Это проблема, вероятно, связана с тем, что трансформерные сети не имеют предварительных предположений о порядке данных, что может привести к их недостаточной адаптации к конкретным требованиям задачи или к обучающему набору данных.

### 5.3 Метрики качества в задаче классификации

Одним из важных аспектов любой оптимизационной задачи является выбор метрик качества. Оценку качества классификационных моделей можно измерять многими способами, каждый из которых отражает различные стороны модели. Выбор основной метрики качества косвенно оказывает сильное влияние на конечный результат, поскольку при обучении модели с гиперпараметрами, их подбор производится с целью увеличения значения выбранной метрики качества. В свою очередь выбор метрики качества зависит от поставленной задачи, чаще всего зависящей от бизнес-целей, а также от особенностей данных, с которыми производится работа. Наиболее распространенными метриками качества для задачи классификации являются точность (англ. precision), полнота (англ. recall), F-мера (англ. F1-measure), ROC-AUC, индекс Джини и другие. Сперва некоторые из них будут рассмотрены с теоретической точки зрения. Затем в рамках задачи, поставленной в данной работе.

Наиболее простой в понимании является метрика accuracy<sup>1</sup> – доля правильных ответов:

$$\text{accuracy}(a, X) = \frac{1}{n} \sum_{i=1}^n [a(x_i) = y_i], \quad (1)$$

где  $a$  - алгоритм,  $X$  - объекты,  $n$  - кол-во объектов,  $a(x_i)$  - предсказание алгоритма на объекте  $x_i$ ,  $y_i$  - истинные ответы. Однако из-за своей простоты accuracy имеет сильные недостатки и не походит в большинстве реальных задач. Наиболее серьезной проблемой является плохое отражение качества работы алгоритма при несбалансированных данных. Она абсолютно не учитывает дисбаланс классов. Например, в задаче диагностики редких заболеваний классификатор, предсказывающий всем пациентам отсутствие болезни будет иметь достаточно высокую accuracy просто потому, что больных людей в выборке намного меньше. Другим ее недостатком является то, что по ней нельзя сказать, в какую сторону ошибается алгоритм. Можно снова привести в пример задачу медицинской диагностики: в случае ошибочного положительного диагноза для здорового больного обернётся лишь ещё одним обследованием, то ошибочно отрицательный вердикт может повлечь роковые последствия. Разновидность обычной accuracy является метрика accuracy top-k, которая измеряет процент случаев, когда истинный класс присутствует среди верхних  $k$  предсказанных классов. Top-k accuracy полезна, когда интерес представляет не только самый вероятный предсказанный класс, но и его ближайшие альтернативы. Чаще всего рассчитывается accuracy@top2. В этом случае модель

---

<sup>1</sup>Во избежание путаницы с названием метрик качества на русском языке, поскольку некоторые из них имеют одинаковый перевод, в тексте будут использоваться их английский названия.

оценивается по тому, насколько точно она предсказывает правильный класс, если учитывать два наиболее вероятных класса (первый и второй по вероятности). Это означает, что если правильный класс присутствует среди первых двух предсказанных классов, то это считается успешным предсказанием.

Для расчета многих метрик используется матрица ошибок классификаций (англ. confusion matrix). Рассмотрим принцип ее построения на примере бинарной классификации и алгоритма, предсказывающего принадлежность каждого объекта одному из классов (см. таблицу 5.1). Как правило, класс, представляющий интерес, называется «положительным» (в таблице – класс 1), а оставшийся – «отрицательным» (в таблице – класс 0). Вся матрица разделена на 4 части, отражающие возможные ситуации при предсказании. В верхнем левом квадрате (англ. true positive) находятся объекты, у которых был предсказан «положительный» класс, и он совпал с истинным. В противоположность в правом нижнем углу (англ. true negative) находятся объекты, у которых был предсказан «отрицательный» класс, который также совпал с истинным. На другой диагонали находятся так называемые «ошибки» модели. В нижнем левом углу помещаются объекты, которые алгоритм не смог опознать как «положительный» класс. В правом верхнем квадрате – объекты, которые алгоритм ошибочно отнес к «положительному» классу.

	$y = 1$	$y = 0$
$\hat{y} = 1$	True Positive (TP)	False Positive (FP)
$\hat{y} = 0$	True Negative (TN)	False Negative (FN)

Таблица 5.1: Матрица ошибок классификации.  $y$  – истинный класс,  $\hat{y}$  – результат модели.

На матрице ошибок основываются такие метрики как precision, recall и их агрегация F1-мера: Precision (см. формулу 2) отражает то, насколько можно доверять классификатору. Другими словами, это доля объектов, которые классификатор определил как положительные и при этом они действительно являются положительными. Введение precision не позволяет определять все объекты в один класс, так как в этом случае получается рост false positive объектов. Recall (см. формулу 3) показывает, какую долю положительных объектов из всех объектов положительного класса обнаружила модель. Recall отражает способность метода вообще обнаруживать данный класс, а precision – способность отличать этот класс от других. В отличие от accuracy, recall и precision не зависят от соотношения классов и поэтому могут быть применимы на несбалансированном датасете. Однако, используемые по отдельности, данные метрики не дают полного понимания картины. Если precision равен 1, то ложноположительные классификации отсутствуют. Однако это ничего не говорит о том, были ли

распознаны все положительные примеры. Если же recall равен 1, то все положительные объекты были распознаны правильно, а ложноотрицательные классификации отсутствуют. При этом ничего не говорится о том, сколько было допущено ложноположительных классификаций.

$$precision = \frac{TP}{TP + FP} \quad (2)$$

$$recall = \frac{TP}{TP + FN} \quad (3)$$

Как уже было сказано ранее F1-мера объединяет precision и recall в своей оценки (см. формулу 4). В базовом варианте F1-мера предполагает одинаковую важность precision и recall, однако если одна из этих метрик является более приоритетной, можно воспользоваться  $F_\beta$  мерой.

$$F_\beta = (1 + \beta^2) \cdot \frac{precision \cdot recall}{(\beta^2 \cdot precision) + recall} \quad (4)$$

$\beta$  в данном случае определяет вес точности в метрике.

Все вышеперечисленные метрики качества являются ограниченными сверху и снизу и располагаются в интервале  $[0, 1]$ . F1-мера достигает максимума при точности и полноте, равными 1, и близка к 0, если один из аргументов близок к 0. Данная особенность позволяет производить точное сравнение качества разных моделей классификации.

Другим семейством метрик в задаче классификации выступают интегральные метрики<sup>2</sup>. Данные метрики удобны тем, что она показывают качество классификатора независимо от выбранного порога. В классификационных моделях часто стоит вопрос о правилах отнесения объекта к положительному или отрицательному классу. Обычно для этого используется вероятностный порог. Из модели возвращается оценка вероятности принадлежности объекта к положительному классу и в зависимости от установленного порога объект будет отнесен к соответствующему классу. Для поставленной задачи будут интересны следующие интегральные метрики: ROC-curve, PR-curve, AUC и Average Precision. Рассмотрим подробнее каждую из них.

Наиболее интуитивным является порог, равный 0.5. Однако такой порог отсечения не всегда может являться оптимальным. При уменьшении порога отсечения будет находить-

---

<sup>2</sup>Интегральная метрика качества – метрика, отражающая качество алгоритма, вне зависимости от выбранного порога.

ся (правильно предсказываться) всё большее число положительных объектов, но также и неправильно предсказываться положительная метка на всё большем числе отрицательных объектов. Для этого были введены две метрики TPR (true positive rate) и FPR (false positive rate) (см формулу 5). TPR отражает долю неверно принятых объектов отрицательного класса, FPR – долю верно принятых объектов положительного класса.

$$TPR = \frac{TP}{TP + FN} \quad FPR = \frac{FP}{FP + TN} \quad (5)$$

В терминах TPR и FPR как раз и строится ROC-curve (см. рисунок 5.8). При идеальной классификации ROC кривая начинается в точке (0; 0), проходит через верхний левый (точка (0;1)) и заканчивается в правом верхнем углу (точка (1;1)). В случае случайной работы классификатора ROC кривая будет иметь диагональный вид, начинаясь в нижнем левом углу и заканчиваясь в правом верхнем.

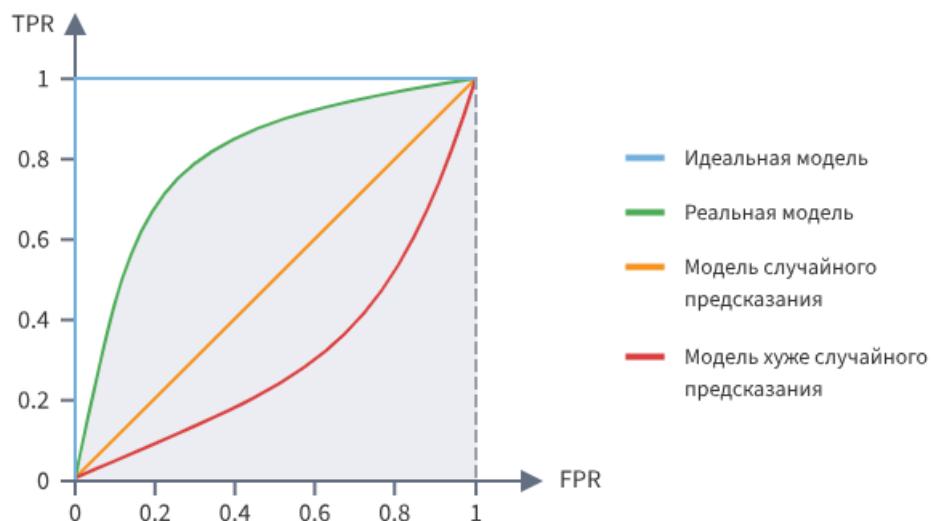


Рис. 5.8: Пример построенной ROC кривой. [<https://loginom.ru/blog/classification-quality>]

Для более точного сравнения ROC кривых считают показатель AUC (Area Under the ROC Curve) – площадь под ROC кривой. Данная мера может принимать значения в диапазоне от 0 до 1, где 1 достигается при идеально классификации, а 0.5 соответствует случайной классификации. Метрика AUC довольно стабильна к дисбалансу классов, а также в целом показывает, насколько хорошо работает алгоритм.

Другой часто анализирующейся кривой является Precision-Recall кривая (PR-curve) (см. рисунок 5.9). В случае чрезесчур малой доли объектов положительного класса ROC-AUC может давать неадекватно хороший результат. PR-curve строится в терминах precision и recall, рассчитанных при разных порогах отсечения. Поскольку данная кривая строится в

терминах precision-recall, которые устойчивы к дисбалансу классов, то и сама кривая более точно отражает качество модели при несбалансированных данных.

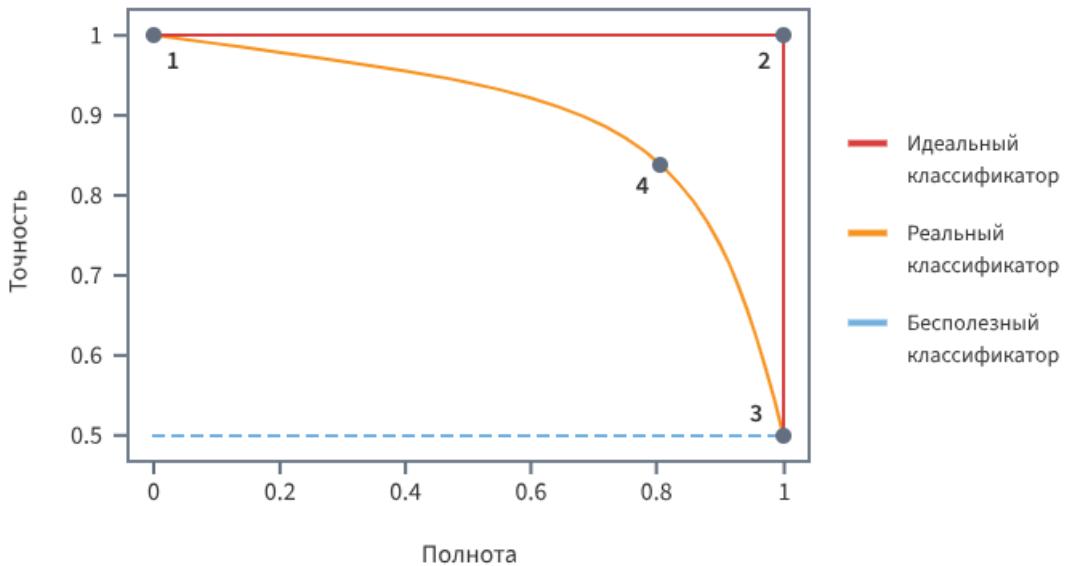


Рис. 5.9: Пример построенной PR кривой. [<https://loginom.ru/blog/classification-quality>]

Аналогичной метрике AUC является метрика Average Precision (AP), отражающая площадь под PR кривой.

Все вышеупомянутые метрики рассматривались в рамках задачи бинарной классификации. Однако в нашем случае решается задача многоклассовой классификации, поэтому необходима адаптация метрик. Существует 3 основных подхода к расчету метрик в многоклассовом случае: микроусреднение (англ. micro average), макроусреднение (англ. macro average) и взвешенное среднее (англ. weighted average). Идея всех подходов – сведение подсчета метрик к бинарному случаю.

При микроусреднении для каждого класса  $k$  в отдельности рассчитываются элементы матрицы ошибок ( $TP_k, FP_k, TN_k, FN_k$ ). Затем полученные характеристики усредняются по всем классам (см. формулу 6) и используются для расчета precision и recall.

$$TP = \frac{1}{K} \sum_{k=1}^K TP_k \quad (6)$$

В макроусреднении также для каждого класса  $k$  в отдельности рассчитываются элементы матрицы ошибок ( $TP_k, FP_k, TN_k, FN_k$ ). Далее на основании полученных значений производится расчет  $precision_k$  и  $recall_k$  (см. формулу 7). Затем происходит усреднение полученных характеристик по классам (см. формулу 8).

$$precision_k(a, X) = \frac{TP_k}{TP_k + FP_k} \quad (7)$$

$$precision(a, X) = \frac{1}{K} \sum_{k=1}^K precision_k(a, X) \quad (8)$$

При взвешенном среднем происходит аналогичный расчет макроусреднению. С тем отличием, что в макроусреднении усреднение по классам происходило с равными весами, а в случае взвешенного среднего усреднение метрик, рассчитанных для каждого класса, происходит с весами, пропорциональными количеству объектов в классе.

Используя микроусреднение, уменьшается влияние малочисленных классов. При макроусреднении вклад каждого класса в финальную метрику будет одинаковым. Третий подход является неким компромиссом между первыми двумя.

Теперь перейдем к использованию метрик качества в рамках данной работы. Проектируемый сервис исходит в первую очередь из бизнес-задачи. Разрабатывается функционал для улучшения ключевых метрик, таких как привлечение новых пользователей, конверсия и увеличения прибыли. предложив уникальные функции, которых нет у конкурентов, или те, которые превосходят конкурирующие решения. К сожалению, бизнес-задачи напрямую не всегда можно переложить в измеримые метрики. К таким целям как раз относится и увеличение прибыли компании, которая зависит от многих факторов и не подходит в качестве измерителя в задачах машинного обучения. Кроме того, оценить эффективность нового функционала возможно только спустя месяц, поскольку потребуется время для составления корректных отчетов по продажам, или по завершении сезона, когда продавцы, используя сервис, смогут подобрать наилучшую категорию товаров. Это, в свою очередь, может привести к росту продаж, что станет показателем успешности предложенных решений. Для этого удобно проведение А/В-тестирования, которое позволяет сравнивать результаты «с» и «без» использования нового функционала, а также получить точные данные о его влиянии на ключевые метрики.

Разобравшись с метриками, исходящими от бизнеса, и придя к заключению о невозможности их использования напрямую в данном проекте, стало крайне важным найти наиболее близко коррелируемые с данными показателями метрики машинного обучения.

Поскольку данные, с которыми производится работа, имеют сильный дисбаланс классов, более подходящими метриками качества будут являться precision, recall и их обобщения. Стоит отметить, что в поставленной формулировке задачи достижение идеального качества не является обязательным условием, поскольку неточности модели могут быть обернуты в рамки взаимодействия с пользователем. Например, при неуверенной классификации можно попросить пользователя перезагрузить другую фотографию или попросить выбрать наи-

более подходящую по его мнению категория из списка наиболее подходящих категорий по мнению модели. В данной работе для получения более обширной картины при построении и оптимизации классификационных моделей рассчитывались как интегральные, так и зависящие от выбранного порога метрики. В качестве неинтегральных метрики рассчитывались accuracy, precision, recall, f1. Из них наибольший интерес представляла метрика precision, поскольку цена неверно подобранный категории для объекта довольно высока. Другими словами, гораздо важнее получить уверенный классификатор, который будет допускать минимум ошибок при своей высокой уверенности в полученном результате. Также некоторый интерес представляла accuracy@top2. Она полезна в ситуации, когда уверенность в предсказании модели не настолько высока, чтобы рассматривать только самое вероятное предсказание. Поскольку работа происходит с реальными данными (все особенности собранных данных см. раздел 4.2), с большой вероятностью могут быть изображения, на которых нельзя однозначно определить класс, или товары, которые могут быть отнесены к разным, но относительно похожим категориям. В таком случае top-2 accuracy позволит учесть эту неопределенность.

В отношении использования микро и макроусреднений в поставленной задаче стоит отметить, что поскольку во всех моделях присутствует в разной степени дисбаланс классов, в макроусреднении при усреднении метрик малых и больших классов важность объектов малочисленных классов будет завышена. В альтернативном случае при микроусреднении плохие предсказания для малочисленных классов будут растворяться по общем фоне метрики, то есть их роль в финальном показателе будет преуменьшена. Исходя из целей работы и особенностей собранных данных, в разрабатываемой классификационной модели важно предсказывать правильно все классы, а не только наиболее большие и популярные. То есть при обучении классификационных моделей и анализе их качества ориентир будет направлен главным образом на метрики, полученные посредством макроусреднения.

Как уже было сказано ранее, на финальное предсказание модели можно повлиять с помощью выбранного вероятностного порога отсечения, согласно которому тот или иной объект будет или не будет относиться к положительному классу. В задачах с взаимодействием с пользователями такая настройка может сыграть решающую роль, поэтому для более грамотного принятия решения при получении предсказаний мы будем опираться на Precision-Recall кривую. При понижении порога отсечения модель большее число объектов будет попадать в положительный класс, то есть произойдет увеличение recall. При повышении вероятностного порога модель будет больше уверена в своих предсказания, однако шанс выявить все объекты положительного класса сократиться, то есть произойдет увеличение precision. Порог отсечения подбирался в каждом классификаторе индивидуально.

Также для полной картины для каждого классификатора были построены ROC кривые и рассчитаны AUC и Average Precision.

## 5.4 Задача создания подписей к изображениям

Задача создания подписей к изображениям (от англ. image captioning) предполагает использование методов глубокого обучения для генерации текстовых описаний на основе визуального содержимого изображений. Для решения этой задачи используется архитектура кодера-декодера (от англ. encoder-decoder). Основные подходы для ее реализации:

1. Использование комбинации сверточных нейронных сетей для обработки изображения и рекуррентных нейронных сетей для генерации подписи.
2. Использование трансформеров.

Архитектура с использованием комбинации CNN и RNN представлена на рисунке 5.10. В качестве кодировщика используется CNN, такие как ResNet, MobileNet или EfficientNet. Эти модели предварительно обучены на больших наборах данных, таких как ImageNet, для извлечения визуальных признаков. Кодировщик отвечает за преобразование изображения в компактное представление (вектор признаков), которое сохраняет важную информацию об изображении. В качестве вектора признаков изображения может использоваться выходной слой CNN, но чаще всего это слой перед последним полно связанным. Декодировщик принимает вектор признаков изображения и генерирует последовательность слов, которая описывает изображение. Декодеры, как правило, основаны на рекуррентных нейронных сетях (RNN), такие как LSTM (Long Short-Term Memory) или GRU (Gated Recurrent Unit). Одна из основных проблем такого подхода — это то, что RNN имеет фиксированную длину контекста и обрабатывает информацию последовательно. Это означает, что RNN видит только небольшой контекст, поэтому при генерации слов часто забывает старые результаты своей генерации. Так же такой подход не позволяет полностью учесть контекст изображения на каждом этапе генерации. В данном случае выделенные признаки изображения с помощью CNN лишь единожды подаются на вход LSTM блока, так что со временем генерация полностью теряет память о исходном изображении и начинает «додумывать самостоятельно». Для решения этих проблем применяется механизм внимания (от англ. attention)[2], основная идея которого состоит в том, чтобы позволить модели обрабатывать входные данные, учитывая их важность и относительные взаимосвязи между элементами данных. Это позволяет модели более гибко и точно адаптироваться к различным задачам и условиям входных дан-

ных, улучшая качество и эффективность моделирования. Механизм внимания может быть реализован разными способами:

- В классической реализации RNN скрытый вектор объединяет в себе информацию, содержащуюся в векторах вывода текущей итерации, через среднее или суммирование, которое можно заменить определенным взвешиванием всех предыдущих векторов, участвующих в усреднении, т.е для получения  $k$ -го скрытого вектора производится взвешивание  $k-1$  предыдущего вектора. Веса при этом подбираются в зависимости от важности того или иного слова, что позволяет модели сосредотачивать внимание на различных аспектах входных данных в соответствии с контекстом задачи.
- Механизм внимания может быть интегрирован для учета контекста изображения при генерации каждого слова в описании. В этом случае кодер обрабатывает входное изображение с тремя цветовых канала, и преобразует его в изображение меньшего размера с «обученными» каналами. Это уменьшенное изображение представляет собой сводное представление всех полезных данных из исходного изображения. Механизм внимания использует это закодированное изображение, что позволяет сети «обращаться» к различным частям изображения на каждом шаге генерации текста. Весь этот процесс можно интерпретировать как вычисление вероятности того, что пиксел является важным для генерации следующего слова (см. рисунок 5.11). Таким образом, контекст самого изображения не теряется в процессе генерации текста. Механизм внимания позволяет сети фокусироваться на разных частях изображения с различной степенью «важности» на каждом этапе генерации, что значительно улучшает качество финального описания. На рисунке 5.12 представлена архитектура декодера RNN с использованием механизма внимания на части изображения.

Преимущества реализации архитектуры с использованием комбинации CNN и RNN:

- CNN позволяет эффективно и точно выделять особенности изображения, что обеспечивает богатую информацию для генерации текста;
- модели CNN + RNN можно легко адаптировать и дообучать для различных задач и наборов данных.

К недостатком данной архитектуры можно отнести следующее:

- Несмотря на улучшения в виде LSTM и GRU, RNN могут испытывать трудности с моделеванием длинных текстов, что может влиять на качество генерации.

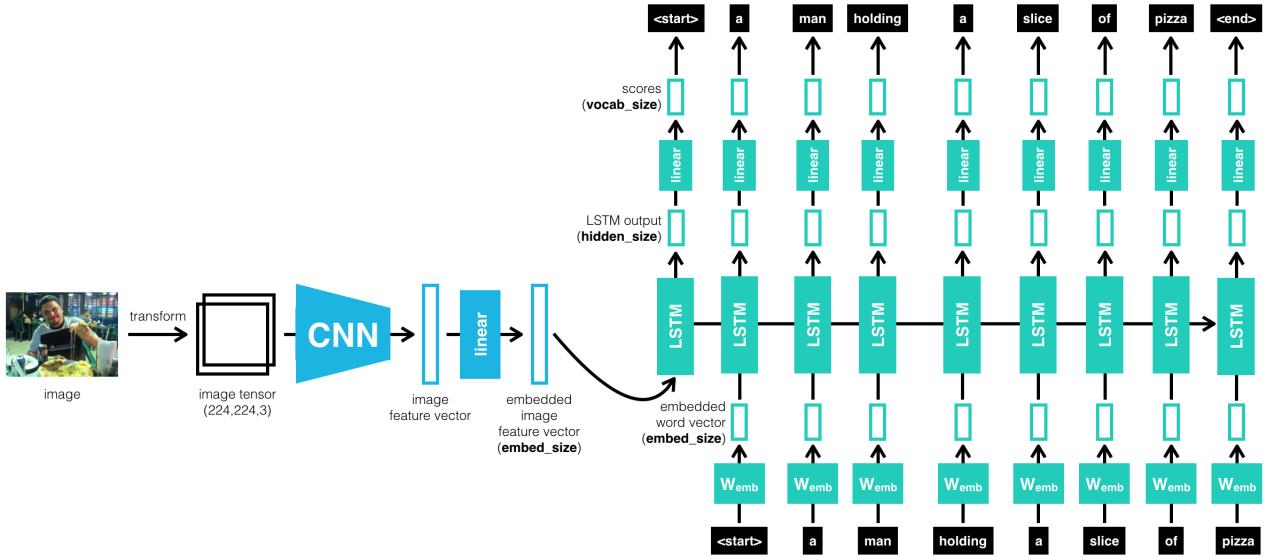


Рис. 5.10: Архитектура задачи Image Captioning с использованием комбинации CNN для обработки изображения и RNN для генерации подписи [38].

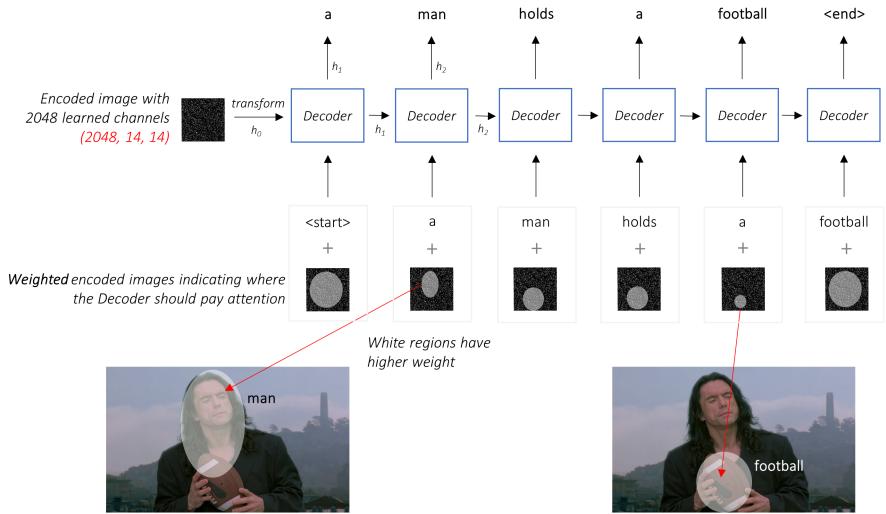


Рис. 5.11: Генерации последовательности с использованием механизма внимания на части изображения в задаче Image Captioning [12].

- RNN могут генерировать текст, который не всегда полностью согласован с изображением. Иногда описание может быть частично правильным, но при этом не охватывать все важные детали изображения.

Архитектура с использованием трансформеров представлена на рисунке 5.13. В качестве кодера используется Vision Transformers (ViTs), который применяет механизмы самовнимания к патчам изображения для извлечения признаков. В качестве декодера используются модели GPT, которые также используют механизмы самовнимания для моделирования долгосрочных зависимостей в тексте, что позволяет генерировать более связные и правильные описания. Ключевым моментом является правильная подача признаков изображения, извлече-

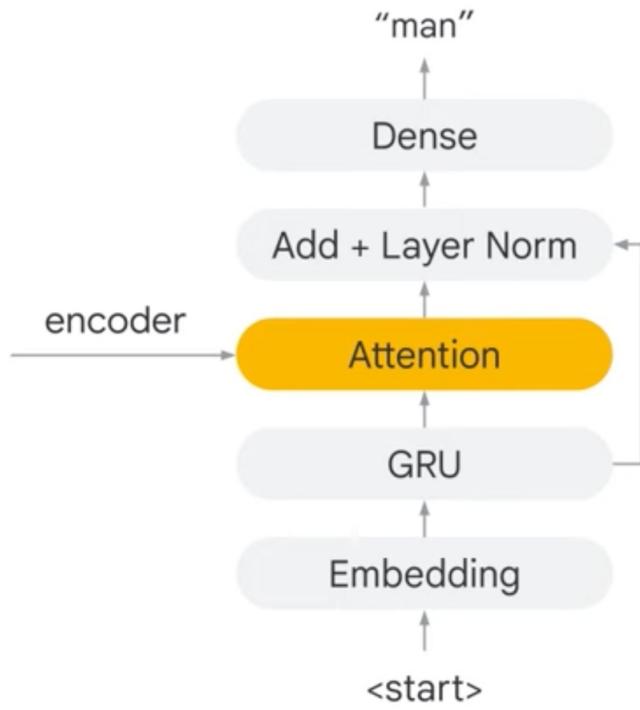


Рис. 5.12: Архитектура декодера RNN с использованием механизма внимания на части изображения в задаче Image Captioning [13].

ченных из ViTs, в соответствующие слои самовнимания GPT, то есть преобразование этих признаков в формат ключей (keys), значений (values) и запросов (queries).

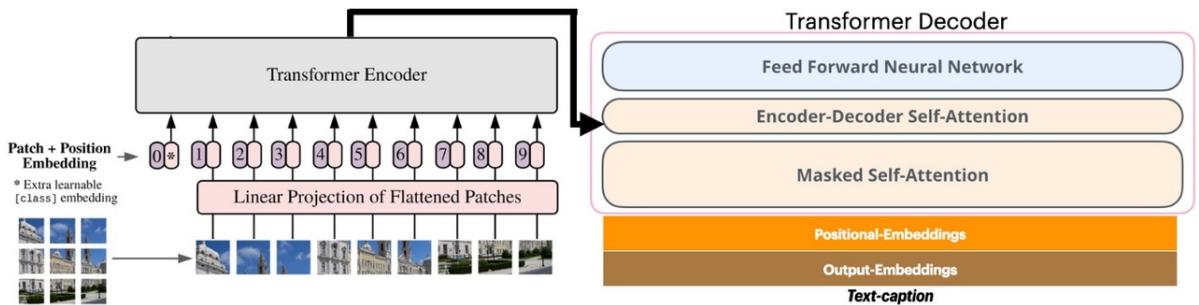


Рис. 5.13: Архитектура задачи Image Captioning с использованием трансформеров [18].

Преимущества реализации:

- способность обрабатывать большие объемы данных и извлекать сложные зависимости.
- модели GPT обладают высоким качеством генерации текста благодаря своему предобучению на огромных объемах текстовых данных. Они способны генерировать разнообразные и грамматически правильные описания для изображений.

К недостатком данной архитектуры можно отнести то, что обучение моделей ViTs и GPT требует значительных вычислительных ресурсов и времени из-за их огромного размера и сложности.

Стоит отметить, что совместить способы решения задачи нельзя, из-за фундаментальных различий в их архитектурных подходах и методах обработки данных. CNN и RNN работают на основе последовательной обработки данных, в то время как ViTs и GPT используют механизмы самовнимания, которые позволяют параллельно обрабатывать данные. Комбинация подходов может потребовать значительных изменений в архитектурах, что вряд ли приведет к улучшению результатов. Поэтому выбор архитектуры (CNN + RNN или ViT + GPT) зависит от конкретных требований проекта и условий, в которых будет использоваться модель. В некоторых случаях может быть полезным попробовать обе архитектуры и выбрать ту, которая лучше соответствует задачам и ресурсам.

## 5.5 Обзор моделей для генерации текста

В данном разделе рассматриваются ключевые модели генерации текста, их архитектурные особенности, а также преимущества и недостатки.

### 5.5.1 Рекуррентные нейронные сети

Рекуррентные нейронные сети (от англ. Recurrent Neural Networks, RNN) — это класс нейронных сетей, специально разработанных для обработки последовательных данных. RNN широко применяются в задачах, где порядок и зависимость данных во времени играют важную роль, например, в таких как обработка текста и генерация последовательностей.

RNN способны учитывать временные зависимости в данных, обрабатывая последовательности входных сигналов. Это достигается благодаря наличию скрытых состояний (hidden states), которые обновляются на каждом шаге последовательности и хранят информацию о предыдущих шагах. В отличие от обычных нейронных сетей, RNN имеют петли обратной связи, позволяющие информации циркулировать внутри сети. Это позволяет RNN «помнить» предыдущие шаги и использовать эту информацию для текущих вычислений (см. рисунок 5.14).

На каждом шаге  $t$  входной вектор  $x_t$  и предыдущее скрытое состояние  $h_{t-1}$  используются для вычисления текущего скрытого состояния  $h_t$ :

$$h_t = \tanh(W_h h_{t-1} + W_x x_t + b_h) \quad (9)$$

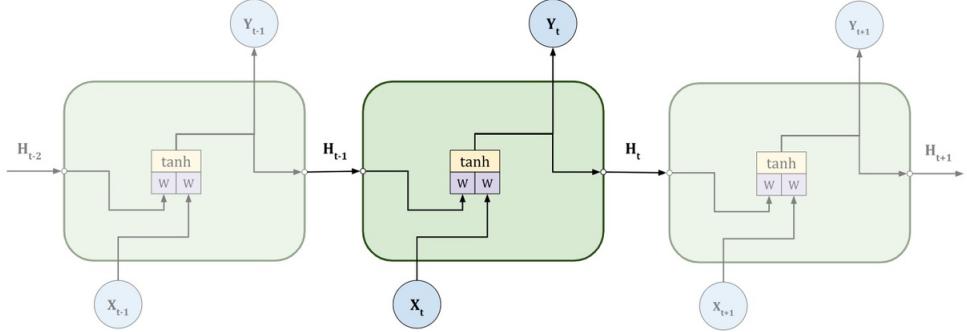


Рис. 5.14: Архитектура RNN.

где  $W_h$  и  $W_x$  — веса,  $b_h$  — смещение, и  $\tanh$  — активационная функция.

При обучении очень длинных последовательностей RNN могут столкнуться с проблемой затухания или взрыва градиентов. Это приводит к тому, что веса либо становятся очень маленькими, либо слишком большими, что затрудняет обучение.

Для решения проблем затухания и взрыва градиентов были предложены более сложные архитектуры, такие как Long Short-Term Memory (LSTM) и Gated Recurrent Unit (GRU).

LSTM — это разновидность RNN, специально разработанная для борьбы с проблемой затухания градиентов. LSTM используют специальные ячейки памяти и механизмы управления потоком информации, что позволяет им эффективно хранить и обрабатывать данные с долгосрочными зависимостями, что является недостижимым для классических RNN.

Ячейка LSTM состоит из трех основных компонентов:

1. Ворота забывания (от англ. Forget Gate), которые используются для управления продолжительностью памяти в ячейке, решая, какую информацию следует забыть, а какую сохранить:

$$f_t = \sigma(W_f[h_{t-1}, x_t] + b_f) \quad (10)$$

где  $f_t$  — значение ворот забывания,  $W_f$  и  $b_f$  — веса и смещения для ворот забывания.

2. Ворота ввода (от англ. Input Gate), которые определяют, какая часть новой информации должна быть сохранена в долгосрочной памяти ячейки LSTM. Они не только фильтруют входные данные, но и решают, какая информация достаточно важна для сохранения:

$$i_t = \sigma(W_i[h_{t-1}, x_t] + b_i) \quad (11)$$

$$\tilde{C}_t = \tanh(W_C[h_{t-1}, x_t] + b_C) \quad (12)$$

где  $i_t$  — значение входного ворота,  $W_i$  и  $b_i$  — веса и смещения для входного ворота,  $\tilde{C}_t$  — кандидат на обновление состояния.

3. Ворота вывода (от англ. Output Gate), которые определяют, какая информация из текущего состояния ячейки будет передана в выходной сигнал сети.

$$o_t = \sigma(W_o[h_{t-1}, x_t] + b_o) \quad (13)$$

$$h_t = o_t \cdot \tanh(C_t) \quad (14)$$

где  $o_t$  — значение выходного ворота,  $W_o$  и  $b_o$  — веса и смещения для выходного ворота,  $h_t$  — скрытое состояние на текущем шаге,  $C_t$  — обновленное состояние ячейки.

Комбинируя результаты всех трех ворот, LSTM обновляет состояние ячейки и скрытое состояние следующим образом:

1. Обновление состояния ячейки:

$$C_t = f_t \cdot C_{t-1} + i_t \cdot \tilde{C}_t \quad (15)$$

2. Обновление скрытого состояния:

$$h_t = o_t \cdot \tanh(C_t) \quad (16)$$

Архитектура ячейки LSTM представлена на рисунке 5.15.

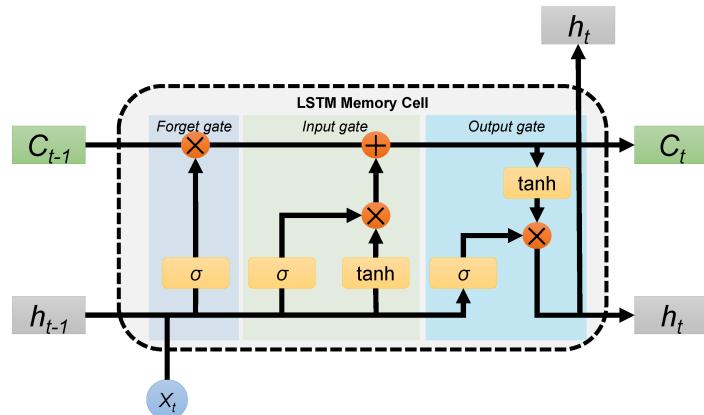


Рис. 5.15: Архитектура ячейки LSTM.

GRU — это упрощенная версия LSTM, которая объединяет забывающие и входные ворота в одно целое, что делает архитектуру менее вычислительно затратной и более простой

для реализации. В GRU отсутствует отдельная ячейка памяти, характерная для LSTM. Вместо этого, скрытое состояние обновляется напрямую. Ворота обновления позволяют модели определить, какую часть предыдущего скрытого состояния следует сохранить, комбинируя его с новой информацией.

GRU использует два основных компонента:

1. Ворота обновления (от англ. Update Gate), которые контролируют какая часть предыдущего скрытого состояния будет перенесена в текущее скрытое состояние.

$$z_t = \sigma(W_z \cdot [h_{t-1}, x_t] + b_z) \quad (17)$$

где  $z_t$  — значение обновляющего ворот,  $W_z$  и  $b_z$  — веса и смещения для обновляющего ворот.

2. Ворота сброса (от англ. Reset Gate), которые определяют какая часть предыдущего скрытого состояния будет сброшена перед вычислением нового состояния.

$$r_t = \sigma(W_r \cdot [h_{t-1}, x_t] + b_r) \quad (18)$$

где  $r_t$  — значение сбрасывающего ворот,  $W_r$  и  $b_r$  — веса и смещения для сбрасывающего ворот.

Новое скрытое состояние вычисляется с учетом текущего ввода и предыдущего скрытого состояния, модулированного сбрасывающими воротами. Формула для кандидата на новое скрытое состояние:

$$\tilde{h}_t = \tanh(W_h \cdot [r_t \odot h_{t-1}, x_t] + b_h) \quad (19)$$

где  $\tilde{h}_t$  — кандидат на новое скрытое состояние,  $\odot$  обозначает поэлементное умножение.

Итоговое скрытое состояние вычисляется как взвешенная сумма предыдущего скрытого состояния и кандидата на новое скрытое состояние, где веса задаются обновляющими воротами:

$$h_t = (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t \quad (20)$$

где  $h_t$  — новое скрытое состояние,  $z_t$  — значение обновляющих ворот.

Архитектура ячейки GRU представлена на рисунке 5.16.

Выбор между LSTM и GRU зависит от требований конкретной задачи. Если приоритетом является скорость обучения, а также ограничены вычислительные ресурсы, то GRU

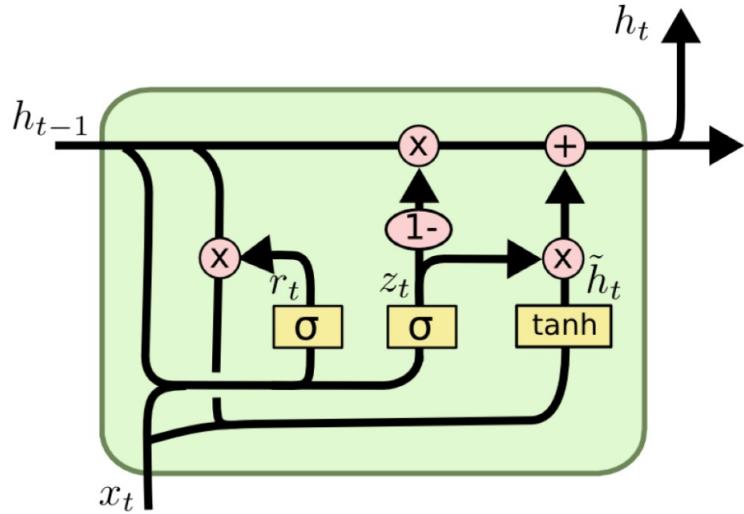


Рис. 5.16: Архитектура ячейки GRU.

может оказаться предпочтительнее из-за своей более простой структуры и меньшего количества параметров. GRU также подходит для простых задач или небольших наборов данных, так как эффективно обучается без потери производительности. Однако, для задач, требующих детального управления информацией и долгосрочной памяти, например, в сложных задачах обработки естественного языка с длинными зависимостями, LSTM может быть более подходящим благодаря своей дополнительной сложности и улучшенному контролю над информацией.

### 5.5.2 Модели генеративного предварительно обученного трансформера

Модели генеративного предварительно обученного трансформера, (англ. Generative Pre-trained Transformer, GPT) — это семейство языковых моделей на основе глубокого обучения, разработанные командой OpenAI [34], которые используют архитектуру трансформера (см. рисунок 5.17) для генерации текста, учитывая контекст и структуру предложений. Модели GPT являются мощными инструментами для генерации текста и решения разнообразных задач в области естественного языка. Их успешное функционирование основано на комбинации трансформерной архитектуры, предварительного обучения на больших объемах текстовых данных и тщательного дообучения на конкретной задаче.

Архитектура GPT имеет два основных сегмента: кодировщик, который в основном работает с входной последовательностью, и декодер, который работает с целевой последовательностью во время обучения и предсказывает следующий элемент. Кодер определяет, какие части ввода следует выделить. Затем он вычисляет матрицу встраивания (встраивание в NLP позволяет словам с похожим значением иметь одинаковое представление) и преобразует ее в серию векторов внимания. Модели GPT используют многоголовое внимание (от англ.

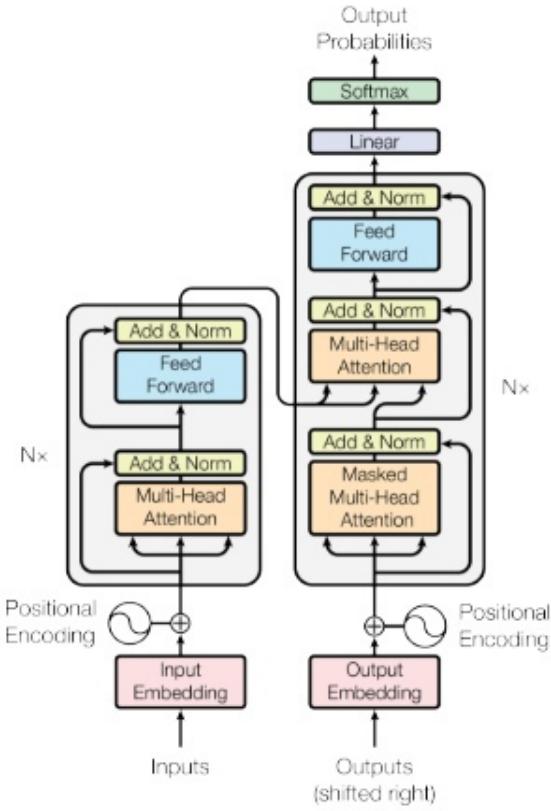


Рис. 5.17: Архитектура трансформера [44].

multi-head attention), которое создает векторы внимания, позволяя модели одновременно фокусироваться на разных частях последовательности. Это позволяет захватывать различные аспекты контекста языка. Созданные вектора внимания проходят через слой нормализации и затем передаются в полносвязный слой. Нормализация помогает стабилизировать и ускорить процесс обучения. Перед передачей в декодер снова выполняется нормализация. Во время обучения кодер работает непосредственно с целевой выходной последовательностью. Декодер вычисляет отдельные векторы встраивания для каждого слова предложения. Поскольку трансформеры не имеют встроенной последовательности обработки данных, то дополнитель-но применяется позиционный энкодер с синусоидальными и косинусоидальными функциями. Кроме того, модель GPT обучается предсказывать следующий токен в последовательности. Для этого используется механизм маскированного внимания (от англ. masked attention), который позволяет модели видеть только предшествующие токены. Во время генерации текста модель принимает на вход начальный токен или последовательность токенов и последова-тельно предсказывает следующие токены, генерируя текст по одному слову за раз. Процесс генерации продолжается до достижения определенного критерия остановки, например, та-кого как достижение максимальной длины текста или специального токена окончания.

Прежде чем приступить к выполнению конкретной задачи, модели GPT проходят

через фазу предварительного обучения на больших корпусах текстовых данных. Во время предварительного обучения модель учится «понимать» структуру и смысл текста, а также создавать внутреннее представление о языке. После предварительного обучения модель может быть дообучена или донастроена на конкретной задаче, что улучшает ее производительность и качество результатов.

На данный момент существует несколько версий GPT, каждая из которых приносит свои улучшения и оптимизации:

1. GPT-1 — первая модель из семейства GPT, которая содержит 117 миллионов параметров [34]. Сложность обучения GPT-1 варьируется в зависимости от доступных вычислительных ресурсов и объема данных для обучения, но в то же время остается доступной для исследователей и специалистов благодаря наличию предобученных моделей.
2. GPT-2 содержит 1.5 миллиарда параметров. Обучение GPT-2 требует больших объемов данных и вычислительных ресурсов, что делает его более сложным в обучении, чем GPT-1 [35]. Для многих исследовательских групп доступ к достаточным ресурсам может быть препятствием для обучения GPT-2, хотя предобученные модели могут быть доступны для использования.
3. GPT-3 содержит 175 миллиардов параметров [3]. Обучение GPT-3 требует огромных вычислительных ресурсов и больших объемов данных, что делает его крайне сложным в обучении. Для большинства исследовательских групп доступ к таким ресурсам может быть недостижимым. Кроме того, обучение GPT-3 может требовать значительных финансовых затрат на инфраструктуру и вычислительные ресурсы.
4. GPT-4 — мультимодальная большая языковая модель, которая способна обрабатывать запросы в виде картинок и текста, а затем выдавать текстовые ответы. В качестве трансформера GPT-4 была предварительно обучена прогнозировать следующий токен (используя как общедоступные данные, так и «данные, лицензированные сторонними поставщиками»), а затем была доработана с помощью обучения с подкреплением на основе отзывов людей [27]. В техническом отчете GPT-4 явно воздерживаются от указания размера модели, ссылаясь на «конкурентную среду и последствия для безопасности крупномасштабных моделей», но согласно оценки разных источников GPT-4 имеет около 1.76 триллиона параметров [26].

Для обучения любой модели GPT требуется тщательное планирование и анализ с целью определения оптимальных методов и ресурсов. Это включает выбор подходящего объема

данных для обучения, оптимизацию гиперпараметров модели, выбор архитектуры и распределение вычислительных ресурсов. Обучение моделей GPT может быть довольно сложным, но при правильном планировании и наличии необходимых ресурсов эти сложности возможно преодолеть.

## 5.6 Генерация предсказаний в задаче создания подписей к изображениям

Принцип генерации описания к изображениям в задаче image captioning ничем не отличается от стандартных схем генераций теста. Поэтому сначала будут описаны базовые принципы методов генерации текста, затем будет произведено более детальное сравнение достоинств и недостатков конкретных способов генерации, реализованных впоследствии в данной работе.

### 5.6.1 Схема генерации текста

Генерация текста с использованием авторегрессивного декодера (от. англ autoregressive decoder) — это процесс, при котором модель предсказывает следующий токен последовательности на основе предыдущих токенов, один за другим. Этот процесс является основой многих современных языковых моделей, например, таких как GPT (Generative Pre-trained Transformer).

Процесс генерации текста можно разделить на следующие этапы:

1. Инициализация. Процесс генерации текста начинается с подачи специального начального токена <BOS> (от англ. beginning of sentence), обозначающего начало последовательности. Этот токен инициирует первый шаг предсказания.
2. Преобразование токенов в эмбеддинги. Каждый токен преобразуется в вектор фиксированной длины, называемый эмбеддингом. Эти эмбеддинги представляют токены в числовом формате и позволяют модели работать с текстом.
3. Прогнозирование следующего токена. Для каждого токена в последовательности модель предсказывает следующий токен. На выходе декодера модель выдает логиты — числовые значения, представляющие оценки вероятностей для всех возможных следующих токенов. Логиты проходят через линейный слой с числом нейронов, равным числу слов в словаре. Логиты преобразуются в вероятности с помощью softmax-функции, которая нормализует логиты так, чтобы их сумма равнялась 1, что позволяет интерпрети-

ровать их как вероятности. На основе полученных вероятностей выбирается следующий токен. Существует несколько стратегий выбора:

- Жадный поиск (от англ. Greedy Search) — выбирается токен с наибольшей вероятностью.
  - Температурная выборка (от англ. Temperature Sampling) — распределение вероятностей изменяется с использованием параметра температуры перед выбором токена.
  - Категориальная выборка (от англ. Categorical Sampling) — токен выбирается случайным образом пропорционально его вероятности, т.е. токен с большей вероятностью имеет больше шансов быть выбранным, но даже токены с меньшей вероятностью имеют ненулевые шансы. Это обеспечивает более естественное разнообразие без дополнительной настройки параметров.
  - Топ- $k$  выборка (от англ. Top- $k$  Sampling) — рассматриваются только  $k$  наиболее вероятных токенов, из которых случайным образом выбирается следующий токен.
  - Топ- $p$  выборка (от англ. Nucleus Sampling) — рассматриваются токены, сумма вероятностей которых не превышает порога  $p$ .
  - Поиск с лучевым прогоном (от англ. Beam Search) — вместо выбора одного наиболее вероятного токена на каждом шаге, beam search рассматривает несколько наиболее вероятных путей генерации (называемых "beams") и выбирает наиболее вероятные последовательности токенов. Beam search поддерживает фиксированное количество путей (beams) и на каждом шаге продолжает их генерацию, выбирая наиболее вероятные продолжения для каждого пути. В конце выбирается наиболее вероятная из всех возможных последовательностей.
4. Обновление последовательности. Выбранный токен добавляется к текущей последовательности. Вектор этого токена передаётся на вход следующей ячейки декодера, и процесс повторяется.
  5. Процесс генерации продолжается до тех пор, пока не будет сгенерирован токен  $\langle \text{EOS} \rangle$  (от. англ end of sentence), обозначающий конец последовательности.

### 5.6.2 Описание популярных подходов

При обучении модели чаще всего используется кросс-энтропийная функция потерь для сравнения сгенерированных описаний с эталонными в обучающем наборе данных. Дру-

гими словами, к генерации описаний к изображениям относятся как к классификации, где на каждом шаге определяется «правильное слово», которое должно стоять на данном месте.

Как было описано ранее, существуют разные способы декодирования последовательности. Наиболее часто встречаются взятие наиболее вероятного слова (жадный поиск), сэмплирование слова из категориального распределения с вероятностями, полученными из модели на данном этапе генерации, и лучевой поиск (англ. beam search). Рассмотрим достоинства и недостатки каждого из них.

Жадный поиск удобен своей простотой и вычислительной эффективности. Поскольку он отслеживает только одну наиболее вероятную последовательность, он требует меньше памяти и вычислений по сравнению с более сложными методами декодирования. Однако он имеет несколько ключевых недостатков. Одним из недостатков является то факт, что жадный поиск ищет лучший вариант непосредственно на каждом этапе и не учитывает долгосрочные последствия своего выбора. Другим недостатком выступает наложение принципов жадного поиска и особенностей архитектуры рекуррентных нейронных сетей, что приводит к неудачным генерациям, поскольку данные модели склонны присваивать наибольшую вероятность слову, которые было сгенерировано на предыдущем шаге. Скорее всего это будет приводить к генерации безопасных, повторяющихся и зачастую скучных результатов, основанных на общих фразах, чаще всего встречающихся в данных, и максимального избегания менее распространенных, но потенциально более интересных вариантов.

Замена жадного отбора слов на сэмплирование из категориального распределения может решить проблему одинаковых, повторяющихся конструкций и слов, однако это не решает проблему локального принятия решений.

Лучевой поиск является более сложным методом декодирования, который отслеживает несколько потенциальных последовательностей на каждом этапе. Принцип его построения заключается в следующем: заранее выбирается величина под название «ширина лучевого поиска» (от англ. beam width), отражающая сколько наиболее вероятных последовательностей будет храниться на каждом шаге генерации. Для каждой из хранимых последовательностей выбирается beam width наиболее вероятных вариантов последующего слова, из которых в свою очередь оставляется beam width наиболее вероятных последовательностей. Данная процедура повторяется на каждом шаге генерации пока не будет сгенерирован символ окончания последовательности или не достигнута максимальная допустимая длина последовательности. Поскольку лучевой поиск рассматривает несколько последовательностей, это делает его более гибким и увеличивает шансы найти лучшую общую последовательность. Отслеживая несколько перспективных последовательностей, он может избежать «застrevания» в менее

вероятных последовательностях из-за локально оптимального выбора. Однако лучевой поиск требует больше вычислительных ресурсов, чем жадный поиск, так как на каждом этапе необходимо поддерживать и рассчитывать вероятности для  $beam_{width}^2$  последовательностей. Более того нет гарантий нахождения наиболее вероятной последовательности, особенно при небольшой ширине луча по сравнению с размером словаря.

На рисунке 5.18 представлен пример декодирования последовательности с помощью жадного отбора и лучевого поиска.

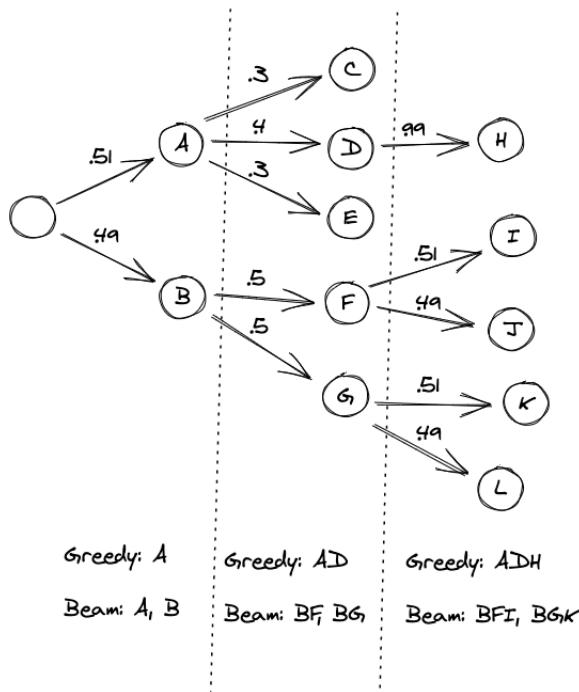


Рис. 5.18: Принцип получения предсказания посредством жадного поиска и лучевого поиска. [<https://vitalflux.com/greedy-search-vs-beam-search-decoding-concepts-examples/>].

## 5.7 Метрики качества в задаче создания подписей к изображениям

Оценить качество сгенерированного текста представляется более сложной задачей нежели оценка качества классификации. Основная часть метрик основана на сравнении полученного текста с его неким эталоном, золотым стандартом. В задаче создания подписей к изображениям эталонным текстом при обучении выступают заранее созданные человеком описания.

Наиболее точной оценкой сгенерированного текста является экспертная оценка, позволяющая учесть все нюансы полученного описания. Оценивание производится по 5-тибальной шкале. Однако она является дорогой, медленной и трудоемкой, поскольку требует при расчете участие человека.

Для автоматической оценки работы сгенерированных текстов зачастую используются такие показатели как BLEU, WER, NIST, ROUGE, METEOR, TER и прочие. Рассмотрим подробнее первые две из них.

Метрика BLEU (Bilingual Evaluation Understudy) на данный момент является одной из самых популярных. Она позволяет учитывать не только точность перевода отдельных слов, но и цепочек слов (N-граммы). Как правило расчет происходит до 4-грамм. Алгоритм BLEU оценивает качество перевода по шкале от 0 до 100 на основании сравнения машинного перевода с золотым стандартом и поиска общих слов и фраз. Основная идея метрики состоит в том, что чем лучше сгенерированный текст, тем больше он должен быть похож на эталонный. Лучше всего такая метрика работает на уровне большого текста, а не на уровне предложений. На маленьком объёме текста метрика зачастую обнуляется из-за отсутствия совпадающих 4-грамм и работает некорректно. Существуют также доработанные варианты метрики, которые подходят для сравнения на уровне предложения.

Word Error Rate (в сокращении WER), или взвешенное расстояние Левенштейна, позволяет измерять расстояние между сгенерированным текстом и эталонным. По сути, WER измеряет минимальное количество операций (замена, удаление, добавление слова), которые необходимо сделать, чтобы из сгенерированного моделью текста получить золотой стандарт (см. формулу 21).

$$WER = \frac{\#substitutions + \#deletions + \#insertions}{caption - output - length} \quad (21)$$

Данные метрики являются простыми и быстрыми оценками качества сгенерированных текстов, коррелирующих с экспертной оценкой. Однако они оперируют только короткими фрагментами, не позволяя оценить общую корректность предложения. Их сложно сравнивать между собой, поскольку оценки носят относительный характер. Также с помощью них невозможно оценить жанровую специфику текста. Еще одним их недостатком является их не дифференцируемость, не позволяющая их использовать в качестве функции потерь, то есть оптимизировать напрямую.

## 5.8 Вывод

Проведя анализ текущих подходов к решению задач многоклассовой классификации и создания подписей к изображениям, было решено остановиться на архитектуре «Encoder-Decoder», где данные части будут представлены нейронными сетями. Однако в нее было внесено одно существенное изменение – разделение блока «Encoder» и «Decoder» и обучение

их по отдельности. Обучение «Encoder» происходило на задачу классификации, «Decoder» - на задачу генерации описаний (см. рисунок 5.19).

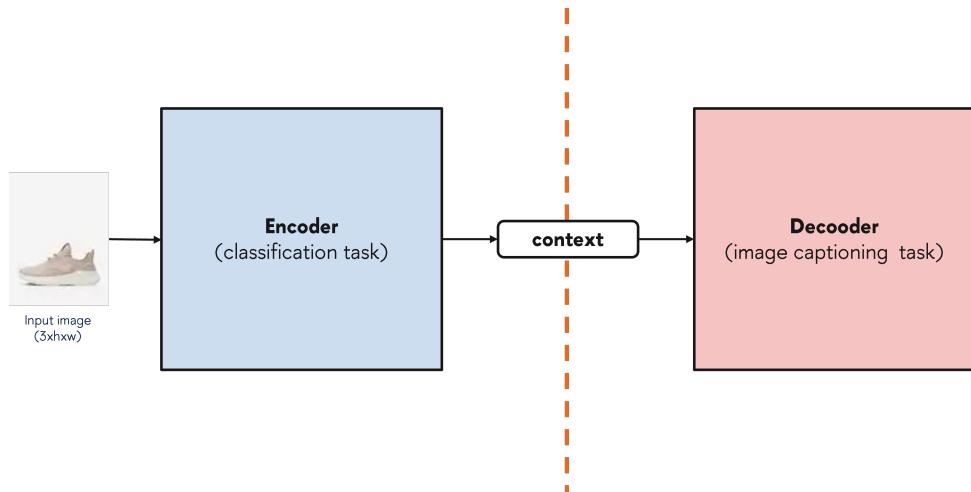


Рис. 5.19: Общая схема архитектуры модели.

Таким образом, следующей задачей стала проверка работоспособности данной схемы в целом. Вследствие было принято решение пойти снизу вверх, от простого к сложному, с постепенным усложнением архитектуры. Другим фактором, повлиявшим на решение начать реализацию с архитектуры CNN + RNN, а не сразу переходить на модели на основе трансформеров, стал факт неоднозначности выбора в пользу того или другого подхода. В классификационных моделях сверточные нейронные сети до сих пор остаются конкурентоспособными. Для достижения качества классификации, сравнимого со сверточными моделями, ViTs требуют значительного объема данных для обучения, значительных вычислительных ресурсов и много дополнительных действий для достижения удовлетворяющего качества классификации. В то время как сверточные нейронные сети « заводятся из коробки», и при минимальных действиях возможно получение высокого качества. В задаче генерации описаний неоспоримым доминатом по качеству создаваемых текстов являются модели трансформеров. Однако, как упоминалось в разделе 5.4, это очень «тяжелые» модели, требующие больших вычислительных мощностей. Рекуррентные нейронные сети, хотя уступают им по качеству генераций, являются легковесными, что может сыграть решающую роль при необходимости запуска разрабатываемого приложения на малых мощностях, и более быстрыми в выдаче предсказаний, что следует принимать во внимание при важности фактора времени, которое будет затрачено на получение предсказания.

Дальнейшим этапом работы стала реализация базовых CNN в качестве кодировщика и RNN в качестве декодировщика с их последующим усложнением, таким как разработка концептуально новых решений, позволяющих повысить качество классификации с учетом

особенностей используемых данных, использование нескольких последовательных и параллельных блоков RNN, а также добавление механизма внимания, применяя разные способы его реализации. При успешном исходе для повышения качества генерации будет выполнен переход блоков энкодера и декодера на модели трансформеров.

## 6 Эксперименты

### 6.1 Общие принципы обучения

В данном разделе будет детальное описание способов, методов и приемов реализации модели. Для лучшего понимания обратимся к ключевой идеи данной работы: должна быть разработана модель, которая по присланной фотографии товара определяет к какой категории изображенный объект лучше отнести и генерирует к нему описание. Таким образом, одновременно должны решаться задача классификации и задача генерации текстового описания по изображению. Как было описано в теоретических основах (см. раздел 5.8), поставленная задача будет решаться с использованием архитектуры «Encoder-Decoder», где, из-за потребности решения одновременно двух задачи, обучение блоков «Encoder» и «Decoder» происходит по отдельности: обучение «Encoder» происходило на задачу классификации, «Decoder» - на задачу генерации описания (см. рисунок 5.19). Другими введенными ограничениями являлось использование свёрточных нейронных сетей в качестве кодировщика и рекуррентных сетей в качестве декодировщика.

Опишем принцип построения разработанной схемы (см. рисунок 6.1). Входными данными выступает фотография товара, которая подается в «encoder». Кодировщик состоит из backbone, инициализированный предобученными весами на ImageNet и частично замороженным (см. раздел 6.2), и двух линейных слоев, соединенных функцией активации. Первый линейный слой отвечает за формирование эмбединга для изображения, который впоследствии будет подан в «decoder», второй – непосредственно за классификацию. После получения предсказания классификатора, сформированный эмбединг подается в качестве контекста декодировщику, который производит генерацию текста. Размер эмбединга изображения был выбран эксперты путем и равнялся 1024.

Необходимо отметить, что поскольку эмбединги изображения формируются в кодировщике, обучающемся только на задачу классификации, их формирование может происходить не оптимально для задачи генерации текста, что может отразиться на качестве полученных описаний.

Для справедливости стоит отметить, что подобная схема<sup>3</sup> была подобрана посредством экспериментов и исходя из требований, налагающихся на нее выдвинутыми ранее ограничениями. Во-первых, в кодировщике необходим линейный слой, отличный от классификационного, для получения эмбединга изображения. Во-вторых, для реализации в RNN

---

<sup>3</sup>В частности, схема кодировщика.

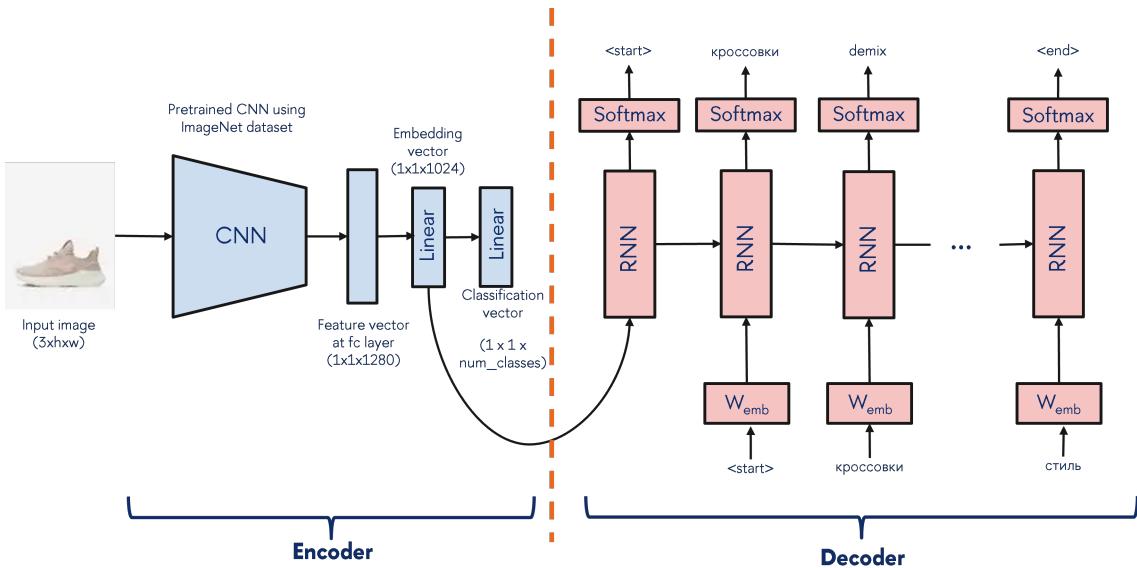


Рис. 6.1: Архитектура реализуемой модели.

второго из видов внимания, описанного на странице 42, требовались отдельные эксперименты с использованием в качестве контекста для RNN трехмерных представлений изображения, доставаемых из более ранних слоев предобученной CNN.

В экспериментах тестировались разные размеры embedding vector<sup>4</sup>, функции активации между слоями, варианты dropout и batch-нормализации, добавление большего числа линейных слоев в голове. Была опробована схема, изображенная на рисунке ?? с параллельным обучением двух эмбедингов и последующей их конкатенации, также имели место варианты с использованием в качестве контекста для RNN эмбединга из «feature vector at fc layer» или из более ранних слоев. Однако, все вышеперечисленные эксперименты прове-

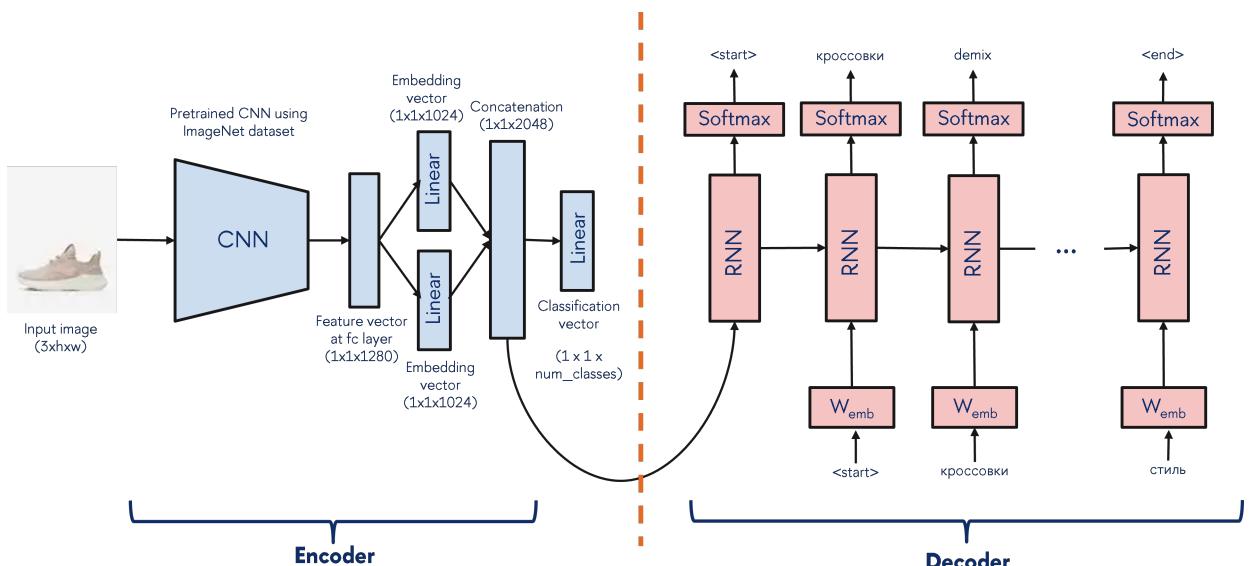


Рис. 6.2: Альтернативная архитектура модели.

<sup>4</sup>Все обозначения берутся согласно схеме 6.1.

рялись посредством качества классификации и однозначно предугадать влияние того или иного варианта на качества генерации описания к изображениям нельзя. Наиболее важным и самым сложным в тестировании качества выступал размер embedding vector<sup>5</sup>.

## 6.2 Решение задачи классификации

Первым шагом в решении задачи классификации было обучение единой модели для всех конечных категорий<sup>6</sup> (см. рисунок 6.3).

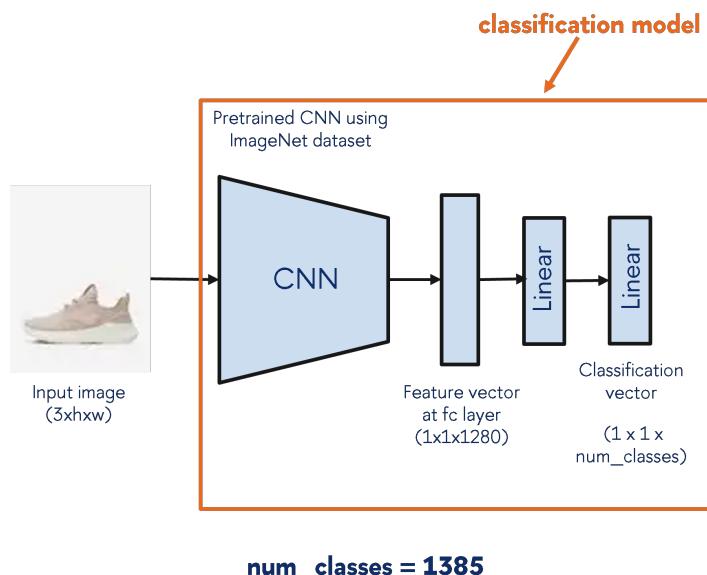


Рис. 6.3: Архитектура единой классификационной модели для всех классов.

Данный вариант имел ряд серьезных недостатков, из-за которых впоследствии было решено от него отказаться:

- Во-первых, для качественного обучения классификационной модели с большим количеством категорий требуется довольно много примеров, чтобы модель смогла выявить особенности каждого класса. Это объясняется тем, что вероятностная масса размывается на большое количество классов, что делает модель менее устойчивой. В рамках данного проекта в каждой категории имелось в распоряжении около 20 объектов, что было явно недостаточно. Более того, данные являются достаточно шумными, усугубляя общую картину. Следствием этого выступило низкое качество классификатора, не удовлетворяющее минимальные требования (см. таблицу 6.1).

<sup>5</sup> Данное утверждение становится понятным, принимая во внимание финальный выбор архитектуры кодировщика, более детально описанный в разделе 6.2

<sup>6</sup> После очистки данных осталось 1385 конечных категорий.

Таблица 6.1: Метрики качества модели, обученной на все конечные категории.

metric	value
accuracy	0.4708
accuracy@top2	0.6154
precision macro	0.4768
recall macro	0.4644
f1 macro	0.4466
precision micro	0.4708
recall micro	0.4708
f1 micro	0.4708
precision weighted	0.4824
recall weighted	0.4708
f1 weighted	0.4526

- Во-вторых, из-за больших размеров модели время обучения даже на текущем датасете было очень велико, что затрудняло подбор оптимальный гиперпараметров. Следствием из этого будет выступать такое же неудовлетворительное по длительности время последующего дообучения/переобучения модели на новых данных.
- В-третьих, поскольку конечная матрица имеет внушительные размеры, время получения предсказаний также оставляло желать лучшего. (ЗАМЕРИТЬ ВРЕМЯ ИНФЕРЕНСА)

Решением указанных недостатков стало получение предсказания посредством дерева моделей. Будем называть архитектуру модели, изображенной на рисунке 1, classification model. Тогда принцип архитектуры дерева моделей будет выглядеть следующим образом: см. рисунок 6.4. За ранее обучается n классификаторов по количеству материнских категорий, каждый из которых обучен на классы, соответствующие данным материнским категориям. Для получения предсказания входное изображение сперва подается в классификационную модель, обученную на классы первой вложенности. Далее в зависимости от предсказанной категории, полученной из данной модели, и при условии, что категория является материнской, картинка передается на вход следующему классификатору, обученному на подкатегории выбранной материнской категории. Данная процедура продолжается до тех пор, пока предсказание какого-либо из классификаторов не окажется конечной категорией.

Поясним подробнее процедуру формирование классов для моделей на примере категории «Канцтовары». Основная идея заключается в объединении всех нижележащих подкатегорий в материнскую категорию. Таблицы 6.2 и 6.3 показывают, как конечные категории раздела «Канцтовары» преобразовывались в классы для моделей второй и третьей вложенности соответственно. Структура сохранения данных при сборе была продумана таким образом, чтобы формирование классов для дерева моделей происходило максимально удобным

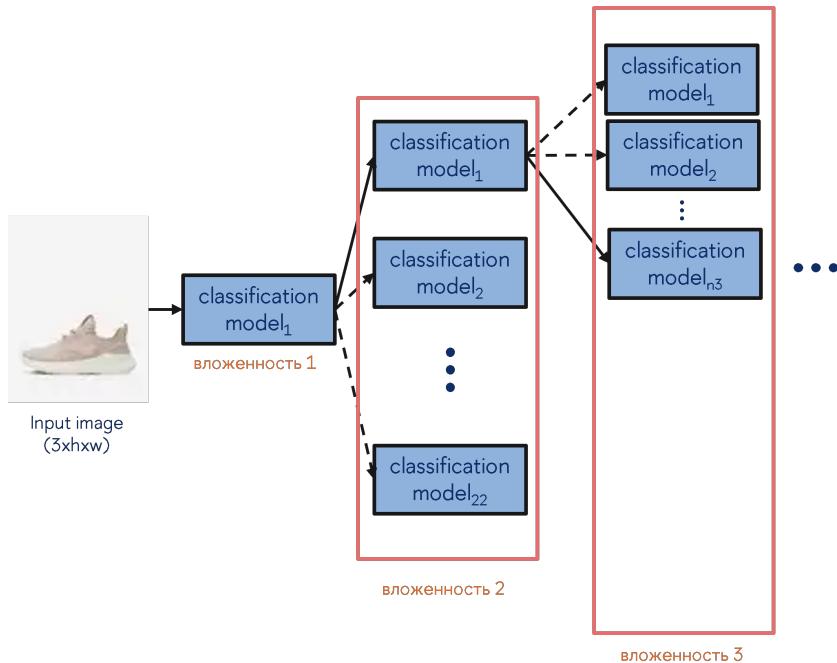


Рис. 6.4: Архитектура дерева классификационных моделей.

образом. Ключевая идея состояла в составлении названия папок, содержащих данные по одной конечной категории, таким образом, чтобы при необходимости можно было с легкостью проследить путь, ведущий от категорий первой вложенности к конкретной конечной категории.

Таблица 6.2: Преобразование классов для модели "Канцтовары" (вторая вложенность), фрагмент.

название папки	класс
Канцтовары_Анатомические&модели	Анатомические&модели
Канцтовары_Бумажная&продукция_Блокноты	Бумажная&продукция
Канцтовары_Бумажная&продукция_Гостевые&книги	Бумажная&продукция
Канцтовары_Бумажная&продукция_Дневники	Бумажная&продукция
Канцтовары_Бумажная&продукция_Закладки	Бумажная&продукция
Канцтовары_Бумажная&продукция_Наклейки	Бумажная&продукция
Канцтовары_Карты&и&глобусы	Карты&и&глобусы
Канцтовары_Письменные&принадлежности	Письменные&принадлежности
Канцтовары_Рисование&и&лепка	Рисование&и&лепка
Канцтовары_Чертежные&принадлежности	Чертежные&принадлежности
...	...

Описанное решения на первый взгляд может показаться очень громоздким и неоправданно усложненным. Получение предсказание через дерево моделей позволяет поднять поставленное качество классификационной задачи в целом. Это объяснено тем, что задача на меньшее количество классов решается априори лучше. Другим достоинством предложенного подхода является уменьшение времени получения предсказаний, поскольку прогон через несколько небольших моделей происходит быстрее, чем через одну большую.

Таблица 6.3: Преобразование классов для модели "Канцтовары\_Бумажная&продукция"(третья вложенность), фрагмент.

название папки	класс
Канцтовары_Бумажная&продукция_Блокноты	Блокноты
Канцтовары_Бумажная&продукция_Гостевые&книги	Гостевые&книги
Канцтовары_Бумажная&продукция_Дневники	Дневники
Канцтовары_Бумажная&продукция_Закладки	Закладки
Канцтовары_Бумажная&продукция_Наклейки	Наклейки
...	...

С переходом на подобную модель классификации возникает вопрос ее адаптации к задаче image captioning. Появление нескольких классификаторов поднимает вопрос получения эмбединга изображения для декодировщика, что может решаться несколькими способами. Например, можно брать эмбединг изображения с самой глубокой модели, то есть той модели, которая предсказала конечную категорию. Другим вариантом является конкатенация эмбедингов, полученных из моделей, принявших участие при получении предсказания. Также можно вместо конкатенации применить взвешивание данных эмбедингов с определенными весами. В работе был использован первый вариант, несмотря на очевидный его недостаток – при получении эмбединга изображения из глубоких классификаторов появляется риск забывания моделью важных общих характеристик объекта (например, чем дамская сумочка отличается от рюкзака) и фокус на мелких деталях (например, как дамскую сумку от фирмы Gucci отличить от сумки фирмы Chanel). Другие упомянутые варианты отпали по причине разного количества моделей, участвующих при получении того или иного предсказания. В этом случае необходимо было разрабатывать дополнительные специфичные приемы, позволяющие получить одинаковый размер финального эмбединга изображения.

После принятия решения об использовании для декодировщика эмбедингов, полученных из самой глубокой модели возникает следующая проблема, требующая решения: как избежать ситуации, когда полученные из разных моделей эмбединги изображения и, соответственно, означающие разные классы, будут численно одинаковыми. Решение данной проблемы стала заморозка большинства слоев backbone и получение эмбедингов из более-менее одного смыслового пространства, что уменьшает вероятность возникновения подобных ситуаций. При проведении экспериментов наиболее оптимальным уровнем размораживания backbone стала разморозка двух последних слоев<sup>7</sup>. Это позволяло поднять качество классификаций на 5-10 процентных пунктов. С другой стороны, подобная заморозка уменьшает время обучения и последующих дообучений модели, потому что происходит обучение только

<sup>7</sup> В частности, последний блок MBConv и блок активации Conv2dNormActivation.

линейной головы классификатора. Кроме того, уменьшается размер необходимого дискового пространства, необходимого для хранения весов классификаторов, поскольку необходимым становится только хранение весов для размороженных слоев и линейных голов моделей. Также стоит отметить значительное облегчение процесса переобучения и дообучения классификаторов, так как архитектура дерева моделей не требует единовременного переобучения всех моделей и классов. Другими словами, переобучение может затрагивать только необходимые модели, никак не касаясь других классификаторов. Таким образом, поддержания в актуальном состоянии большого количества классификационных моделей не будет являться проблематичным. Еще одним достоинством применения замораживания основной части backbone является уменьшение времени, необходимое на получение предсказания, по сравнению с полностью размороженной моделью. Аргументировано это тем, что при передаче изображения между моделями в дереве будет происходить только переинициализация весов головы моделей.

Следующей досадной неприятностью при переходе на архитектуру получения предсказания посредством дерева моделей может стать количество классификаторов, необходимых к обучению. Данная цифра напрямую зависит от структуры каталога и детализированности категорий выбранного маркетплейса. Как было упомянуто в разделе 4.1, максимально было до пяти уровней вложенности. Другими словами, максимальная глубина дерева моделей – 5. Однако кроме глубины дерева важную роль играет его ширина. В таблице 6.4 представлено количество моделей, которое должно быть обучено в зависимости от выбранной глубины вложенности.

Таблица 6.4: Количество моделей, необходимые к обучению в зависимости от уровня вложенности.

кол-во моделей	уровень вложенности
171	вложенность 5
165	вложенность 4
153	вложенность 3
22	вложенность 2
1	вложенность 1

Можно заметить, что значительная детализация категорий происходит на третьем уровне вложенности. Принимая во внимание цели данной работы, которые заключаются в том числе в проверке работоспособности предложенной архитектуры в целом, было решено остановиться на втором уровне вложенности. Таким образом, происходило обучение 22 классификационных модели. В таблице 6.5 представлена статистика по размерам датасетов, на которых были обучены модели классификации. Согласно пятидесятыму квантилю, ровно в

половине моделей количество данных не превышало 1000. Однако (см. также 4.4) нельзя не обратить внимания на большой размах в размере категорий: какие-то модели были обучены на 5000 примерах, какие-то только на 300.

Таблица 6.5: Описательная статистика по размерам датасетов для моделей в дереве классификаций (слева - по второй вложенности, справа - по всем моделям).

dataset size		dataset size	
count	20	count	20
mean	1283.75	mean	1283.75
std	1226.88	std	1226.88
min	264.00	min	264.00
25%	484.00	25%	484.00
50%	954.50	50%	954.50
75%	1660.25	75%	1660.25
max	5720.00	max	5720.00

В обоих подходах при проведении экспериментов в качестве сверточных нейронных сетей брались MobileNetV2 из-за своей компактности и быстроте, а также семейство моделей EfficientNetV2 из-за их высокого качества практически на всех стандартных наборах данных. Финальной моделью была выбрана EfficientNetV2-S, сочетающая в себе оптимальный баланс качества классификаций и затрат на время обучения.

Другими используемыми приемами при обучении классификаторов было добавление аугментаций. При обучении всех моделей использовались аугментации, смешивающие разные изображения (в частности MixUp и CutMix[36]). Использование настолько сильных аугментаций являлось необходимым в связи сильным переобучение моделей под обучающий набор данных, который был вызван отчасти их небольшим размером. Другие виды аугментаций подбирались при оптимизации модели и составляли индивидуальный набор для каждого классификатора. В качестве оптимизатора лучше всего себя показал AdamW<sup>8</sup> (адаптивный градиентный шаг с использованием momentum и weight decay). Также часть классификаторов потребовала использование шедуллера (англ. scheduler) для изменения градиентного шага (англ. learning rate). В основном использовался CosineAnnealingLR<sup>9</sup>. В качестве функции потерь использовался CrossEntropyLoss<sup>10</sup> с применением техники label smoothing.

### 6.2.1 Х3 КАК НАЗВАТЬ4 (Результаты классификации ?)

Как было описано в разделе 5.3, для каждой модели рассчитывались такие метрики как accuracy, precision, recall, f1 мера с использованием макроусреднения. Также строились

<sup>8</sup><https://pytorch.org/docs/stable/generated/torch.optim.AdamW.html>

<sup>9</sup>[https://pytorch.org/docs/stable/generated/torch.optim.lr\\_scheduler.CosineAnnealingLR.html](https://pytorch.org/docs/stable/generated/torch.optim.lr_scheduler.CosineAnnealingLR.html)

<sup>10</sup><https://pytorch.org/docs/stable/generated/torch.nn.CrossEntropyLoss.html>

матрица ошибок и classification\_report<sup>11</sup>. Из интегральных метрик производилось построение ROC и PR кривых с расчетом AUC и Average Precision как для каждого класса в отдельности, так и с использование микро- и макроусреднения.

Схема расчета метрик была усложнена тем фактом, что понимания качества одной классификационной модели недостаточно для понимания всей классификации в целом. Для этой цели был написан ряд функций, позволяющий рассчитать данные показатели, объединенные по всем моделям, с использованием идей микро- и макроусреднения, а также их комбинации микро-макроусреднения.

Вариант с применением принципов макроусреднения (более точнее можно охарактеризовать как макро-макро усреднение) состоял из расчета необходимых показателей (для PR-curve рассчитывались precision и recall, для ROC-curve – FPR и TPR) для каждой из 22 моделей по схеме, описанной в разделе 5.3, для всех необходимых порогов отсечения. Затем полученные значения для каждого порога усреднялись с одинаковыми весами. В случае микроусреднения (более точное название микро-микро усреднение) для каждой модели для всех необходимых порогов рассчитывались элементы матрицы ошибок по алгоритму, описанному в разделе 5.3. Далее по каждому порогу происходило их усреднение, и на основании полученных общих характеристик TP, FP, TN, FN производились расчеты precision и recall в случае PR-curve и FPR и TPR в случае ROC-curve. Вариант расчета микро-макро усреднения производился по принципу: для каждой модели считаются метрики посредством микроусреднения, объединение метрик по всем моделям происходит через макроусреднение. Для каждой модели в отдельности по принципу микроусреднения (см. раздел 5.3) для всех требуемых порогов рассчитывались значения precision, recall для PR-curve и FPR, TPR для ROC-curve, которые впоследствии усреднялись по вероятностным порогам с одинаковыми весами. По аналогичным схемам производился расчет Average Precision и AUC.

На рисунке 6.5 представлены общие для всей модели классификации PR-кривые, полученные посредством вышеописанных методов. Рисунок 6.6 содержит ROC-кривые.

На желтой PR-кривой, рассчитанной по принципам макроусреднения, можно заметить резкое падение значения precision в самом начале, что соответствует наиболее высоким порогам отсечения. Точно такое же проседание качества можно отметить и на двух других кривых (резкое падение оранжевой и красной кривых в левом верхнем углу), однако менее выраженное. Попробуем объяснить данное явление.

Для этого необходимо понимание значений верхних квантилей порогов отсечения, при-

---

<sup>11</sup>[https://scikit-learn.org/stable/modules/generated/sklearn.metrics.classification\\_report.html](https://scikit-learn.org/stable/modules/generated/sklearn.metrics.classification_report.html)

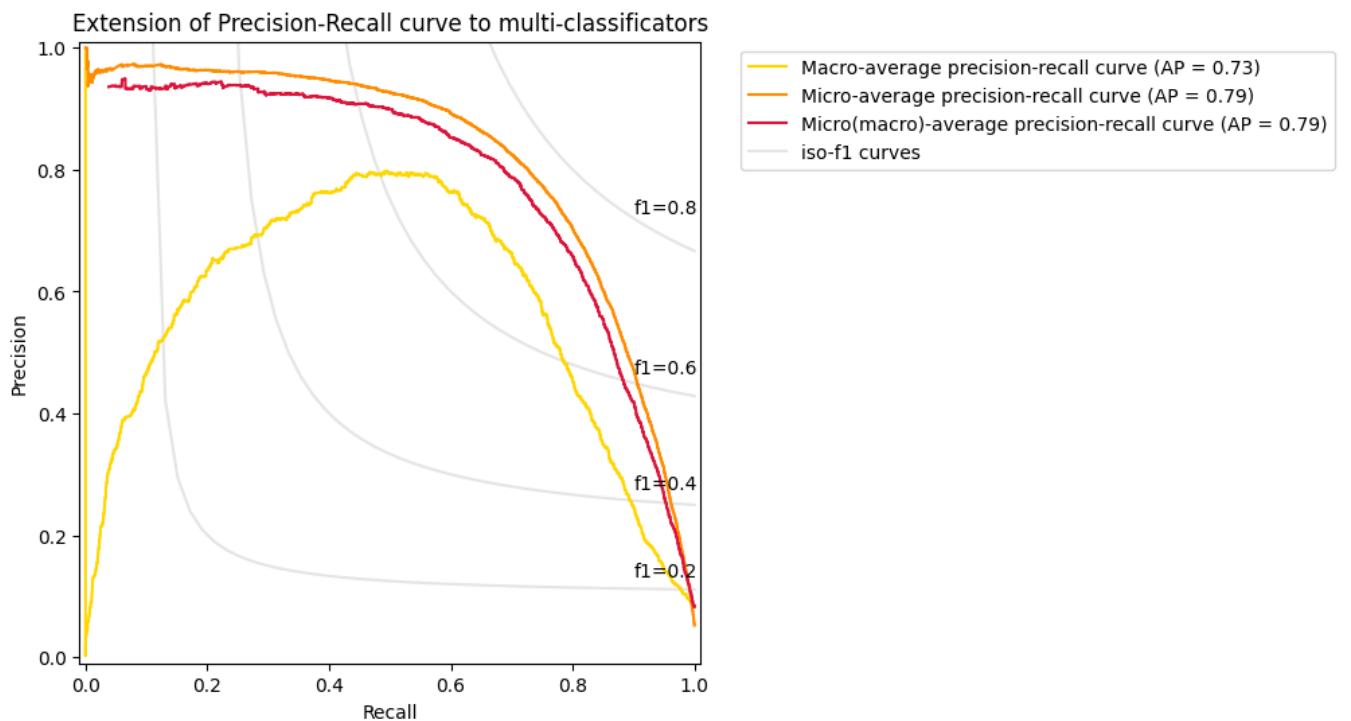


Рис. 6.5: PR-curves, объединенная по всем классификационным моделям .

нявших участие в построении PR-кривых (см. таблицу 6.6, а также распределение плотности точек на PR кривых. Легко заметить, что в 97% случаях вероятности предсказаний, полученные из модели, не превышают 0.48. Что в свою очередь уже можно считать довольно неуверенными классификациями. Например, модель может предсказать, что объект с вероятностью 45% относится к классу 1 и с вероятностью 44% относится к классу 2. Поскольку разница в уверенностях невелика, отсюда резкое снижение true positive объектов и рост false positive объектов и вытекающее из этого понижение метрики precision. Касательно распределения плотности точек на разных частях графика, при помощи анализа было выявлено, что значение показателя recall, равное 0.5, соотносится с 37% порогом отсечения, а recall, равный 0.2 соответствует 65% порогу. Таким образом, правая часть графика содержит в себе несоразмерно больше точек по сравнению с левой.

Из всего вышеперечисленного можно сделать предположение, что в большинстве классификаторов присутствуют классы, которые моделям трудно отличать от других и в которых они не очень уверены (уверенность в 40-70% нельзя назвать сильной). Это приводит к тому, что при определенном уменьшении порога резко возникает много false positive объектов, что приводит к падению precision. Данный вывод подтверждается еще и тем фактом, что падение значения precision при макроусреднении сильное, а последующее восстановление более долгое (левая ветвь желтой параболы) нежели при микроусреднении, поскольку вклад каждого класса в значение показателей при макроусреднении равный. В промежуточном ва-

Таблица 6.6: Верхние квантили вероятностных порогов, участвовавших в построении PR-кривых, объединенным по всем классификационным моделям.

quantile	threshold
0.90	0.089
0.91	0.102
0.92	0.119
0.93	0.145
0.94	0.183
0.95	0.244
0.96	0.342
0.97	0.484
0.98	0.634
0.99	0.760
1.00	0.980

рианте последовательного применения micro-macro усреднения (красная линия), ожидаемо, получен средний результат между желтой и оранжевой линией.

Наиболее точные классификации происходят при порогах 30-45%, соответствующим вершине параболы. В этом случае доверять классификатору можно на 80% (значение precision), однако при этом он находит только 45-60% объектов из выборки (значение recall). Обратим внимание, что данные выводы справедливы при анализе качества классификации в целом по всем моделям и могут немного отличаться в каждом индивидуальном случае.

Также стоит отметить, что ни одно из усреднений не достигает 80% F1 показателя. Однако всех кривые пересекают 60-70% iso-F1 линии. Следовательно, при принятии решения о выборе порога отсечения на финальное предсказания необходимо найти компромиссное решение, при котором будет приемлемо высокое доверие к классификатору и при этом он будет способен находить довольно много объектов положительного класса.

Как было сказано в разделе 5.3, ROC кривая при сильном дисбалансе классов склонна давать слишком оптимистичные результаты. В целом здесь заметна та же картина, что и на PR-кривых. Наилучшие показатели получаются при микроусреднении, поскольку хорошо предсказываемые классы поднимают общие показатели. Поскольку в данных имеются плохо предсказываемые классы, макропоказатели принимают более низкие значения. Вариант с объединением микро и макро подходов дает промежуточный результат. Значения AUC во всех случаях очень высокие (выше 0.9).

В таблице 6.7 представлена статистика по значениям метрик качества, достигнутых в классификационных моделях. Из значения accuracy и accuracy@top2 можно сделать вывод, что классификационное дерево работает довольно точно. В двух наиболее вероятных классов по мнению модели с очень большой вероятностью будет находиться верный. В рамках реализуемого сервиса такие показатели являются хорошим критерием будущей успешности.

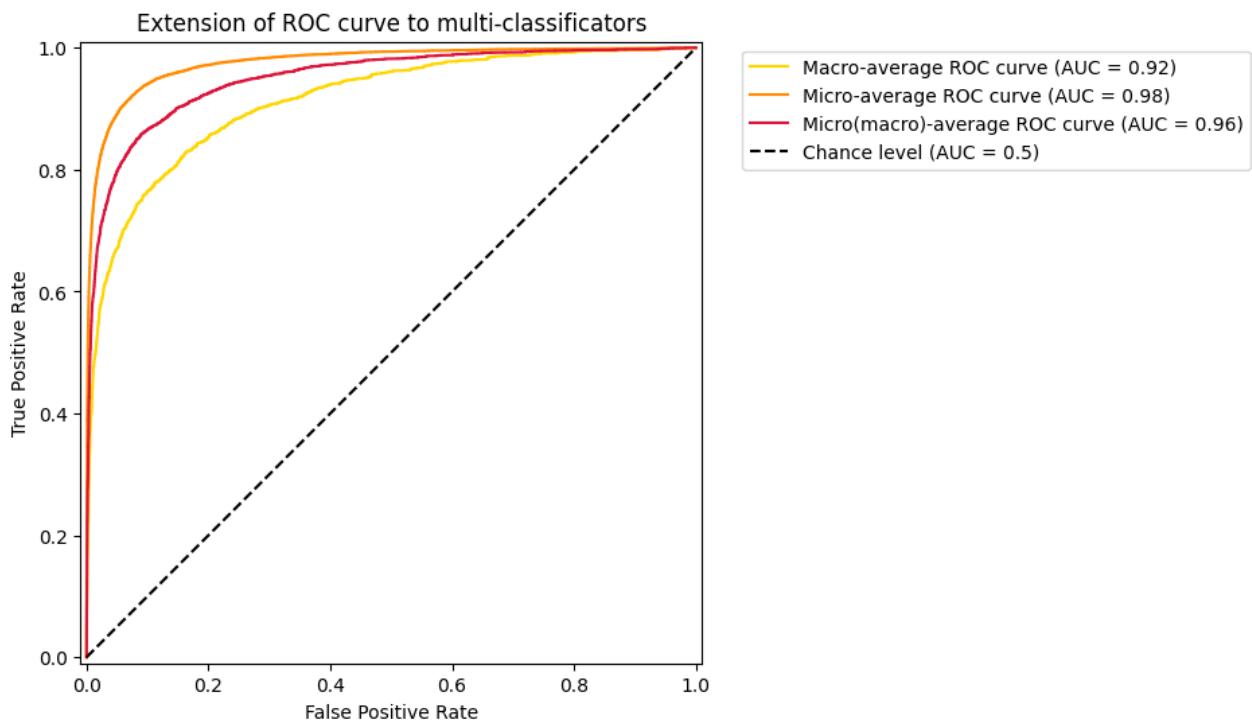


Рис. 6.6: ROC-curves, объединенная по всем классификационным моделям .

сти, поскольку при неоднозначности предсказания (например, когда классы действительно похожи по смыслу) можно задать пользователю вопрос с просьбой выбрать с его точки зрения наиболее подходящую категорию из двух предложенных. Поскольку в первую очередь происходила оптимизация метрики precision, его показатели выше, нежели значения recall. Стоит отметить, что precision имеет стабильные показатели на всех вариантах усреднения по классам (микро, макро, взвешенное). Значения recall и f1 показателя при микроусреднении и взвешенном среднем увеличиваются на 10 и 5 процентных пункта соответственно. Таким образом, в среднем по моделям доверять дереву классификаций можно на 75% при том, что оно находит около 65% объектов положительного класса в тестовой выборке.

Важным замечанием будет справедливость указанных характеристик именно для собранного набора данных. Как упоминалось в разделе 4.2, на каждую конечную категорию приходилось около 20 товаров, что, разумеется, не может охватить все разнообразие возможных товаров.

Стоит отметить значительную разницу в качестве на обучающем и тестовом наборе данных в сторону переобучения (см. таблицу 6.8), несмотря на применение всевозможных механизмов по его снижению. Решающую роль играл небольшой размер классов (на конечные категории приходилось в среднем по 15 примеров) и разделов в целом.

Для более полного понимания неоднозначностей, присутствующих в собранных данных, и построенных моделей, рассмотрим детально результаты классификатора на примере

Таблица 6.7: Описательная статистика значений метрик качества, достигнутых в классификационных моделях, на тестовом наборе данных.

	accuracy	accuracy_topk2	precision_macro	recall_macro	f1_macro	precision_micro
count	21	21	21	21	21	21
mean	0.748234	0.854424	0.750832	0.652785	0.675169	0.748234
std	0.071282	0.046749	0.085743	0.075017	0.065261	0.071282
min	0.628342	0.742424	0.607571	0.465225	0.535206	0.628342
25%	0.716049	0.827586	0.697682	0.610287	0.620570	0.716049
50%	0.758333	0.853846	0.740199	0.666667	0.698496	0.758333
75%	0.776316	0.883741	0.811409	0.686893	0.717860	0.776316
max	0.869565	0.931707	0.905467	0.781250	0.775536	0.869565

	recall_micro	f1_micro	precision_weighted	recall_weighted	f1_weighted
count	21	21	21	21	21
mean	0.748234	0.748234	0.752711	0.748234	0.736822
std	0.071282	0.071282	0.075861	0.071282	0.072002
min	0.628342	0.628342	0.603139	0.628342	0.607821
25%	0.716049	0.716049	0.720258	0.716049	0.710373
50%	0.758333	0.758333	0.763074	0.758333	0.748742
75%	0.776316	0.776316	0.794346	0.776316	0.766984
max	0.869565	0.869565	0.876190	0.869565	0.861785

категории «Обувь»<sup>12</sup>. Проанализировав распределение данных по категориям (см. рисунок 6.7), можно заметить сильный дисбаланс классов. На рисунках 6.9, 6.8, 6.10 представлены classification report и матрица ошибок, а также более точные значения метрик качества accuracy, accuracy@topk, precision, recall и f1, рассчитанные через макроусреднение для тестового набора данных. Можно заметить, что качество, согласно метрика, в среднем составляет 70%. Такой показатель далек от идеала, однако подобная цифра объяснима с точки зрения особенностей датасета.

Для начала стоит принять во внимание, что категория малочисленна и содержит 440 товаров. При разделении на обучающую и тестовую выборки для тестовой было отделено 20% от всех товаров из категории. Другими словами, часть категорий имела менее 5 примеров в тестовом наборе данных. Легко ожидать, что при небольшом размере категории (например, категория «Обувь\_Для&новорожденных» включает всего 13 товаров) фотографии товаров могут иметь разнообразный характер, так что в тестовый набор могут попасть фотографии совершенно отличные от обучающего набора. В таком случае не стоит ожидать, что модель, видевшая порядка 10 примеров, сможет распознать данную категорию на совершенно отличных по внешнему виду товарах.

<sup>12</sup>Выбор данной категории для детального анализа не имеет скрытого подтекста. Категория имеет среднестатистические показатели, не являясь лучше или хуже других категорий. «Обувь» была выбрана поскольку, во-первых, имеет небольшое число классов, что делает графики менее загроможденными и упрощает общий анализ. Во-вторых, она отражает многие особенности в данных, характерные также и для других категорий и моделей.

Таблица 6.8: Описательная статистика значений метрик качества, достигнутых в классификационных моделях, на обучающем наборе данных.

	accuracy	accuracy_topk2	precision_macro	recall_macro	f1_macro	precision_micro
count	21	21	21	21	21	21
mean	0.955063	0.990519	0.960581	0.953518	0.955016	0.955063
std	0.056057	0.015293	0.045906	0.051586	0.050910	0.056057
min	0.795455	0.938202	0.849978	0.843508	0.844379	0.795455
25%	0.941667	0.991658	0.955447	0.932242	0.945330	0.941667
50%	0.979167	0.994565	0.973056	0.974867	0.973301	0.979167
75%	0.995652	1.000000	0.996241	0.995536	0.996029	0.995652
max	1.000000	1.000000	1.000000	1.000000	1.000000	1.000000

	recall_micro	f1_micro	precision_weighted	recall_weighted	f1_weighted
count	21	21	21	21	21
mean	0.955063	0.955063	0.956287	0.955063	0.955005
std	0.056057	0.056057	0.054852	0.056057	0.055983
min	0.795455	0.795455	0.796801	0.795455	0.795484
25%	0.941667	0.941667	0.942354	0.941667	0.941762
50%	0.979167	0.979167	0.979873	0.979167	0.978951
75%	0.995652	0.995652	0.995881	0.995652	0.995649
max	1.000000	1.000000	1.000000	1.000000	1.000000

Таблица 6.9: Classification report для модели "Обувь".

	precision	recall	f1-score	support
Обувь_Аксессуары&для&обуви	1.00	0.75	0.86	4
Обувь_Детская	0.67	0.67	0.67	9
Обувь_Для&новорожденных	0.33	0.33	0.33	3
Обувь_Женская	0.80	0.88	0.83	40
Обувь_Мужская	0.76	0.68	0.72	28
accuracy			0.76	84
macro avg	0.71	0.66	0.68	84
weighted avg	0.76	0.76	0.76	84

Другим важным наблюдением будет достаточно сильная путаница моделью товаров из категорий «Обувь\_Женская» и «Обувь\_Мужская». Проанализировав собранные данные и согласно здравому смыслу, легко заметить, что некоторые женские и мужские модели обуви похожи. Особенно сложно отличить обувь из подкатегории «Кеды&си&кроссовки». Для наглядности на рисунке 6.9 представлены товары из подкатегории «Кеды&си&кроссовки» для женщин (слева) и мужчин (справа). Аналогичный вывод справедлив и для категории «Обувь\_Детская», где можно найти похожие взрослую обувь модели.

Последним важным замечание относительно особенностей данных будет наличие неудачного парсинга в некоторых случаях, которое невозможно заранее предугадать. Так, например, в категории «Обувь\_Для&новорожденных» в момент сбора данных попались неудачные товары (см. сравнение товаров 6.10, размещенных на «Wildberries» на текущий момент, и попавших в собранную выборку), которые предположительно впоследствии отчасти были

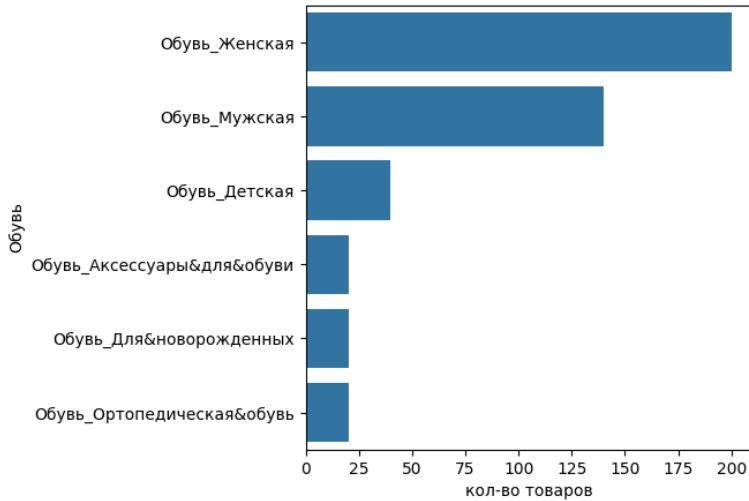


Рис. 6.7: Архитектура дерева классификационных моделей.

Таблица 6.10: Метрики качества модели "Обувь".

metric	value
accuracy	0.7619
accuracy@top2	0.8929
precision	0.7111
recall	0.6607
f1	0.6815

перенесены в другую категорию работниками «Wildberries» либо претерпели другие изменения. Можно заметить, что хотя категория предполагает обувь для новорожденных, по собранным с ней товарам тематика ставится под сомнение. Например, очень много присутствует товаров, таких как балетки или внешне более взрослые кроссовки, которые с таким же успехом можно было отнести к категории «Обувь\_Детская» и в которой действительно присутствуют подобные товары.

Из всего вышеперечисленного, а также из замечаний, описанных в разделе 5.3, следует главным образом один вывод – ожидать от модели классификации качества близкого к идеальному не стоит. Такова действительность работы с реальными данными, подверженными законам реальной жизни. На рисунке 6.11 представлены некоторые из ошибок классификатора на тестовых данных.

Проведем анализ PR и ROC кривых (см. рисунок 6.12 и 6.13 соответственно). В поведении кривых с макро и микроусреднением по классам можно заметить картину, аналогичную кривым, объединенным по всем моделям. В рассуждении стоит отталкиваться в первую очередь от анализа порогов отсечения, используемых для построения PR-кривых, и распределения плотности значений на графиках.

На голубой кривой, отвечающей за макроусреднение, при наивысших порогах отсе-

		Матрица ошибок				
		Обувь_Аксессуары&для&обуви	Обувь_Детская	Обувь_Для&новорожденных	Обувь_Женская	Обувь_Мужская
Истинные значения	Обувь_Аксессуары&для&обуви	3	0	0	0	1
	Обувь_Детская	0	6	2	0	1
	Обувь_Для&новорожденных	0	1	1	1	0
	Обувь_Женская	0	1	0	35	4
	Обувь_Мужская	0	1	0	8	19

Рис. 6.8: Матрица ошибок модели "Обувь" для тестового набора данных

чения имеется виденное ранее «проседание» в качестве precision. Это происходит по двум причинам. В таблице ?? представлены квантили порогов отсечения выше 0.9 для данной кривой. В 90% случаях вероятности предсказаний модели меньше 0.5. Такой показатель говорит о еще более неуверенной классификации, чем в общем случае. Другой причиной является особенности данных, которые влияют в том числе и на качество классификатора. В категории «Обувь» наименее хорошо предсказывается класс «Обувь\_Для&новорожденных» (см. таблицы 6.9 - 6.10), что соответствует второму классу<sup>13</sup>. Из таблицы верхних квантилей порогов отсечения (см. таблицу ??) видно, что максимальная вероятность на тестовых примерах в данной категории равняется 0.58, что является очень низким значением. Девяносто девятый квантиль составляет 39%. То есть классификатор на данной категории очень не уверен и с трудом отличает ее от других. Принимая во внимание способ расчета метрик при макроусреднении, который усредняет значение показателей precision и recall по всем классам, неудивительно падение precision на высоких порогах отсечения.

Подобное проседание метрики precision и параболообразная форма кривой заметно и на оранжевой линии, отвечающей за микроусреднение метрик, с тем различием, что падение качества происходит не сразу. Отдаление падения значения precision можно объяснить тем, что, принимая во внимание принцип расчета микро метрик и низкие вероятности предсказаний на некоторых категорий, классификация получается очень точной (precision равен 1). Как только происходит понижение порога до уровня, когда в игру вступают плохо предска-

<sup>13</sup>Подобная достаточно сильная неуверенность классификатора проявляется и в других классах.

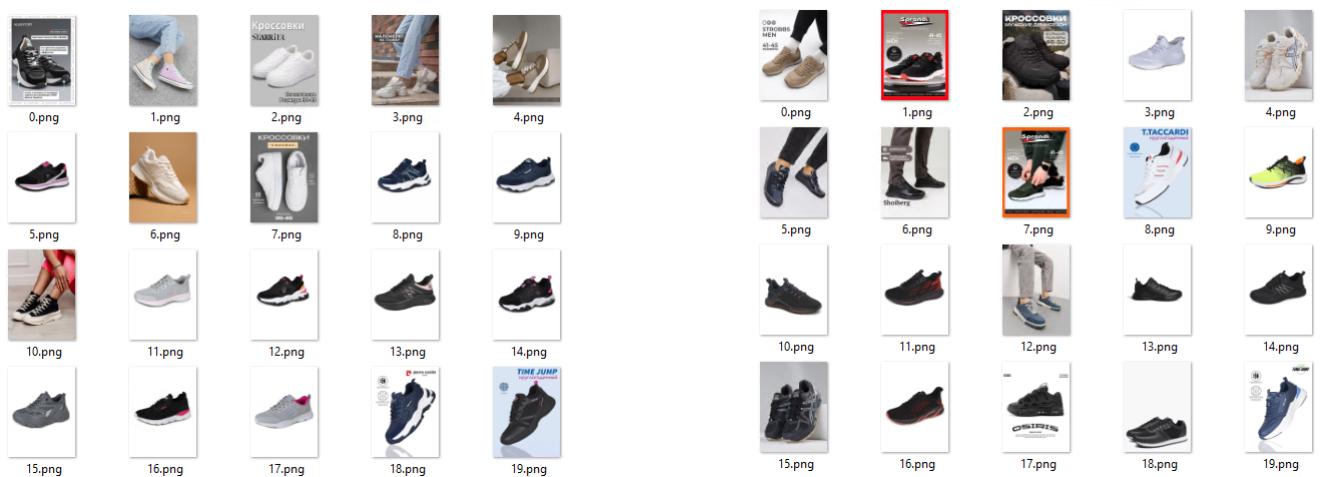


Рис. 6.9: Изображения, попавшие в категорию "Обувь\_Женская\_Кеды&и&кроссовки" (слева) и категорию "Обувь\_Мужская\_Кеды&и&кроссовки" (справа).

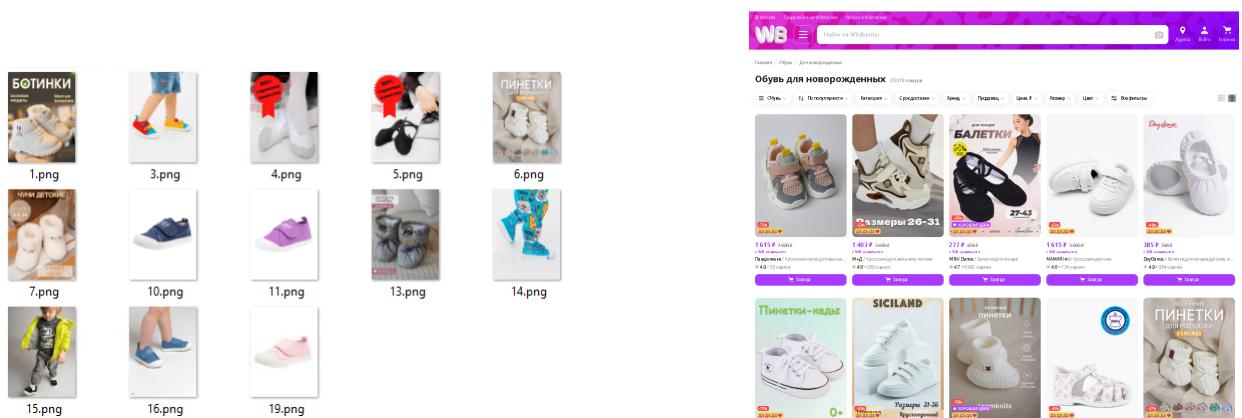


Рис. 6.10: Изображения, попавшие в категорию "Обувь\_Для&новорожденных" при парсинге (слева) и пример товаров, размещенных в разделе "Обувь\_Для&новорожденных" на текущий момент на "Wildberries" (справа).

зываемые категории или неоднозначные фотографии, возникает взлет false positive примеров и проседание precision.

Таким образом, исходя из визуального и аналитического анализа кривых, наиболее удачным выбором порога будут пороги, соответствующие вершинам парабол micro-average и macro-average pr-curve (оранжевая и голубая линии соответственно). Данный фрагмент характеризует 0.35-0.37 вероятностные пороги, при которых precision варьируется в диапазоне 74-73%, а recall находится в районе 59%.

Показатели ROC кривых (см. рисунок 6.13) согласуются со всеми вышеприведенными выводами. В целом значение AUC по классам довольно неплохое (ожидаемо, самое низкое в категории «Обувь\_Для&новорожденных», класс 2), все значения превышают показатель в 80%.

Подытоживая анализ модели, построенной на категорию «Обувь», можно сказать, что



Рис. 6.11: Примеры изображений из тестового набора данных, на которых был предсказан неверный класс (*y\_preds* - класс, предсказанный моделью, *y\_true* - инстинктивный класс).

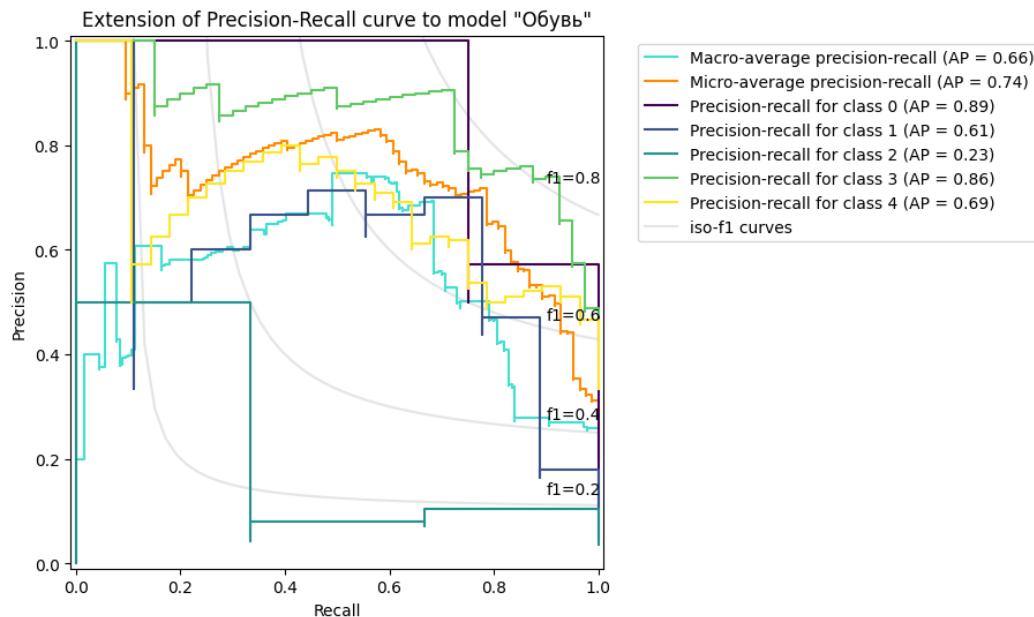


Рис. 6.12: PR-curve для модели "Обувь".

в модели присутствуют как хорошо-, так и плохо предсказываемые классы. В связи с этим, при оценивании модели в целом при макроусреднении показатели получаются более низкими, поскольку все классы имеют одинаковую важность. При микроусреднении метрик по классам картина более оптимистичная, так как плохая предсказательная сила на малочисленных классах нивелируется хорошими показателями на многочисленных категориях.

### 6.3 Х3 КАК НАЗВАТЬ5 (Image captioning)

После обучения всех классификаторов и получения из них эмбедингов изображений можно было переходить к решению задача генераций текстового описания.

Первым этапом в решении задачи создания подписей к изображениям стала подготовка собранных с «Wildberries» текстов. К данному вопросу стоит отнестись с особой осторожностью, поскольку внешний вид текстов, поданных в модель, будет напрямую влиять на полученные из нее описания. Существует большое разнообразие вариантов предобработки текстовых данных, способствующих улучшению производительности модели, таких как

quantile	threshold	quantile	threshold
0.90	0.476	0.90	0.476
0.91	0.501	0.91	0.501
0.92	0.513	0.92	0.513
0.93	0.535	0.93	0.535
0.94	0.585	0.94	0.585
0.95	0.604	0.95	0.604
0.96	0.629	0.96	0.629
0.97	0.648	0.97	0.648
0.98	0.695	0.98	0.695
0.99	0.772	0.99	0.772
1.00	0.858	1.00	0.858

Таблица 6.11: Верхние квантили вероятностных порогов, участвовавших в построении PR-кривых модели "Обувь".

Таблица 6.12: Верхние квантили вероятностных порогов, участвовавших в построении PR-кривой для категории «Обувь\_Для&новорожденных» модели "Обувь".

удаление лишних символов и стоп-слов, приведение к нижнему регистру, лемматизация и стемминг, обработка чисел и дат, токенизация и другие. Выбор пайплайна предварительной обработки зависит от поставленной задачи и требований, выдвигаемых к тексту. В рамках данной работы к текстам было поставлено следующее условие – генерируемые моделью тексты должны быть максимально похожими на настоящие тексты. Исходя из этого все цифры, специальные символы, знаки препинания и связующие частицы были оставлены без изменений, так как они способствуют сохранению важных структурных и семантических особенностей текста. Прочая обработка заключалась в приведении всех символов к нижнему регистру, для сокращения итогового числа токенов. График 6.14 содержит статистику по длинам последовательностей, полученных после предобработки. Можно заметить, что чаще всего размер описания не превосходит 2000 символом, что соответствует примерно 400 словам<sup>14</sup>. Максимальная встречающаяся длина равнялась 5000 символам, то есть примерно 1000 словам. Авторами было принято решение не ставить сильных ограничений на длину последовательности и производить при необходимости обрезку текста по 5000 символам. Затем была применены алгоритмы токенизации текста в двух вариантах.

Токенизатор - это ключевой компонент в процессе обработки текста, который разбивает текст на отдельные токены или слова. Выбор подходящего токенизатора существенно влияет на результат генерации текста в моделях обработки естественного языка и является критически важным шагом.

Для генерации текста были опробованы и применены следующие токенизаторы:

<sup>14</sup>Расчет исходит из средней длины слова в 5 букв.

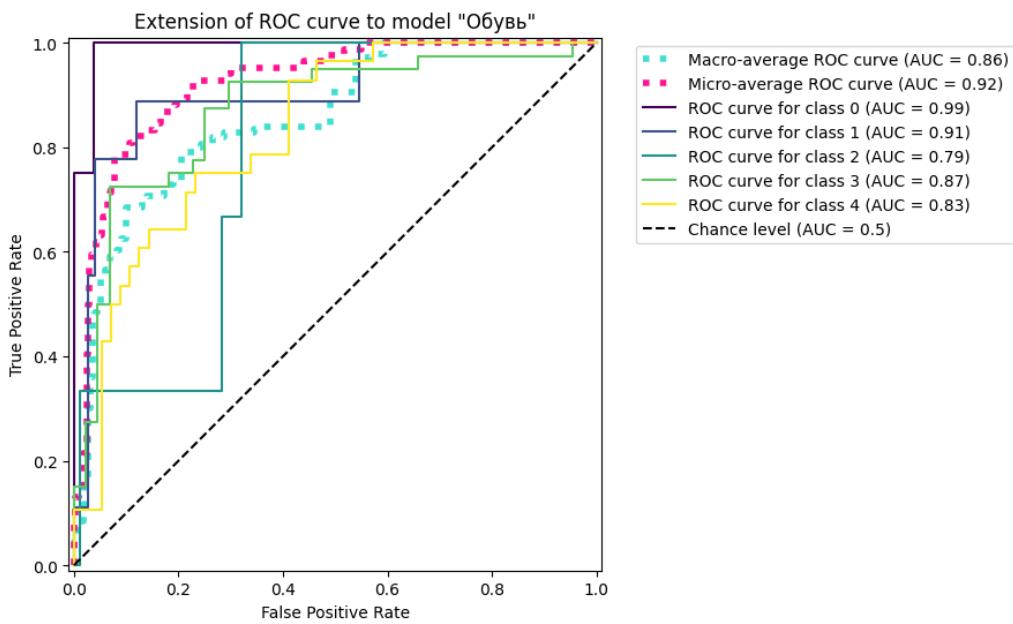


Рис. 6.13: ROC-curve для модели "Обувь".

- Кодирование парами байтов (от англ. Byte Pair Encoding, BPE) — это один из самых популярных методов токенизации, основанный на статистическом анализе корпуса текстов. Токенизатор разбивает текст на наименьшие семантически значимые подстроки, называемые байт-парами, что обеспечивает эффективную обработку редких слов и подслов. Это особенно полезно при генерации текста, где важно учитывать различные варианты слов и их частотность. Поскольку BPE работает на уровне байтов или подслов, ему нужно больше данных для эффективного построения словаря и выделения семантически значимых токенов. Это особенно важно для работы с редкими или нестандартными словами. BPE может быть более гибким и эффективным в обработке текста, но он также более сложен в настройке и требует больше вычислительных ресурсов. Тем не менее, при правильной настройке он может обеспечить более точное и гибкое представление текста.
- Токенизатор на уровне слов (от англ. Word Level Tokenizer) - это метод токенизации, который разбивает текст на отдельные слова или токены на основе пробелов или других разделителей. В отличие от BPE, который может разбивать текст на более мелкие подстроки и тем самым учитывать подслова или суффиксы, токенизатор на уровне слов работает на уровне целых слов. Это может привести к потере некоторой семантической информации, особенно в случае сложных слов или словоформ.

При неограниченном размере словаря число токенов равнялось примерно 160 тыс. в случае BPE токенизатора и 130 тыс. в случае Wordlevel токенизатора.

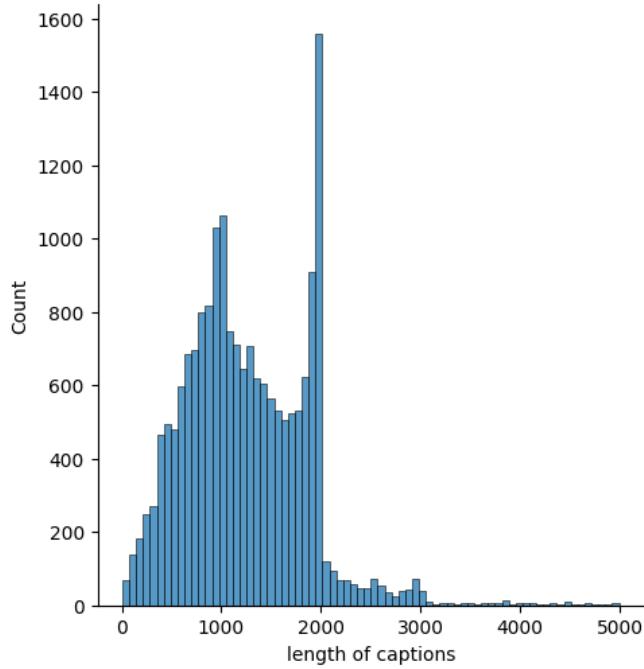


Рис. 6.14: Распределение длин описаний товаров. Примечание: длины рассчитаны в символах.

Было придумано несколько вариантов моделей с постепенным усложнением ее архитектуры. Во всех предложенных модификациях тестировались LSTM и GRU блоки.

Бейзлайном выступил одиночный блок рекуррентной сети (см. рисунок 6.15). Следу-

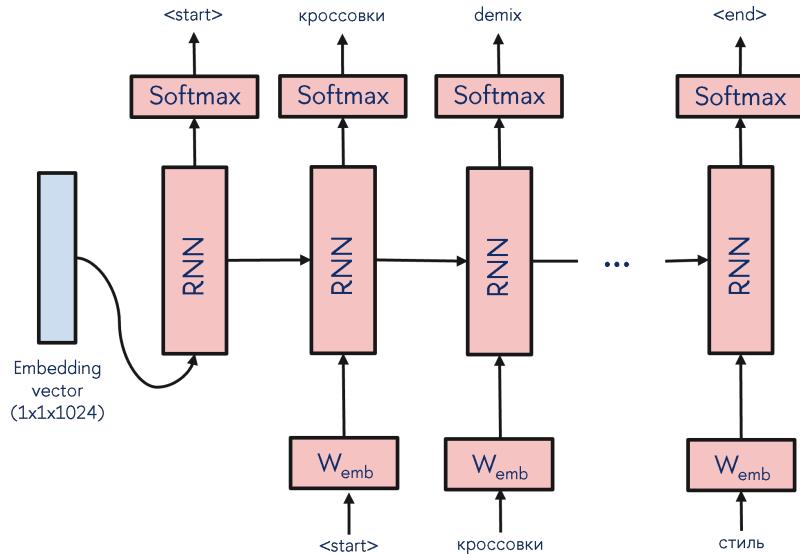


Рис. 6.15: Схема генерации текста при помощи одного блока RNN.

ющим усложнение схемы было добавление последовательных блоков RNN, в которых выход предыдущего блока становится входом следующего (см. рисунок 6.16). Далее был предложен вариант реализации параллельных RNN с двумя вариациями получения предсказаний (см. рисунок 6.17, 6.18): конкатенация и взвешивание. При параллельных RNN эмбединг

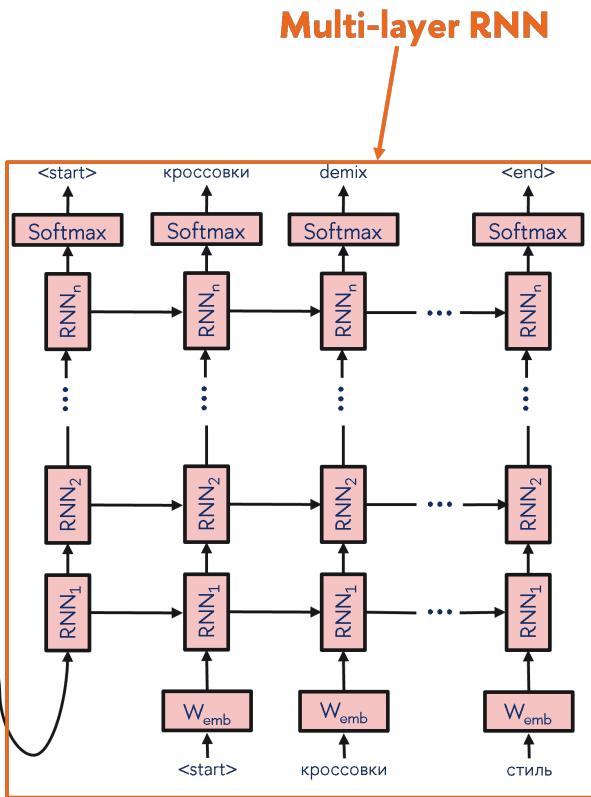


Рис. 6.16: Схема генерации текста при помощи последовательных блоков RNN.

изображения прогоняется одновременно через несколько блоков multi-layer RNN (см. рисунок 6.16) по принципу сиамских моделей. В варианте конкатенации к выходам из multi-layer RNN блоков применяется конкатенация с последующим навешиванием на полученный тензор линейного слоя для получения предсказания. В варианте со взвешиванием выходы multi-layer RNN блоков перевзвешиваются с определенными весами, аналогично наложению линейной регрессии. После на полученный тензор также накладывается линейный слой. Последней

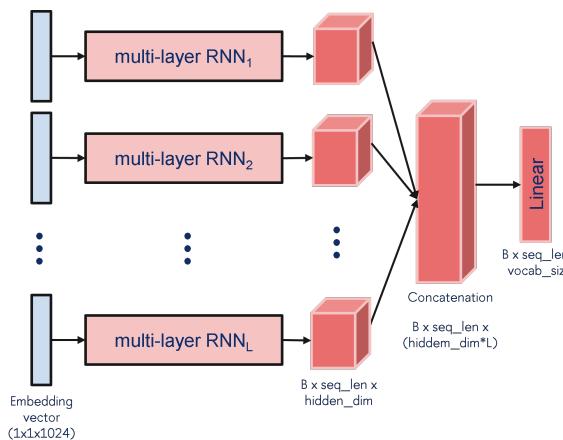


Рис. 6.17: Параллельные RNN (конкатенация).

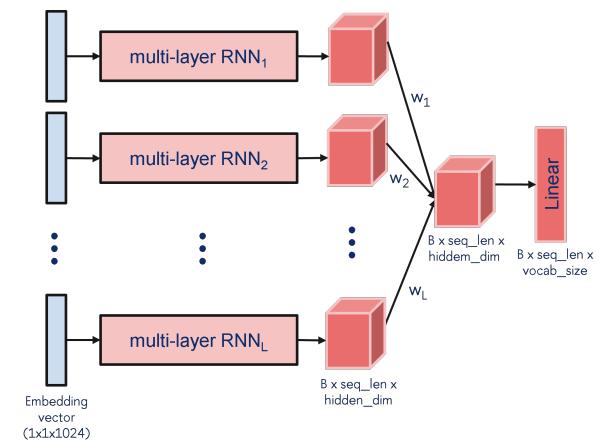


Рис. 6.18: Параллельные RNN (взвешивание).

предложенной модификацией стало добавление двух видов attention (подробнее о каждом

см. в разделе 5.4):

- взвешенное внимание;
- механизм внимания, который позволяет модели сосредоточиться на различных частях изображения с разной степенью важности на каждом этапе генерации.

Из анализа результатов классификационного дерева была выдвинута гипотеза, что качество классификации может оказывать влияние на качество сформированного эмбединга изображения и, следовательно, качество генерации текстовых описаний. Принимая во внимание разницу в качестве классификаций на обучающем и тестовом наборе данных<sup>15</sup>, было предложено отделить от обучающего датасета небольшое количество данных<sup>16</sup> (15%), примерно равное тестовому датасету, которое впоследствии отражало бы качество генераций на эмбедингах изображений, полученных из уверенного классификатора (см. таблицу 6.13). Таким образом, способность модели генерировать описания проверялась в трех вариантах: обучающий набор данных отражал данные, которые модель видела при обучении (отсутствие ошибки модели), валидационный – данные при условии хорошей классификации, но которые модель не видела при обучении (ошибка модели генерации), тестовый – данные при условии не очень качественной классификации и которые модель тоже не видела при обучении (наложение ошибок модели классификации и генерации).

Таблица 6.13: Размеры датасетов для задачи генерации подписей к изображениям.

	dataset size
train dataset	18857
val dataset	3329
test dataset	5550

При генерации текста для выбора наиболее вероятных последовательности слов использовались следующие стратегии (подробнее о каждой см. в разделе 5.6.1):

- жадный поиск;
- категориальная выборка;
- beam search.

<sup>15</sup>Разделение собранных данных на обучающую и тестовую выборки было произведено один раз в самом начале. Таким образом, тестовые данные для задачи классификации и для задачи генерации текстовых описаний были одними и теми же.

<sup>16</sup>Будем называть отделенную часть валидационным набором данных.

Лучшее качество генерации было достигнуто с использованием beam search.

В результате проведенных экспериментов была проверена гипотеза о том что качество, качество классификации влияет на качество генерации описания.

## 7 Проектирование архитектуры программного продукта

В 2022 году граждане Российской Федерации столкнулись с трудностями работы с магазинами приложений для смарт-устройств. Так, например, с 24 февраля из российского раздела App Store были удалены почти 7000 мобильных приложений [28]. Поэтому при построении архитектуры приложения был выбран подход к созданию клиент-серверного приложения, которое будет работать практически на любом устройстве (стационарный компьютер, ноутбук, планшет или смартфон). Одним из способов реализации такого подхода является написание telegram бота. В настоящее время это одно из трендовых направлений в IT сфере. В 2024 году Telegram посещают 900 миллионов человек в месяц [46]. По количеству аудитории он входит в пятерку самых популярных мессенджеров в мире. Выбор в пользу написания телеграм-бота вместо веб-приложения может быть обусловлен рядом факторов, включая удобство использования, скорость разработки, доступность, безопасность, а также гибкость и масштабированность для обработки большого количества пользователей.

За логику, работоспособность и правильное функционирование бота отвечает серверная часть (англ. backend), которая скрыта от пользователя. Серверная часть включает в себя:

- модуль для обработки запросов от пользователя;
- модуль для взаимодействия с обученной моделями классификации для определения категории товара и генерации его описания.

В контексте работы с моделями машинного обучения и их применения в системах автономного управления, вынос предсказаний моделей в очередь сообщений может быть полезно для оптимизации работы и повышения устойчивости системы.

На рисунке 7.1 представлена архитектура программного продукта с использованием стека технологий (подробнее см. в разделе 7.1).

### 7.1 Стек технологий

Для проектирования, разработки и обучения нейронных сетей использовался следующий стек технологий:

- Язык программирования Python — язык общего назначения, с помощью которого можно решать сложные задачи машинного обучения и быстро создавать прототипы для последующей их отладки. Язык гибкий и мультиплатформенный, имеет обширный набор

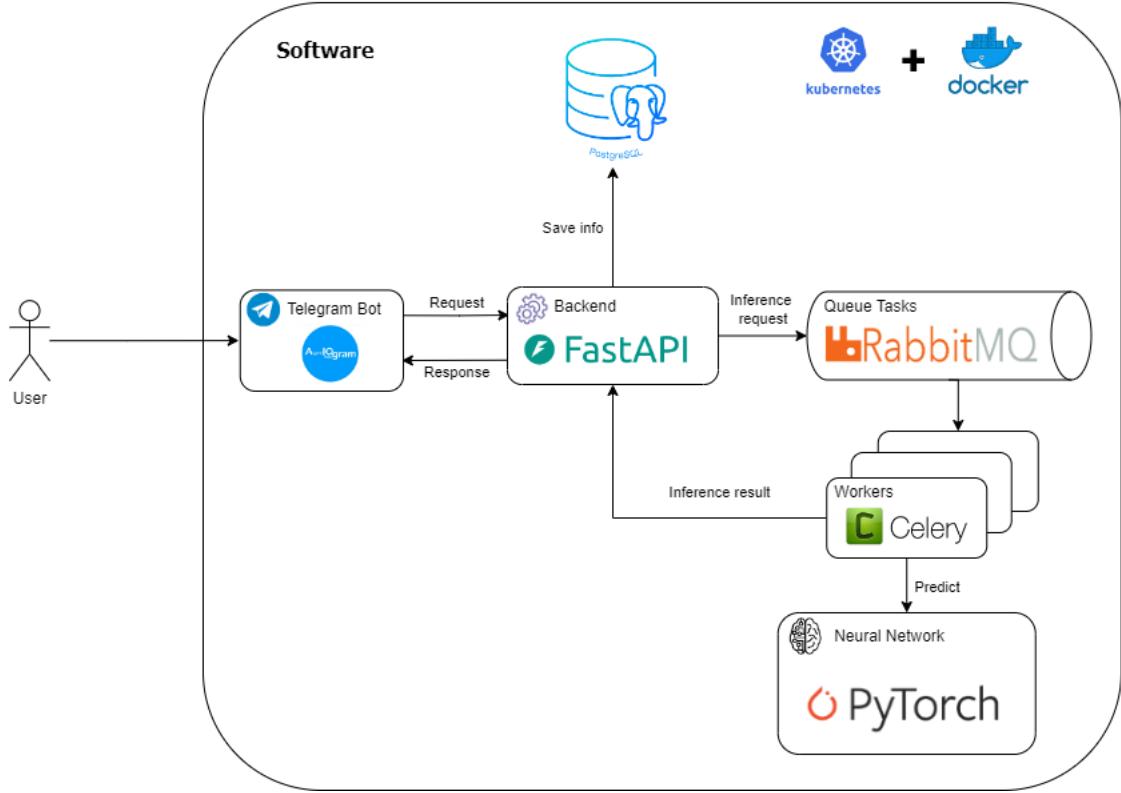


Рис. 7.1: Архитектура ПО с использованием стека технологий.

библиотек для искусственного интеллекта. Python удобно использовать для обработки и подготовки обучающих данных [31].

- Для реализации архитектуры нейронной сети использовался Pytorch — библиотека глубокого обучения с открытым исходным кодом, написанная на языке Python и созданная на базе Torch. Используется для решения различных задач машинного обучения: компьютерное зрение, NLP, создания и обучения нейронных сетей [32]. Простота использования, обширные возможности и активное сообщество делают ее популярным выбором для исследования и разработки в области глубокого обучения.
- Для реализация серверной части был выбран FastAPI — это современный и быстрый фреймворк для создания веб-приложений на языке Python, предлагающий полезные инструменты и функции для облегчения процесса создания веб-приложений[9].
- При реализации механизма обработки очереди задач использовалась комбинация инструментов: Celery[4] и RabbitMQ[33] для надежного обмена данными, а также Flower для мониторинга процесса выполнения задач. Celery представляет собой асинхронную очередь задач на языке Python, обеспечивающую создание, планирование и выполнение задач асинхронно. RabbitMQ, в свою очередь, является популярным брокером сообще-

ний для обмена данными между различными компонентами приложения, обеспечивая надежную доставку сообщений и поддерживая различные протоколы и архитектуры коммуникации. Flower представляет собой веб-интерфейс для мониторинга и управления задачами, запущенными с помощью Celery, предоставляя удобную панель управления для отслеживания статуса выполнения задач, просмотра логов и управления очередями. Эта связка обеспечивает гибкое и масштабируемое решение для управления задачами в приложении.

- Для хранения информации о пользователях и фотографиях товара используется СУБД PostgreSQL [29]. Она предоставляет надежное хранение данных, поддерживает множество расширений и функций, дает возможность работы с различными типами данных, а также обладает отличной производительностью и масштабируемостью.
- Для реализации бота для телеграмма используется библиотека Aiogram[1], которая предоставляет удобные инструменты для работы с API Telegram, обеспечивая простоту в использовании и расширяемость. К преимуществом данной библиотеки можно отнести асинхронную поддержку кода, наличие работы с медиафайлами, командами, встроенными клавиатурами, опросами и многое другое, что позволяет создавать ботов с различным функционалом.
- Для локального тестирования приложения использовался Docker Compose[6], что позволило быстро развернуть локальное окружение с минимальными усилиями. Параллельно, для управления контейнеризированным приложением в производственной среде использовался Kubernetes (k8s)[25]. Этот выбор обеспечил высокую доступность и масштабируемость приложения. Использование Docker Compose и Kubernetes существенно упростило процесс развертывания и повысило качество сервиса, обеспечив надежную и масштабируемую инфраструктуру.
- В Docker Compose добавлен мониторинг сервиса с помощью Prometheus[30] и Grafana[14].

Вычисления происходили с использованием аппаратных ускорений на GPU Nvidia Tesla V100 и A100.

## 7.2 Демонстрация работы приложения

Чтобы воспользоваться функционалом бота пользователю необходимо ввести команду «/predict» и загрузить фотографию товара. Далее ему будет предложена наиболее вероятная

категория товара и сгенерировано SEO-описание. Кроме того, у пользователя будет запрошено подтверждение или отклонение предложенной категории товара. Если пользователю категория не понравится, то бот не будет генерировать описание и попросит перефотографировать товар. В последствии эта обратная связь может быть использована для дообучения модели с целью ее дальнейшего улучшения точности и качества предсказаний.

На рисунках 7.2 и 7.3 представлены примеры работы сервиса на мужских джинсах.



Рис. 7.2: Демонстрация работы — подтверждение категории.



Рис. 7.3: Демонстрация работы — генерация описания.

На рисунке 7.4 представлен пример работы сервиса на духах.

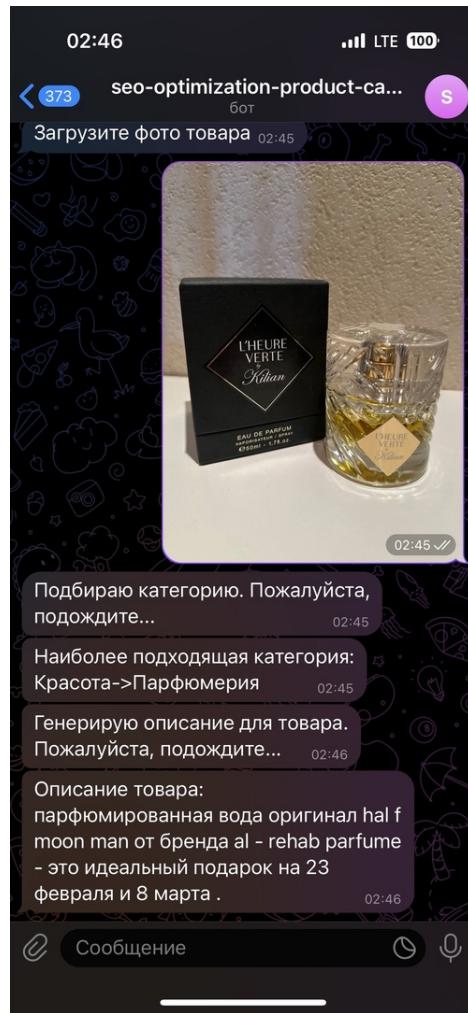


Рис. 7.4: Демонстрация работы сервиса на духах.

# Заключение

В рамках выпускной квалификационной работы было разработано программное обеспечение, в основе которого реализована модель нейронной сети, способная классифицировать товары на маркетплейсе на основе их фотографий и генерировать соответствующие к ним описания. Формализованы входные и выходные данные.

Были решены все поставленные задачи:

- Подготовлен набор данных, содержащий изображения товаров и соответствующие им категории и текстовые описания.
- Проанализированы существующие архитектуры нейронных сетей, используемых для классификации изображений и генерации текста. В ходе проведенного анализа была выбрана наиболее подходящая архитектура для решения поставленной задачи.
- Обучена спроектированная архитектура на подготовленных данных, а затем была оценена ее эффективность.
- Спроектирована архитектура программного обеспечения, описаны основные модули.
- Интегрирована модель нейронной сети в сервис.

Была проверена работоспособность схемы кодера-декодера с использованием комбинации сверточных нейронных сетей для обработки изображений и рекуррентных нейронных сетей для генерации подписей. В задаче классификации были достигнуты следующие результаты: в среднем по моделям доверять дереву классификации можно на 75%, при этом находя около 65% объектов положительного класса в тестовой выборке. Этот показатель далек от идеала, но объясним особенностями датасета.

В задаче генерации описаний была использована CNN из задачи классификации в качестве кодировщика и RNN в качестве декодировщика, с последующим усложнением. Это включало разработку новых решений для повышения качества классификации, использование последовательных и параллельных блоков RNN, а также добавление механизма внимания с разными способами его реализации. Однако качество генерации с использованием RNN остается недостаточно высоким. Для улучшения результатов рекомендуется развернуть экземпляр LLM, например, модель GPT-2.

Итогом работы стало подтверждение, что предложенная схема кодера-декодера успешно решает поставленную задачу. В результате проведенных экспериментов была подтверждена гипотеза о том, что качество классификации влияет на качество генерации описания, чем

точнее модель подберет категорию товара, тем лучше будет его описание. Для дальнейшего повышения качества генерации описаний рекомендуется рассмотреть переход на модели трансформеров, которые требуют значительных вычислительных ресурсов и времени на обучение, но могут обеспечить более высокий уровень результатов. Кроме того, выявила необходимость в увеличении объема датасета для достижения более высоких показателей качества.

Разработанное программное обеспечение имеет перспективу дальнейшего развития и улучшения:

- в качестве кодера и декодера использовать трансформеры;
- разработка функционала, позволяющего пользователям задавать ключевые слова, которые будут использоваться нейронной сетью при генерации текстовых описаний товаров;
- увеличение глубины подбора наиболее подходящей категории;
- увеличение количества данных обучающей выборки для повышения показателей точности;
- подключение систем для сбора метрик продукта;
- рассмотреть другие маркетплейсы («Ozon», «Яндекс Маркет», «Маркет»).

## Структура деления задач между участниками проекта

Для наглядного представления распределения обязанностей в проекте была составлена таблица 7.1, которая позволяет структурировано и ясно проследить прогресс работы, определить распределение обязанностей и оценить вклад каждого члена команды в общий результат.

Бузава С.М.	Куликов Д.А.
Сбор и анализ данных, написание функций для работы с датасетом	Реализация Телеграмм бота
Очистка данных	Очистка данных
Реализация и обучение моделей классификаторов	Обучение моделей классификаторов
Реализация и обучение моделей RNN с использованием последовательных и параллельных блоков	Реализация и обучение моделей RNN с использованием механизма внимания
Генерация последовательностей с помощью Beam Search	
Построение бизнес кривых	

Таблица 7.1: Распределение обязанностей.

Процесс разработки программного обеспечения осуществлялся совместными усилиями с использованием github-репозитория [47], который облегчил совместную работу над проектом, управление исходным кодом и процессом разработки, а также повысил эффективность и прозрачность работы всей команды.

## Список литературы

1. Aiogram. *Документация*. URL: <https://docs.aiogram.dev/en/dev-3.x/> (дата обр. 29.05.2024).
2. Dzmitry Bahdanau, KyungHyun Cho и Yoshua Bengio. “Neural Machine Translation by jointly learning to align and translate”. В: (2014).
3. Tom B. Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, Sandhini Agarwal, Ariel Herbert-Voss, Gretchen Krueger, Tom Henighan, Rewon Child, Aditya Ramesh, Daniel M. Ziegler, Jeffrey Wu, Clemens Winter, Christopher Hesse, Mark Chen, Eric Sigler, Mateusz Litwin, Scott Gray, Benjamin Chess, Jack Clark, Christopher Berner, Sam McCandlish, Alec Radford, Ilya Sutskever и Dario Amodei. “Language Models are Few-Shot Learners”. В: (2020).
4. Celery. *Документация*. URL: <https://docs.celeryq.dev/en/stable/> (дата обр. 29.05.2024).
5. CopyMonkey. *Сервис*. URL: <https://www.copymonkey.app/> (дата обр. 29.05.2024).
6. Docker. *Документация*. URL: <https://docs.docker.com/> (дата обр. 29.05.2024).
7. Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit и Neil Houlsby. В: () .
8. Tinkoff Ecommerce. *Итоги года на маркетплейсах: в 2023 году*. URL: <https://www.tinkoff.ru/about/news/29012024-marketplaces-year-results-number-of-purchases-increased-by-63-percent-in-2023/> (дата обр. 29.05.2024).
9. FastApi. *Документация*. URL: <https://fastapi.tiangolo.com/> (дата обр. 29.05.2024).
10. Gerwin. *Сервис*. URL: <https://app.gerwin.io/> (дата обр. 29.05.2024).
11. Github. *Дамасем Fashion-MNIST*. URL: <https://github.com/zalandoresearch/fashion-mnist> (дата обр. 29.05.2024).
12. Github. *Реализация архитектуры Image Captioning с использованием CNN и RNN*. URL: <https://github.com/sgrvinod/a-PyTorch-Tutorial-to-Image-Captioning> (дата обр. 29.05.2024).
13. Google. *Create image captioning models: Overview*. URL: [https://www.youtube.com/watch?v=LWIZj\\_RJYjM](https://www.youtube.com/watch?v=LWIZj_RJYjM) (дата обр. 29.05.2024).

14. Grafana. *Документация*. URL: <https://grafana.com/docs/> (дата обр. 29.05.2024).
15. Kaiming He, Xiangyu Zhang, Shaoqing Ren и Jian Sun. “Deep Residual Learning for Image Recognition”. B: (2015).
16. Andrew Howard, Mark Sandler, Grace Chu, Liang-Chieh Chen, Bo Chen, Mingxing Tan, Weijun Wang, Yukun Zhu, Ruoming Pang, Vijay Vasudevan, Quoc V. Le и Hartwig Adam. “Searching for MobileNetV3”. B: (2019).
17. Andrew G. Howard, Menglong Zhu, Bo Chen, Dmitry Kalenichenko, Weijun Wang, Tobias Weyand, Marco Andreetto и Hartwig Adam. “Efficient Convolutional Neural Networks for Mobile Vision Applications”. B: (2017).
18. HuggingFace. *Реализация архитектуры Image Captioning с использованием трансформеров*. URL: <https://huggingface.co/nlpconnect/vit-gpt2-image-captioning> (дата обр. 29.05.2024).
19. IBM. *What is artificial intelligence (AI)?* URL: <https://www.ibm.com/topics/artificial-intelligence> (дата обр. 29.05.2024).
20. IBM. *What is computer vision (CV)?* URL: <https://www.ibm.com/topics/computer-vision> (дата обр. 29.05.2024).
21. IBM. *What is machine learning (ML)?* URL: <https://www.ibm.com/topics/machine-learning> (дата обр. 29.05.2024).
22. IBM. *What is neural networks?* URL: <https://www.ibm.com/topics/neural-networks> (дата обр. 29.05.2024).
23. Kaggle. *Дамасем eCommerce Item Data*. URL: <https://www.kaggle.com/datasets/cclark/product-item-data> (дата обр. 29.05.2024).
24. Kaggle. *Дамасем Innerwear Data from Victoria's Secret, Others*. URL: <https://www.kaggle.com/datasets/PromptCloudHQ/innerwear-data-from-victorias-secret-and-others> (дата обр. 29.05.2024).
25. Kubernetes. *Документация*. URL: <https://kubernetes.io/docs/home/> (дата обр. 29.05.2024).
26. Medium. *GPT-4 Parameters: The Future of Natural Language Processing*. URL: <https://medium.com/@mlubbad/gpt-4-parameters-the-future-of-natural-language-processing-7f0f099070f8> (дата обр. 29.05.2024).
27. OpenAI. “GPT-4 Technical Reports”. B: (2024).

28. Sarah Perez. *Russia's App Store lost nearly 7K apps since its invasion of Ukraine, but some Big Tech apps remain*. URL: <https://techcrunch.com/2022/03/15/russias-app-store-lost-nearly-7k-apps-since-its-invasion-of-ukraine-but-some-big-tech-apps-remain/> (дата обр. 29.05.2024).
29. PostgreSQL. *Документация*. URL: <https://www.postgresql.org/docs/> (дата обр. 29.05.2024).
30. Prometheus. *Документация*. URL: <https://prometheus.io/docs/introduction/overview/> (дата обр. 29.05.2024).
31. Python. *Документация*. URL: <https://www.python.org/doc/> (дата обр. 29.05.2024).
32. Pytorch. *Документация*. URL: <https://pytorch.org/> (дата обр. 29.05.2024).
33. RabbitMQ. *Документация*. URL: <https://www.rabbitmq.com/docs> (дата обр. 29.05.2024).
34. Alec Radford, Karthik Narasimhan, Tim Salimans и Ilya Sutskever. “Improving Language Understanding by Generative Pre-Training”. B: (2018).
35. Alec Radford, Jeffrey Wu, Rewon Child, David Luan, Dario Amodei и Ilya Sutskever. “Language Models are Unsupervised Multitask Learner”. B: (2019).
36. ReadMedium. *Cutout, Mixup, and Cutmix: Implementing Modern Image Augmentations in PyTorch*. URL: <https://readmedium.com/cutout-mixup-and-cutmix-implementing-modern-image-augmentations-in-pytorch-a9d7db3074ad> (дата обр. 29.05.2024).
37. Mark Sandler, Andrew Howard, Menglong Zhu, Andrey Zhmoginov и Liang-Chieh Chen. “MobileNetV2: Inverted Residuals and Linear Bottlenecks”. B: (2019).
38. Towards Data Science. *Архитектура Image Captioning с использованием CNN и RNN*. URL: <https://towardsdatascience.com/automatic-image-captioning-with-cnn-rnn-aae3cd442d83> (дата обр. 29.05.2024).
39. SkillFactory. *Словарь IT*. URL: <https://blog.skillfactory.ru/glossary/nlp/> (дата обр. 29.05.2024).
40. Mingxing Tan и Quoc V. Le. “EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks”. B: (2020).
41. Mingxing Tan и Quoc V. Le. “EfficientNetV2: Smaller Models and Faster Training”. B: (2021).

42. TorontoAI. *EfficientNet: повышение точности и эффективности с помощью AutoML и масштабирования моделей*. URL: <https://torontoai.org/2019/05/28/efficientnet-improving-accuracy-and-efficiency-through-automl-and-model-scaling/> (дата обр. 29.05.2024).
43. TurboText.Pro. *Сервис*. URL: <https://turbotext.pro/> (дата обр. 29.05.2024).
44. Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser и Illia Polosukhin. “Attention Is All You Need”. В: (2017).
45. Data World. *Дамасем Fashion Products on Amazon*. URL: <https://data.world/promptcloud/fashion-products-on-amazon-com> (дата обр. 29.05.2024).
46. Алексей Бегин. *Статистика Telegram (июнь 2024)*. URL: <https://inclient.ru/telegram-stats/> (дата обр. 01.06.2024).
47. Бузаева Софья и Куликов Дмитрий. *Реализация проекта: SEO-оптимизация карточек товара на маркетплейсах*. URL: <https://github.com/Kulikov17/seo-optimization-product-cards/> (дата обр. 29.05.2024).

## A Приложение 1

### Распределение данных по категориям второй вложенности.

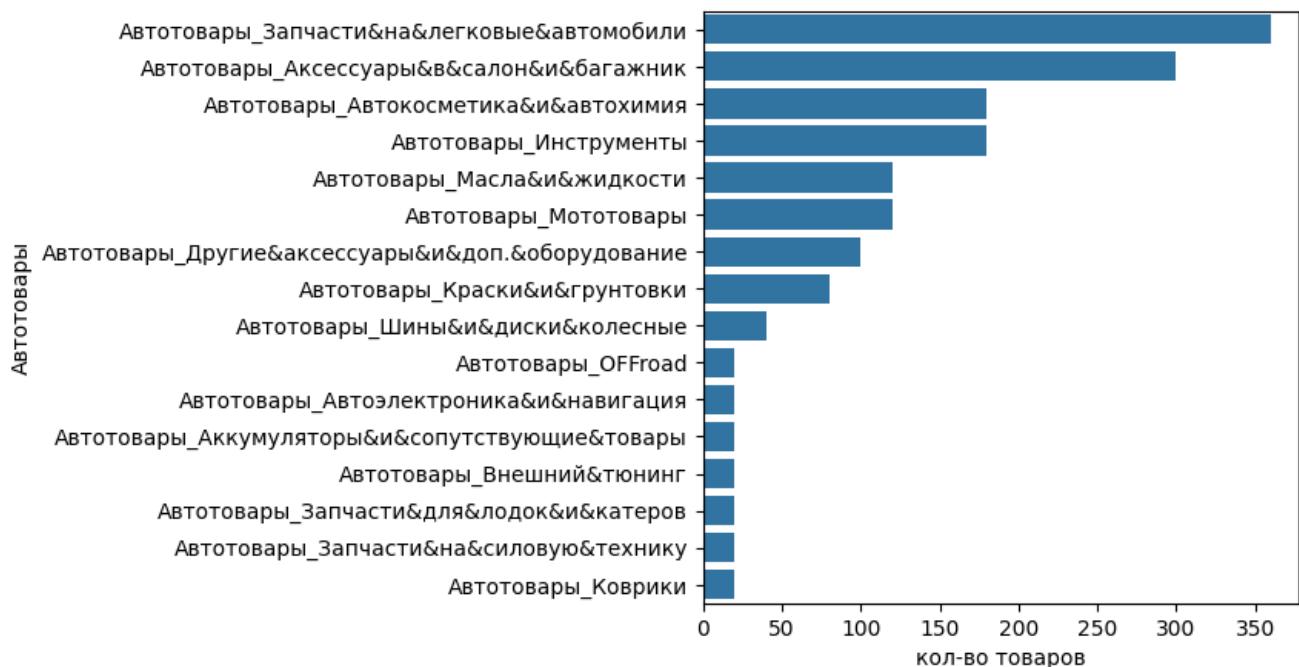


Рис. А.1: Распределение данных в категории «Автотовары».

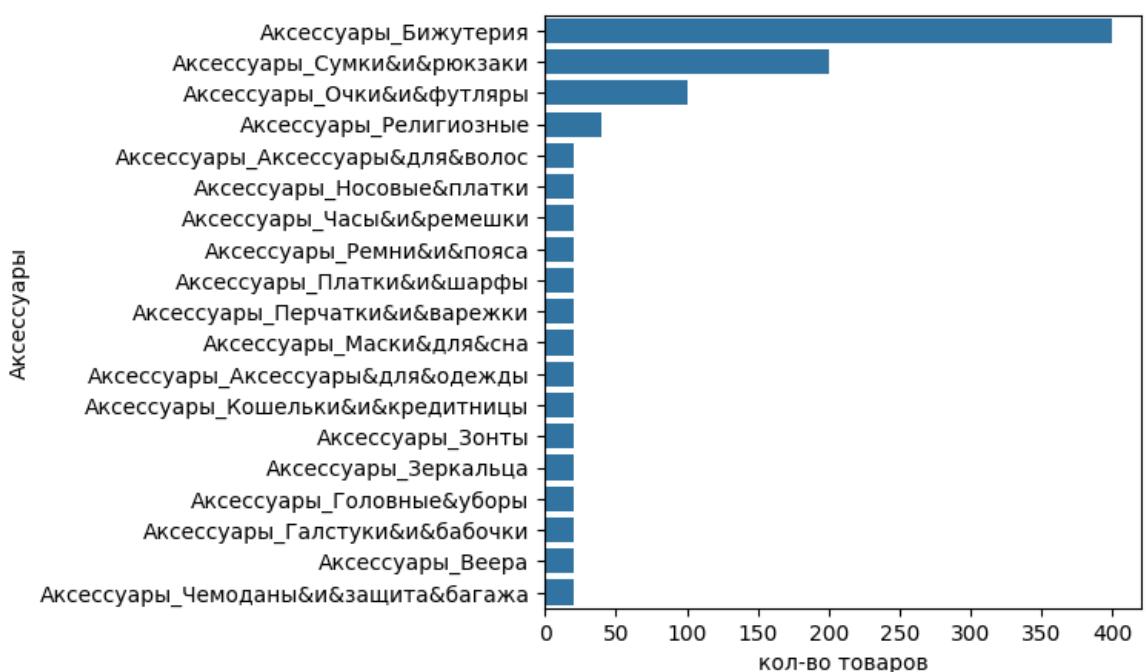


Рис. А.2: Распределение данных в категории «Аксессуары».

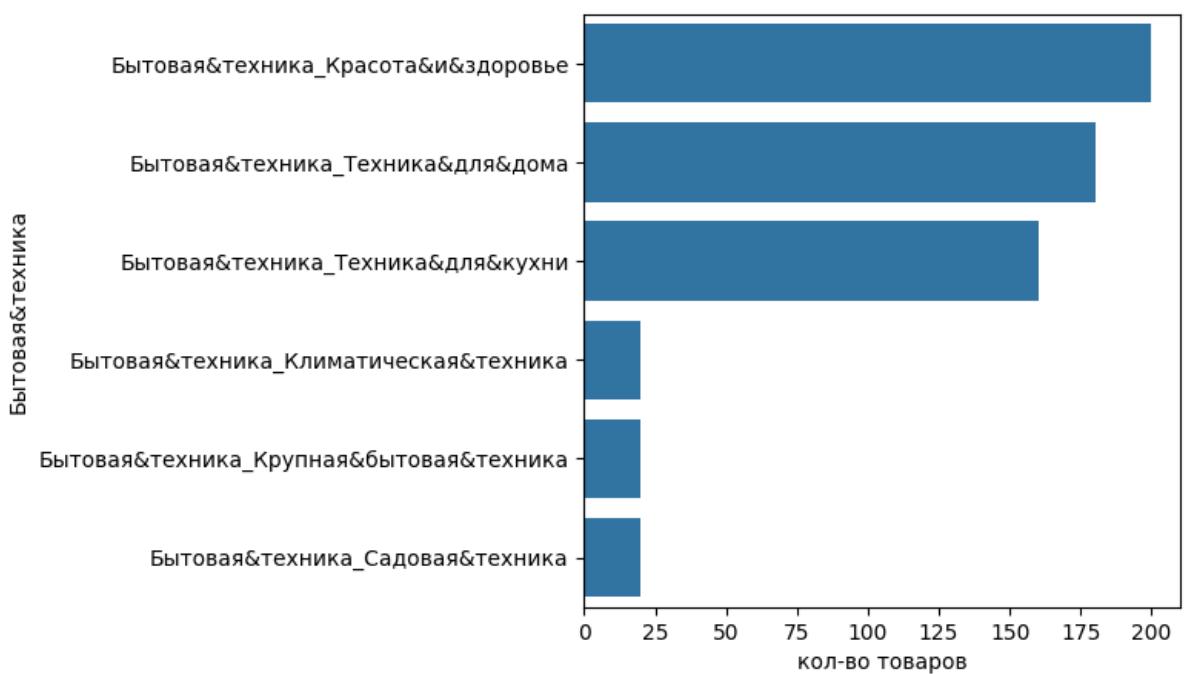


Рис. А.3: Распределение данных в категории «Бытовая&техника».

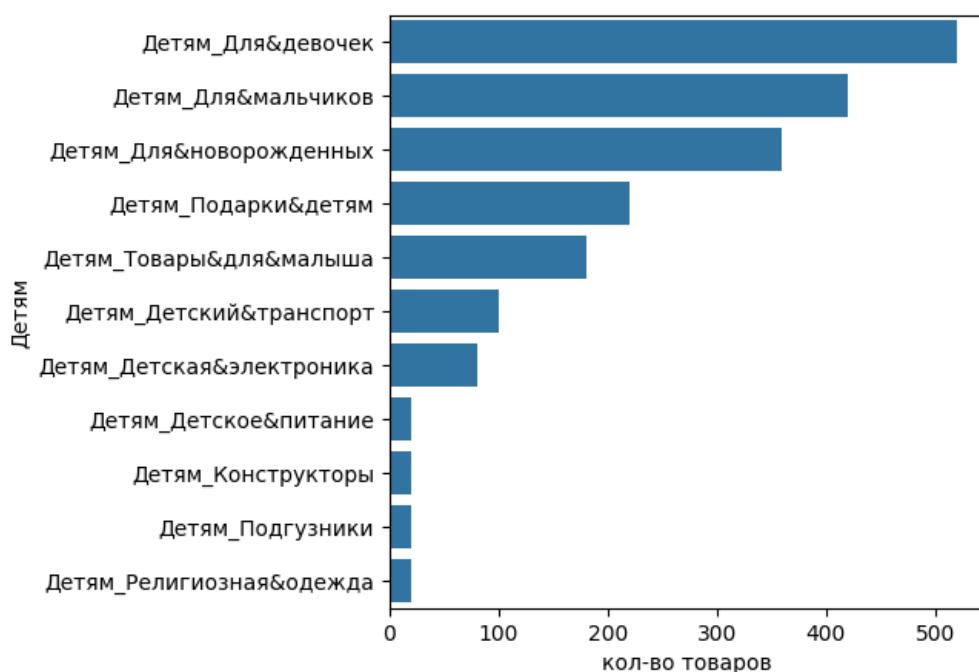


Рис. А.4: Распределение данных в категории «Детям».

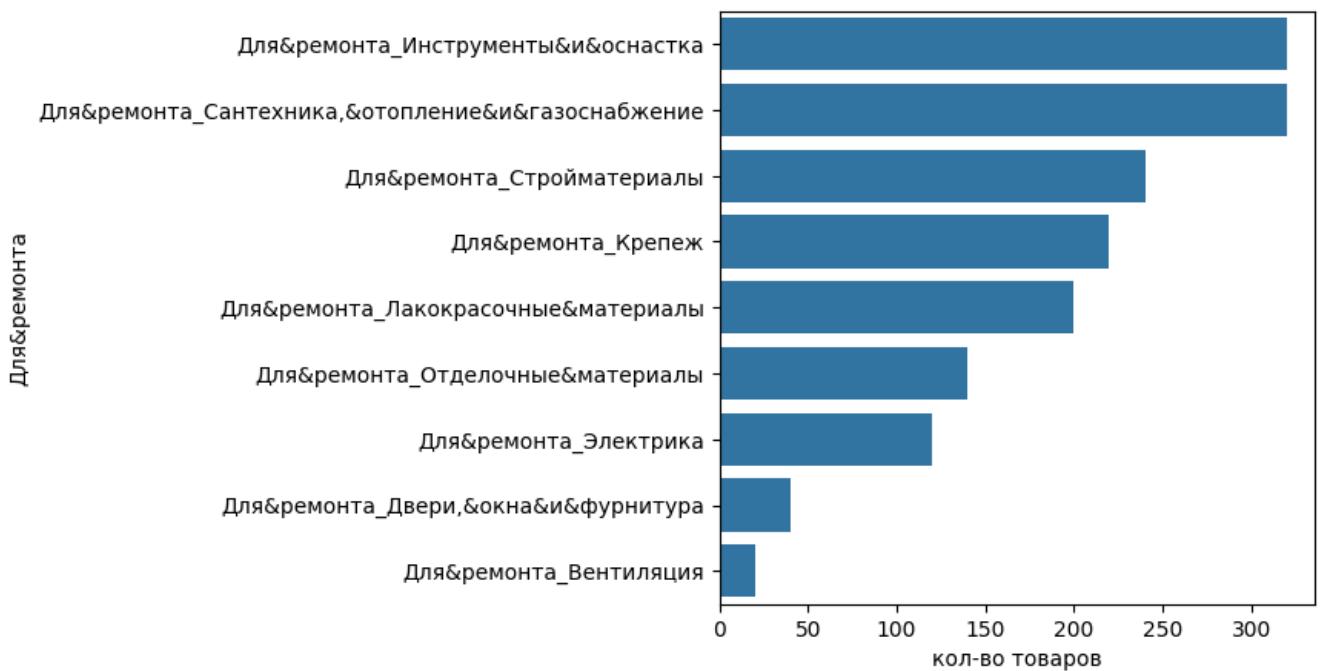


Рис. А.5: Распределение данных в категории «Для&ремонта».

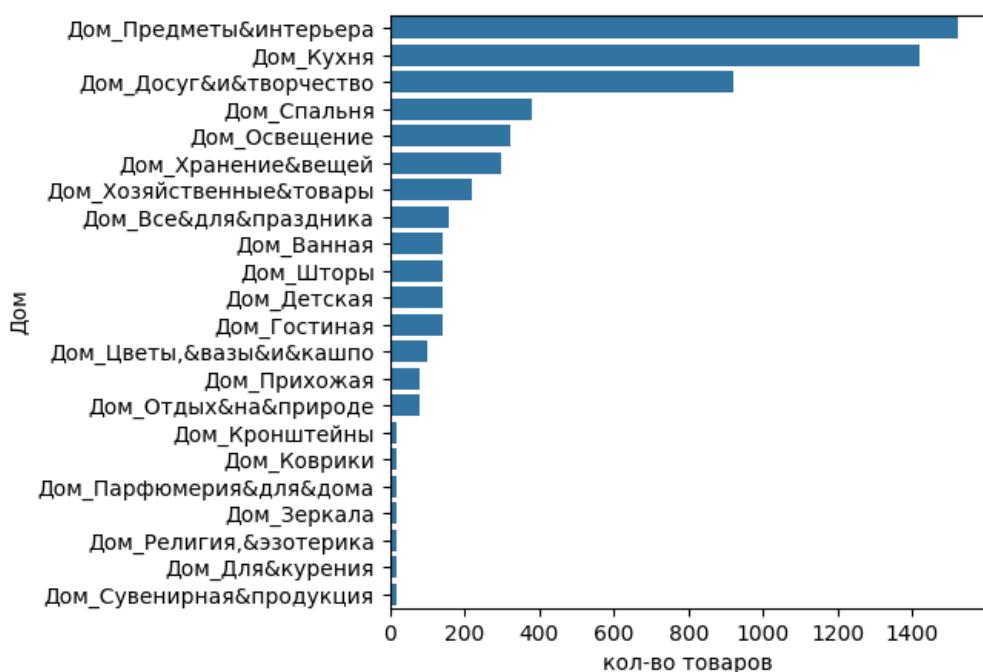


Рис. А.6: Распределение данных в категории «Дом».

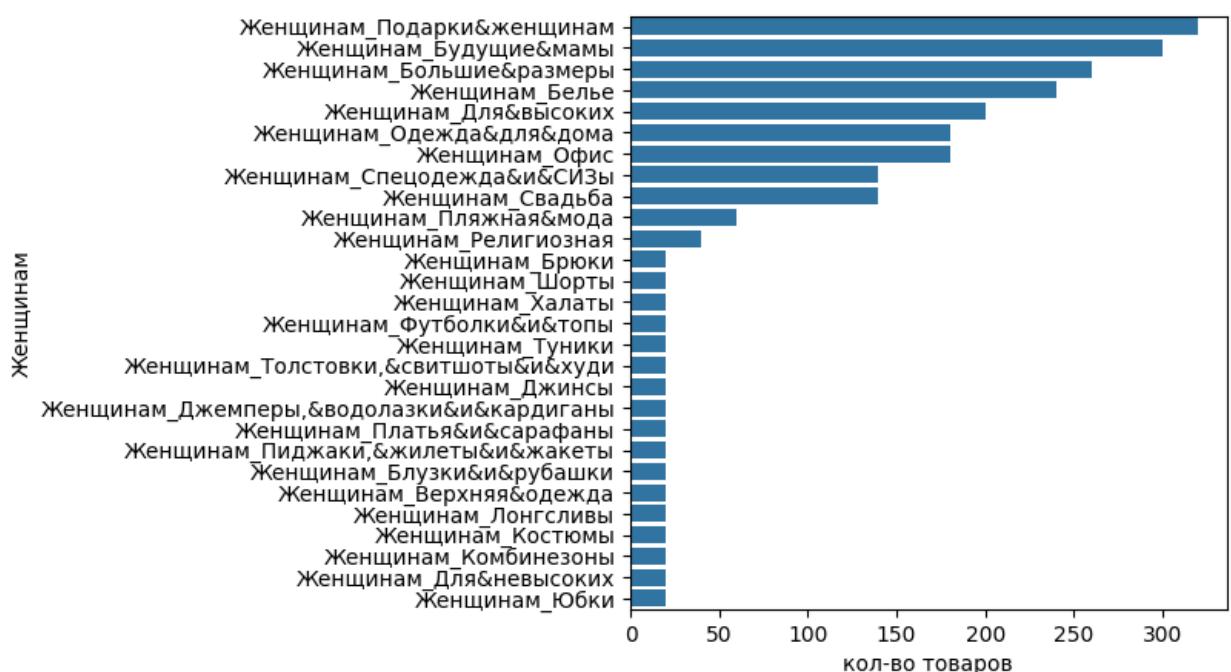


Рис. А.7: Распределение данных в категории «Женщинам».

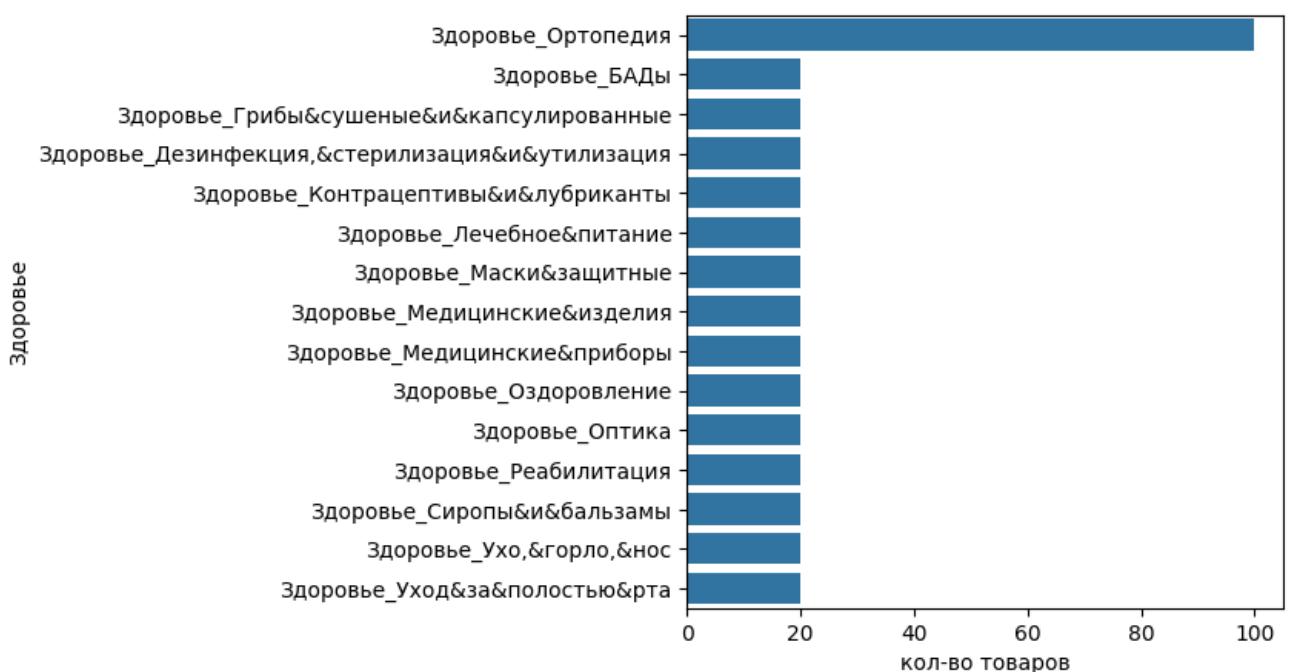


Рис. А.8: Распределение данных в категории «Здоровье».

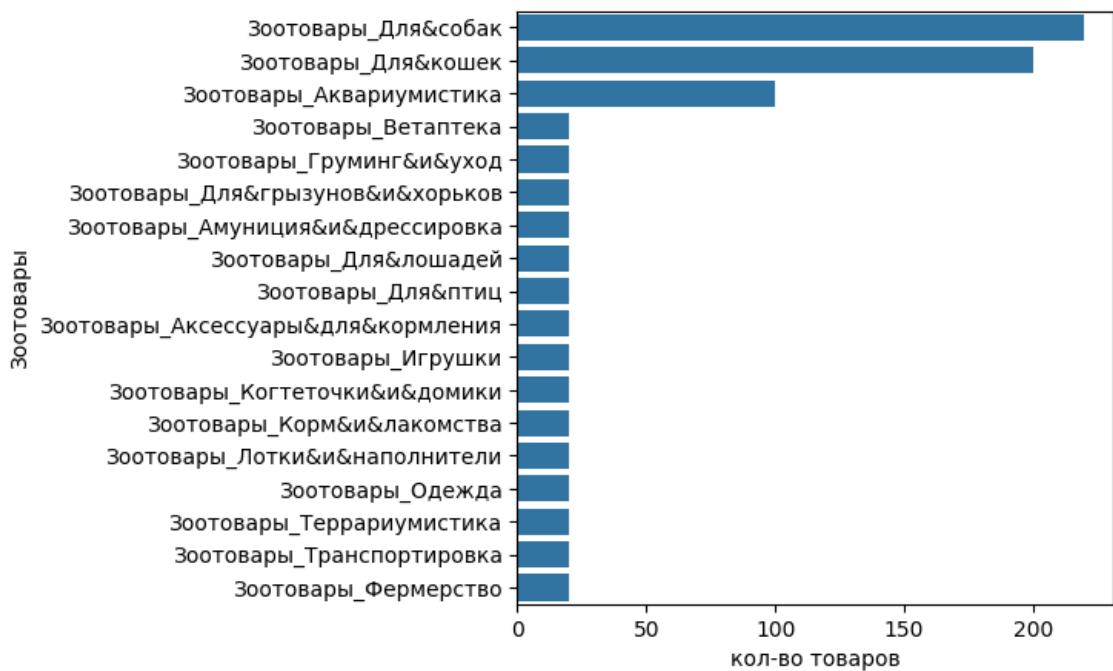


Рис. А.9: Распределение данных в категории «Зоотовары».

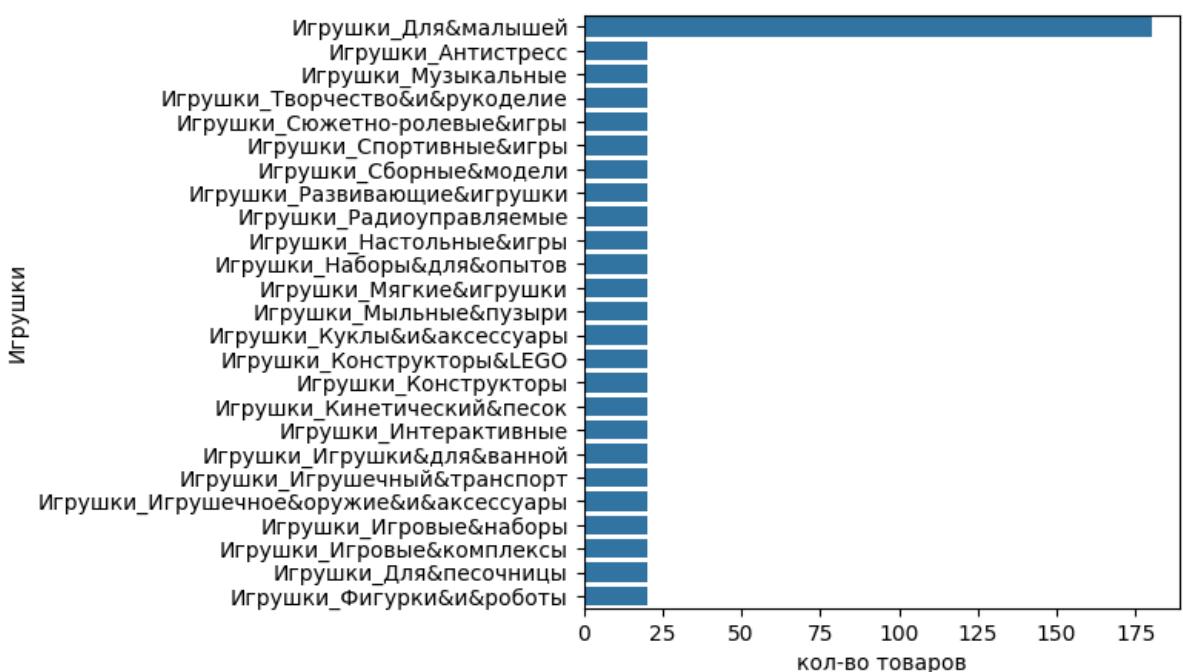


Рис. А.10: Распределение данных в категории «Игрушки».

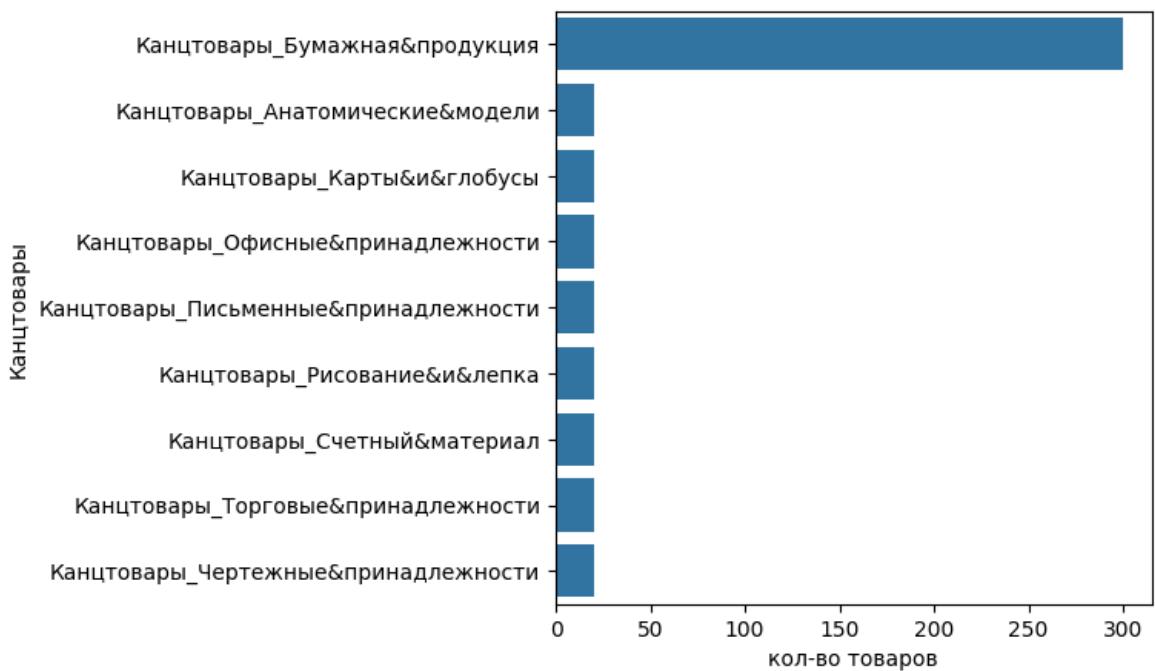


Рис. А.11: Распределение данных в категории «Канцтовары».

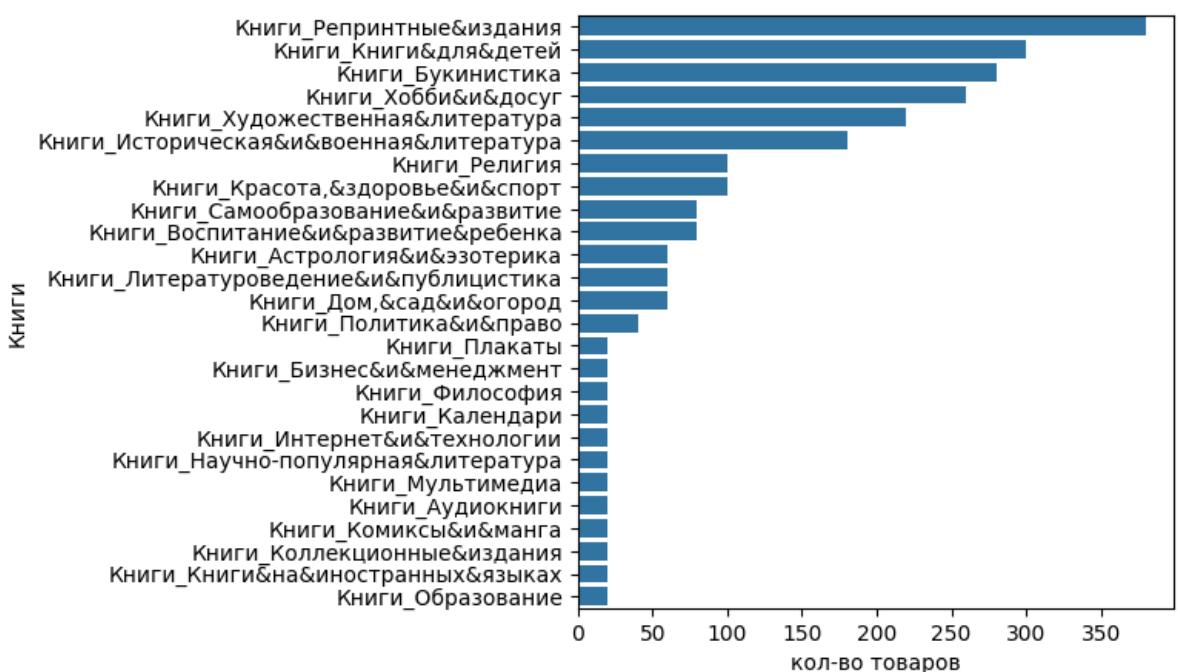


Рис. А.12: Распределение данных в категории «Книги».

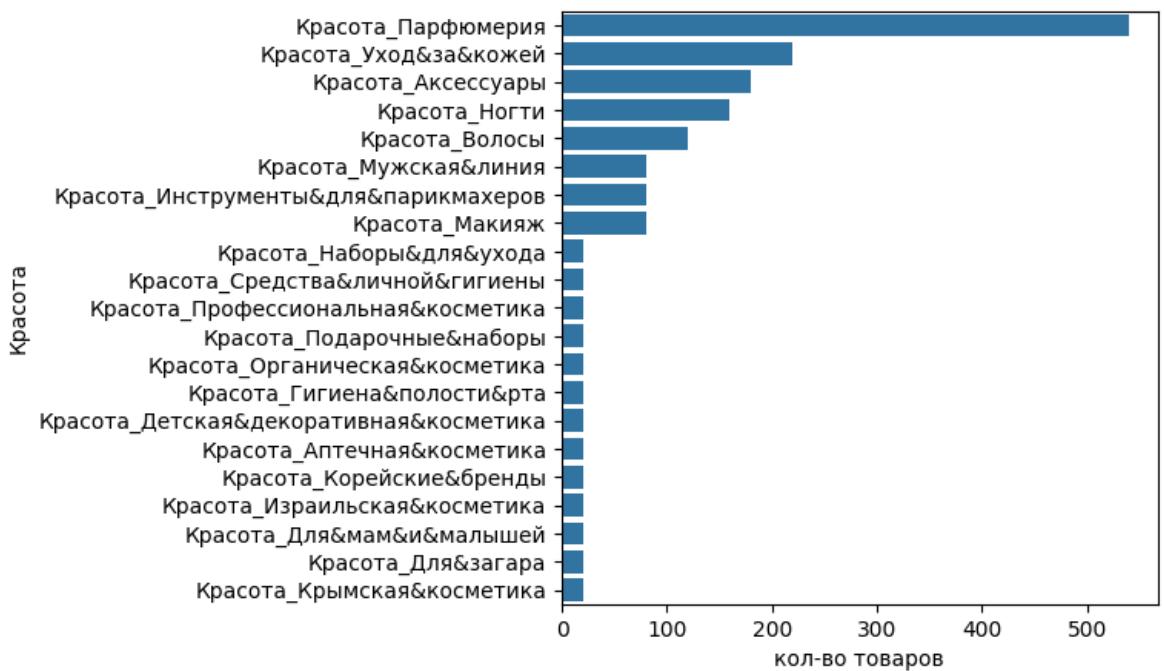


Рис. А.13: Распределение данных в категории «Красота».

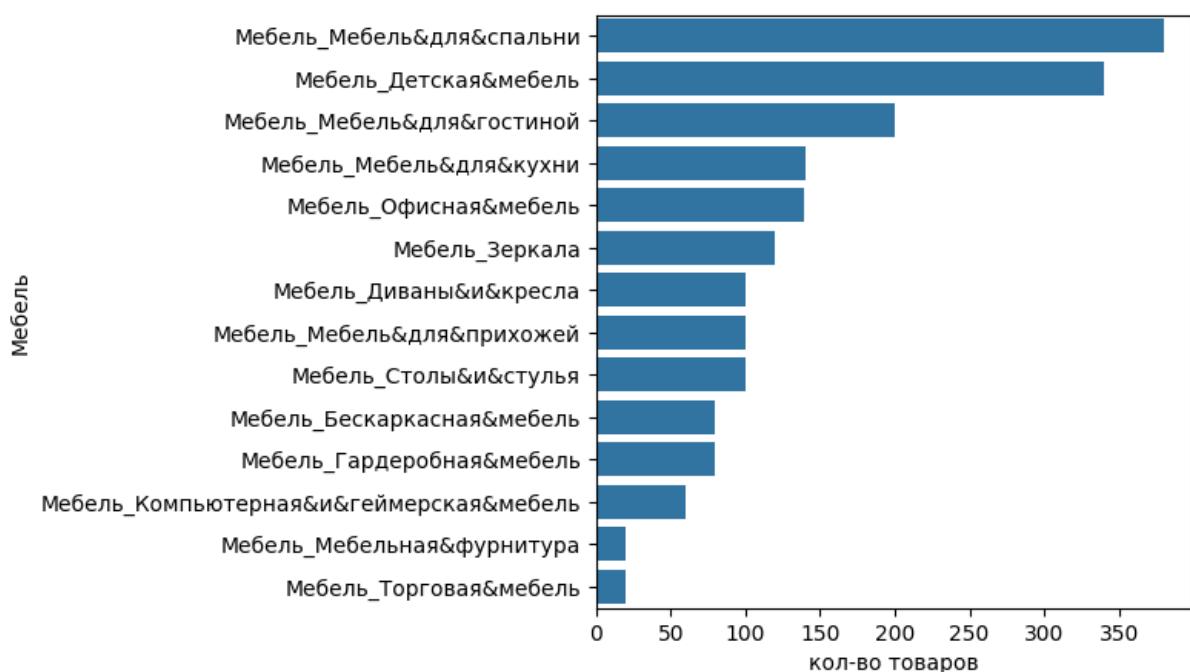


Рис. А.14: Распределение данных в категории «Мебель».



Рис. А.15: Распределение данных в категории «Мужчинам».

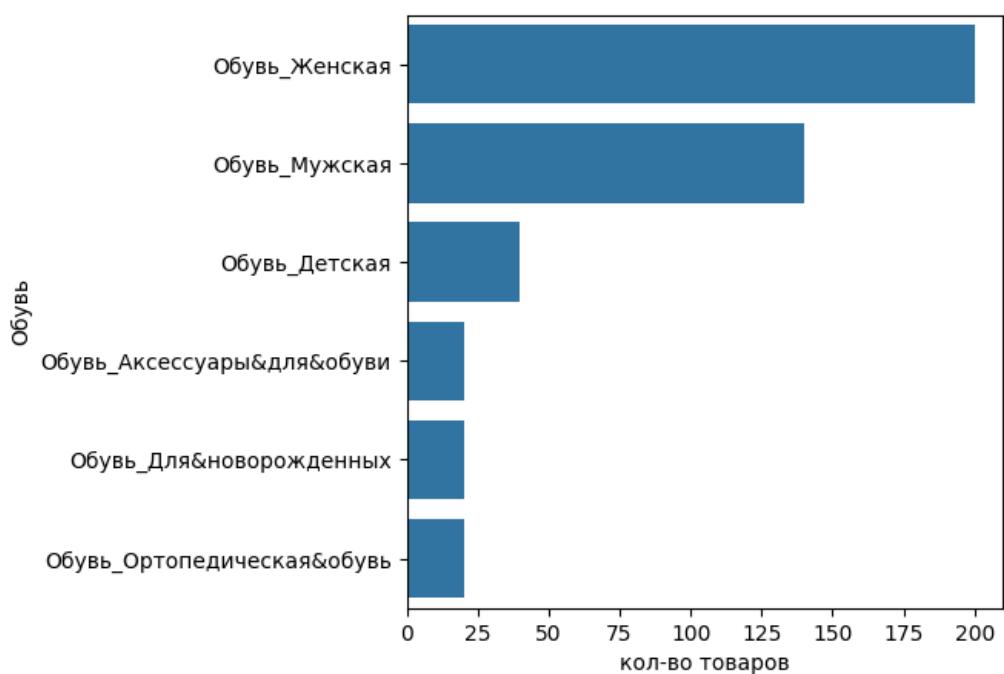


Рис. А.16: Распределение данных в категории «Обувь».

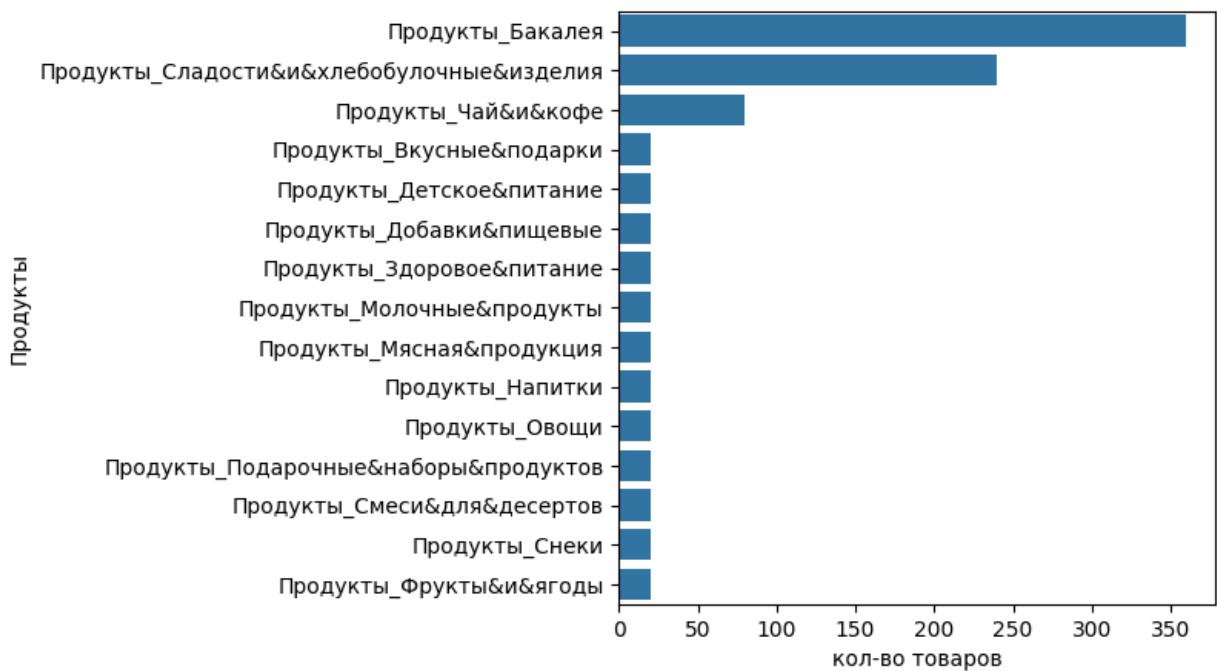


Рис. А.17: Распределение данных в категории «Продукты».

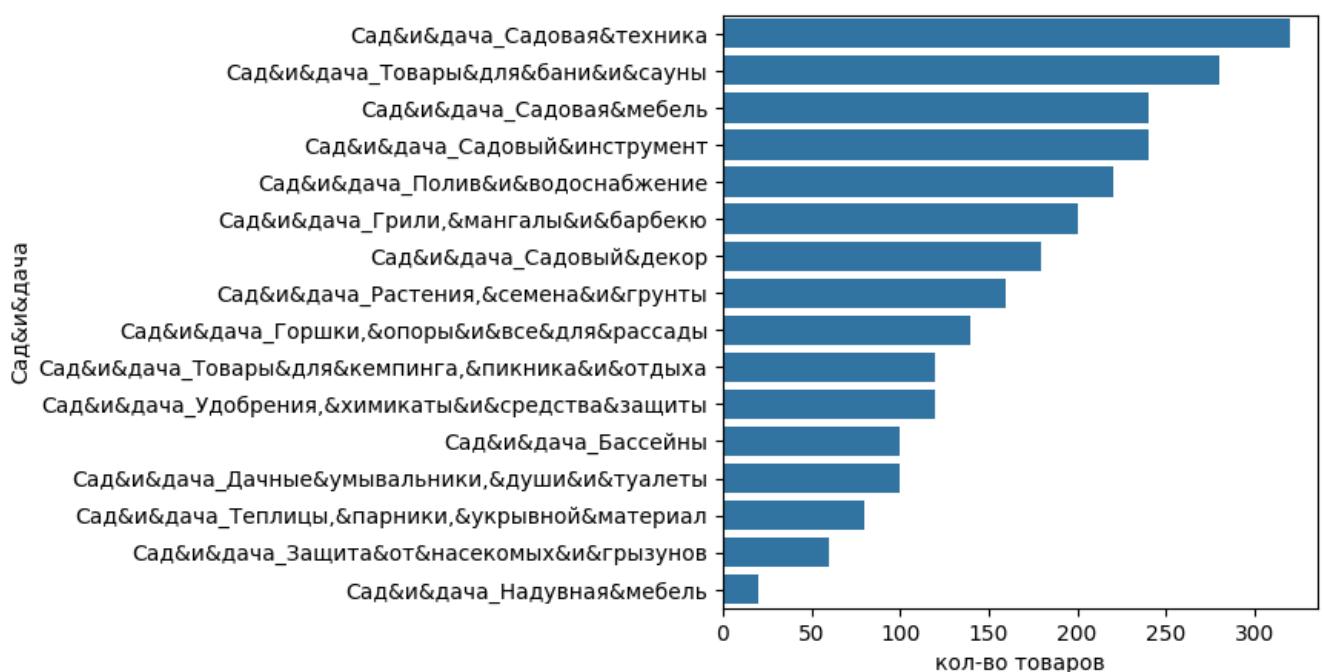


Рис. А.18: Распределение данных в категории «Сад&и&дача».

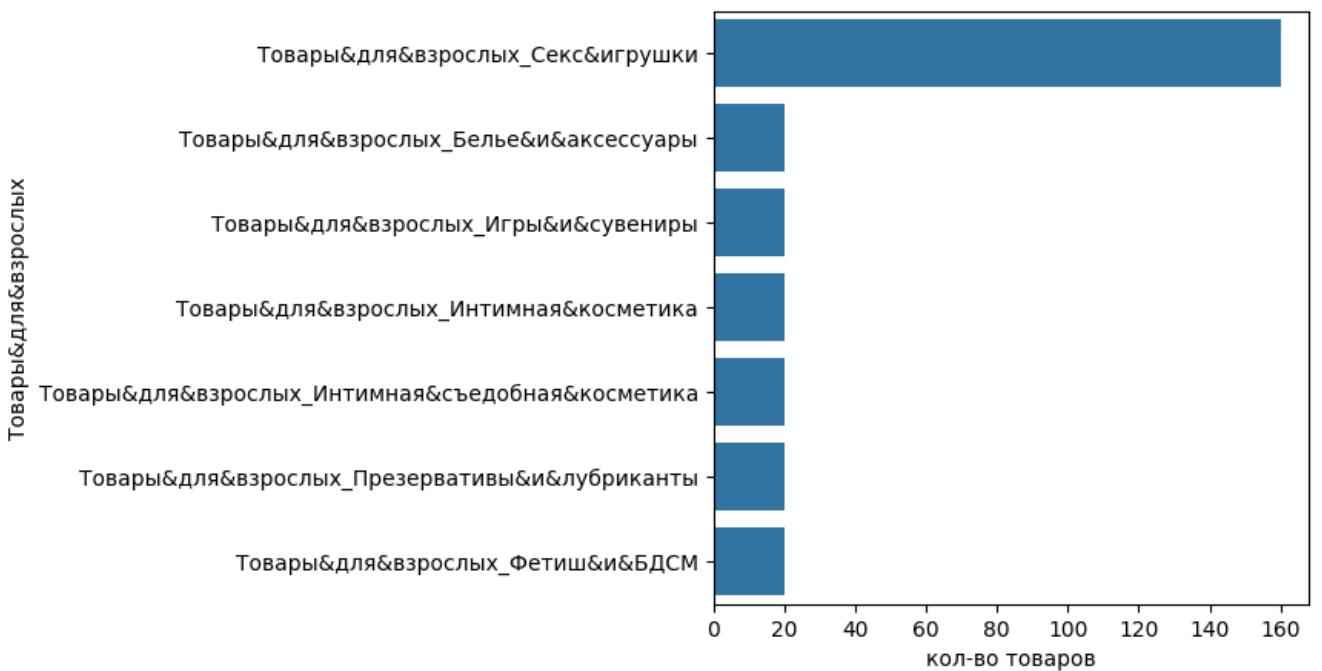


Рис. А.19: Распределение данных в категории «Товары&для&взрослых».

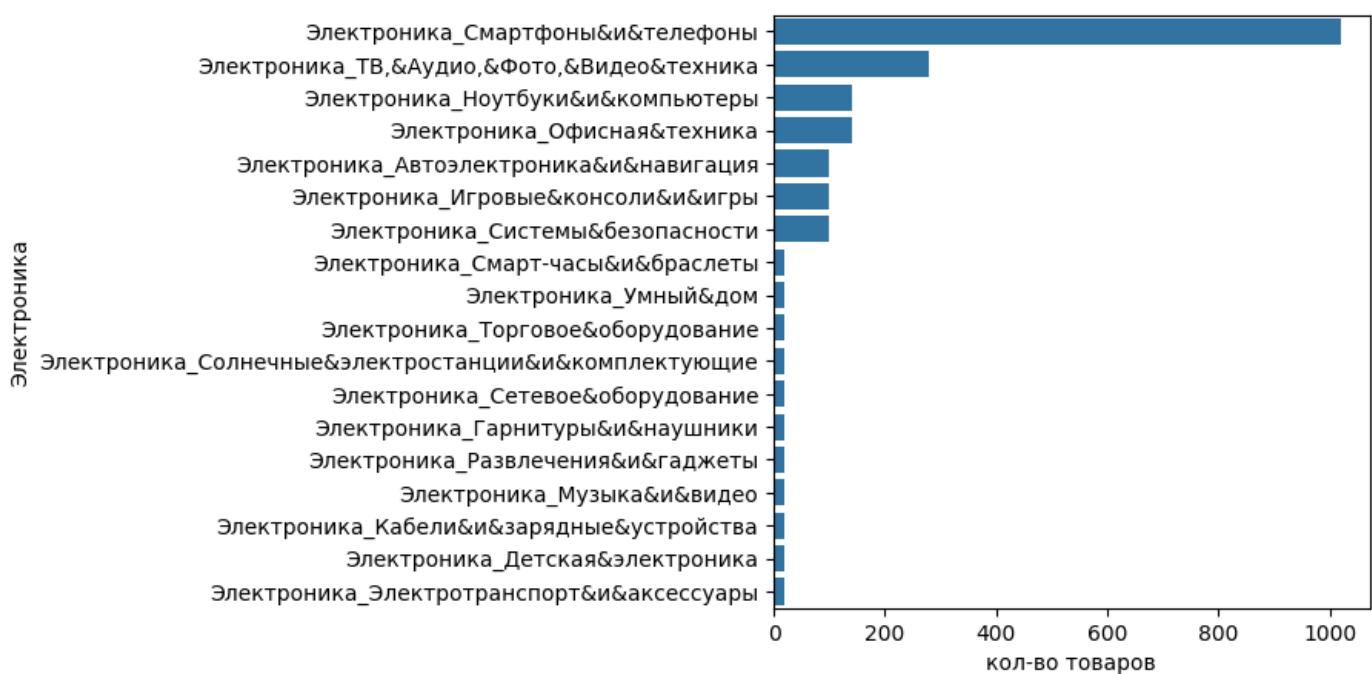


Рис. A.20: Распределение данных в категории «Электроника».

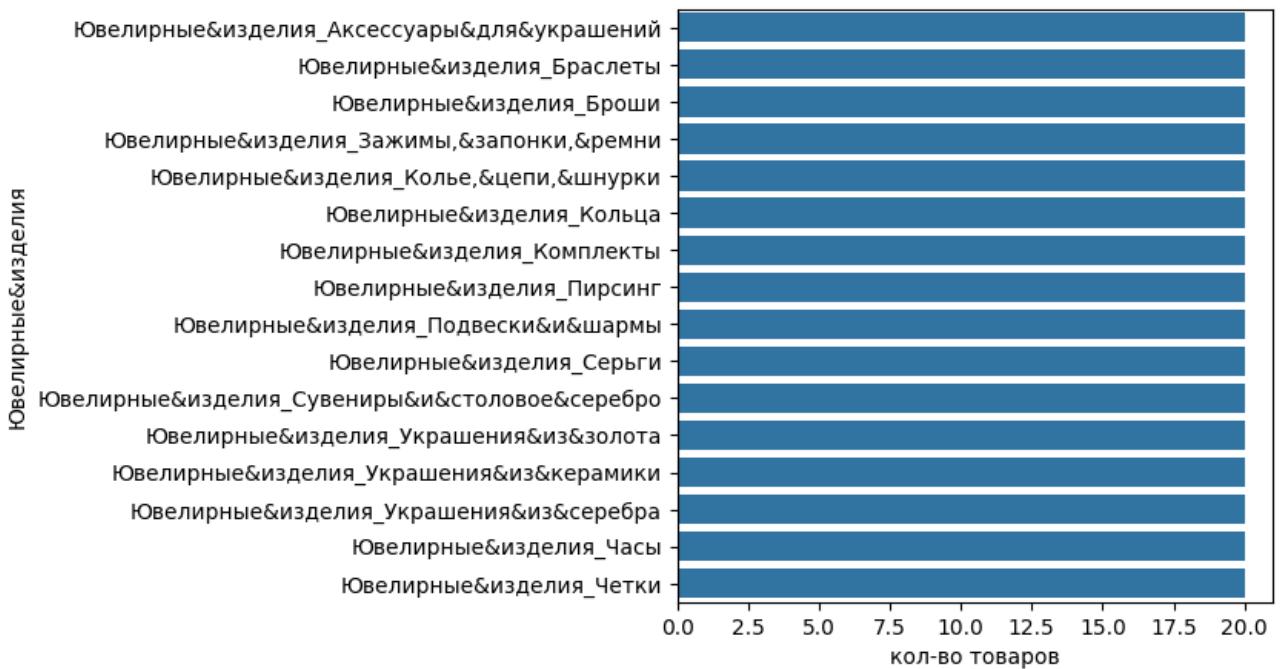


Рис. A.21: Распределение данных в категории «Ювелирные&изделия».

## B Приложение 2

PR кривые, построенные для каждой классификационной модели.

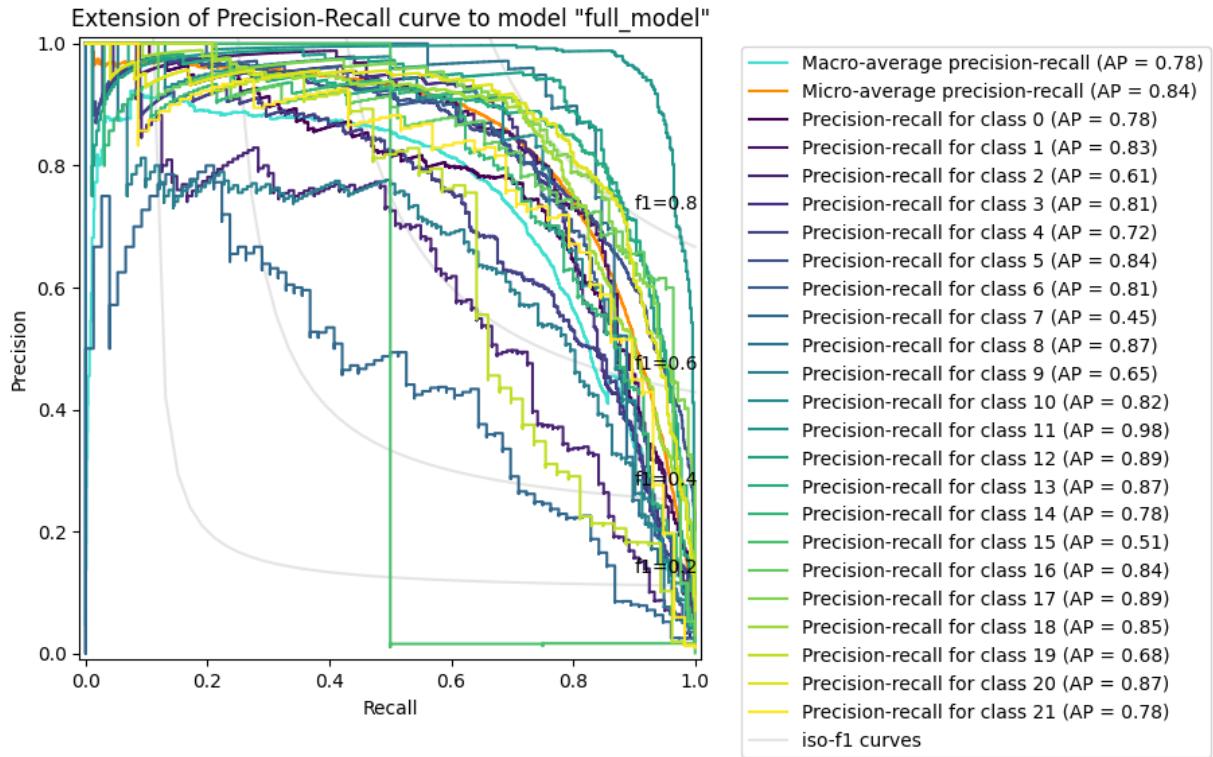


Рис. B.1: PR-curves для модели "full\_model".

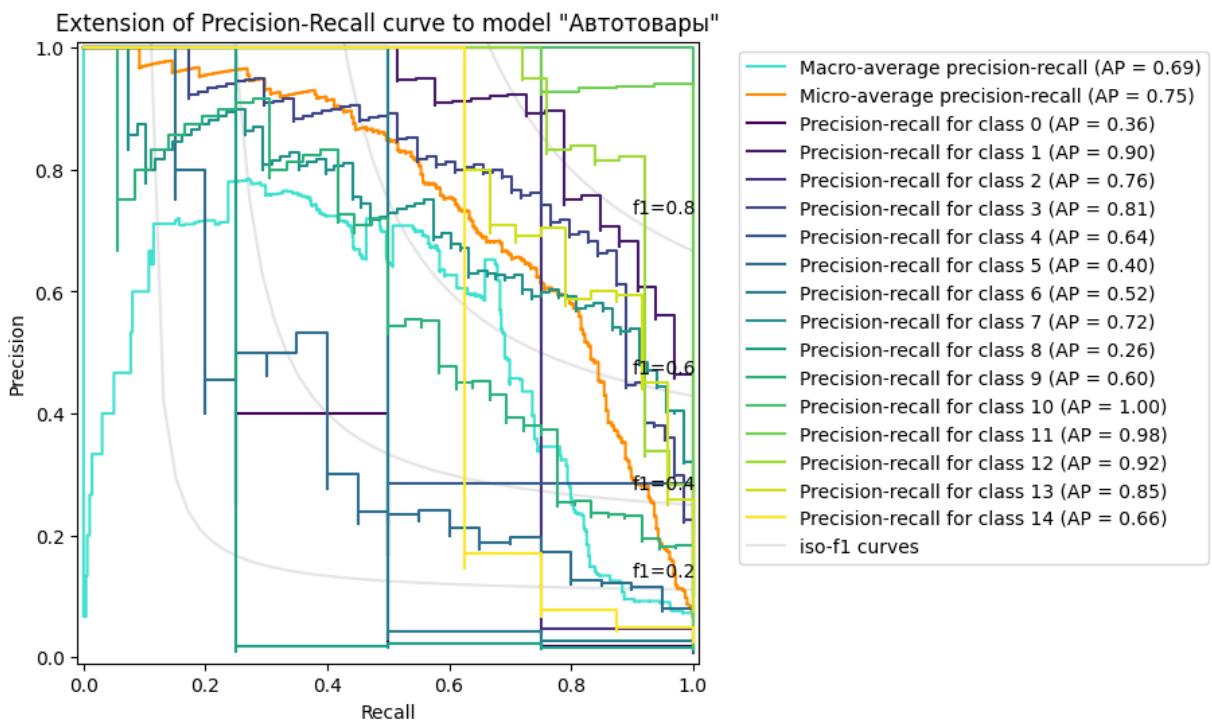


Рис. В.2: PR-curves для модели «Автотовары».

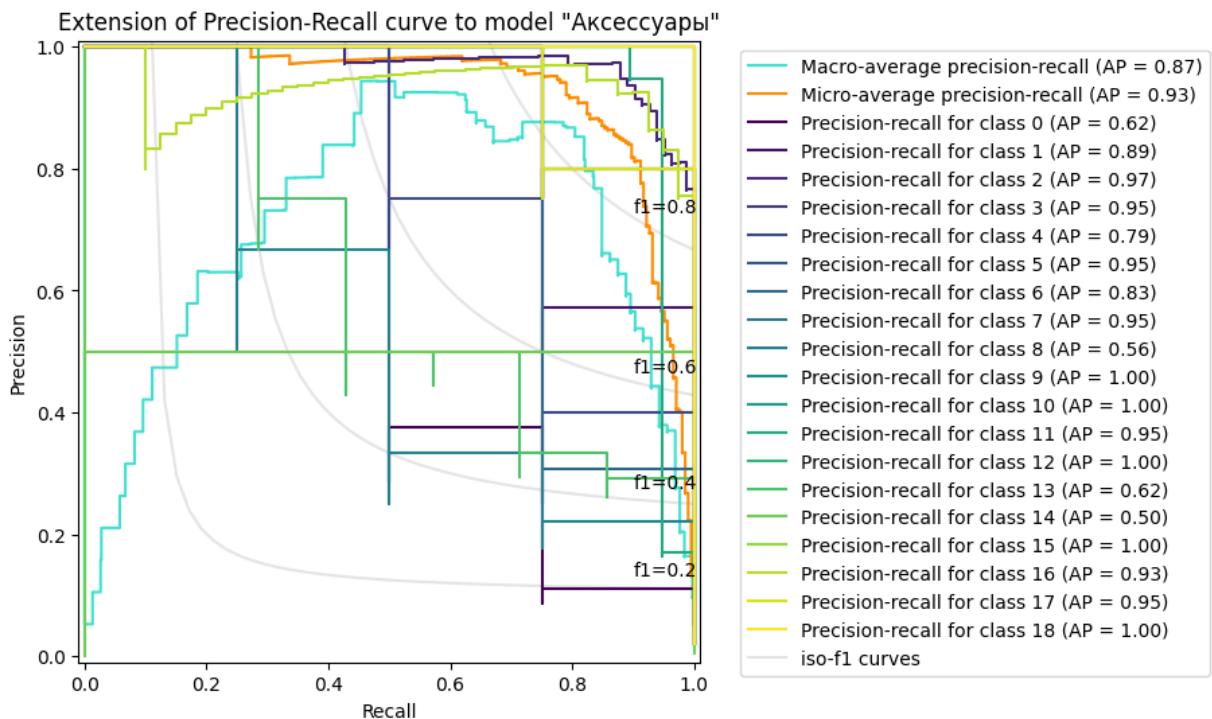


Рис. В.3: PR-curves для модели «Аксессуары».

Extension of Precision-Recall curve to model "Бытовая&техника"

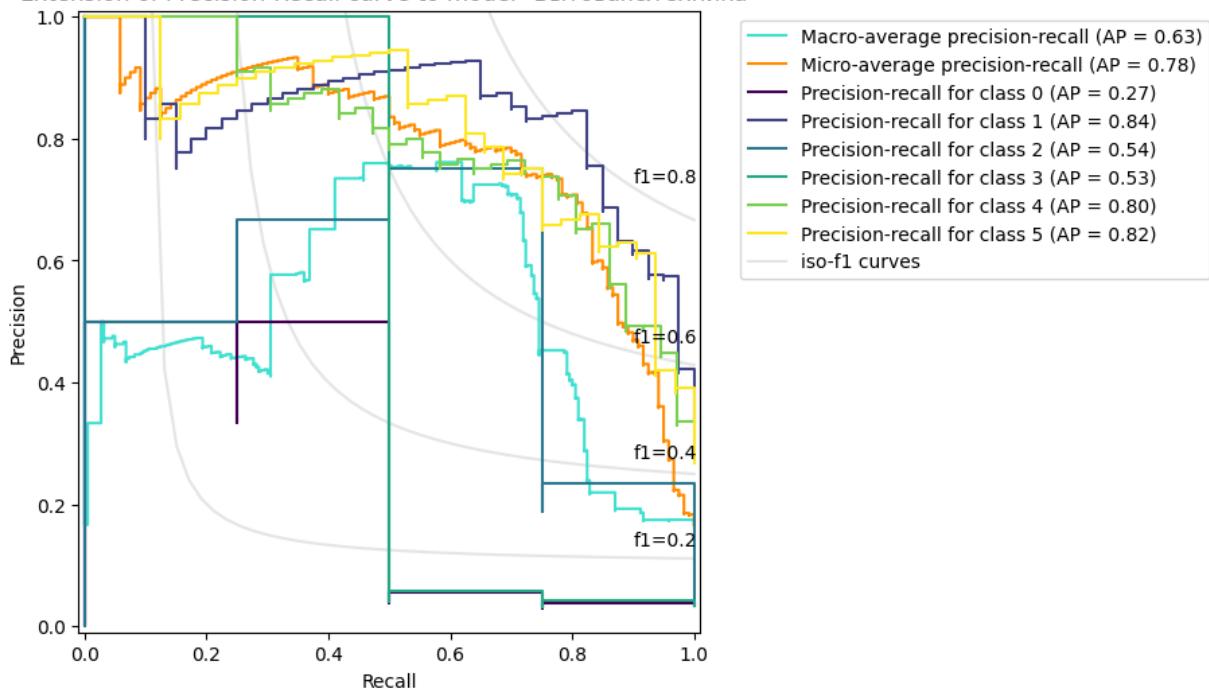


Рис. В.4: PR-curves для модели «Бытовая&техника».

Extension of Precision-Recall curve to model "Детям"

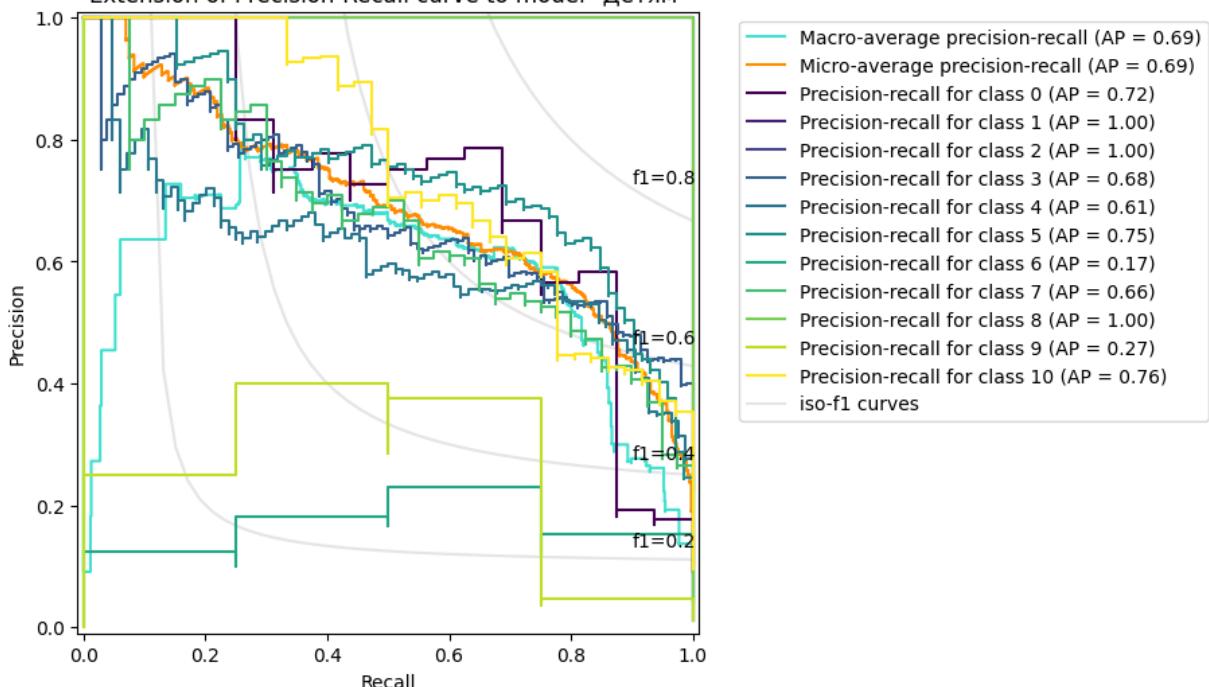


Рис. В.5: PR-curves для модели «Детям».

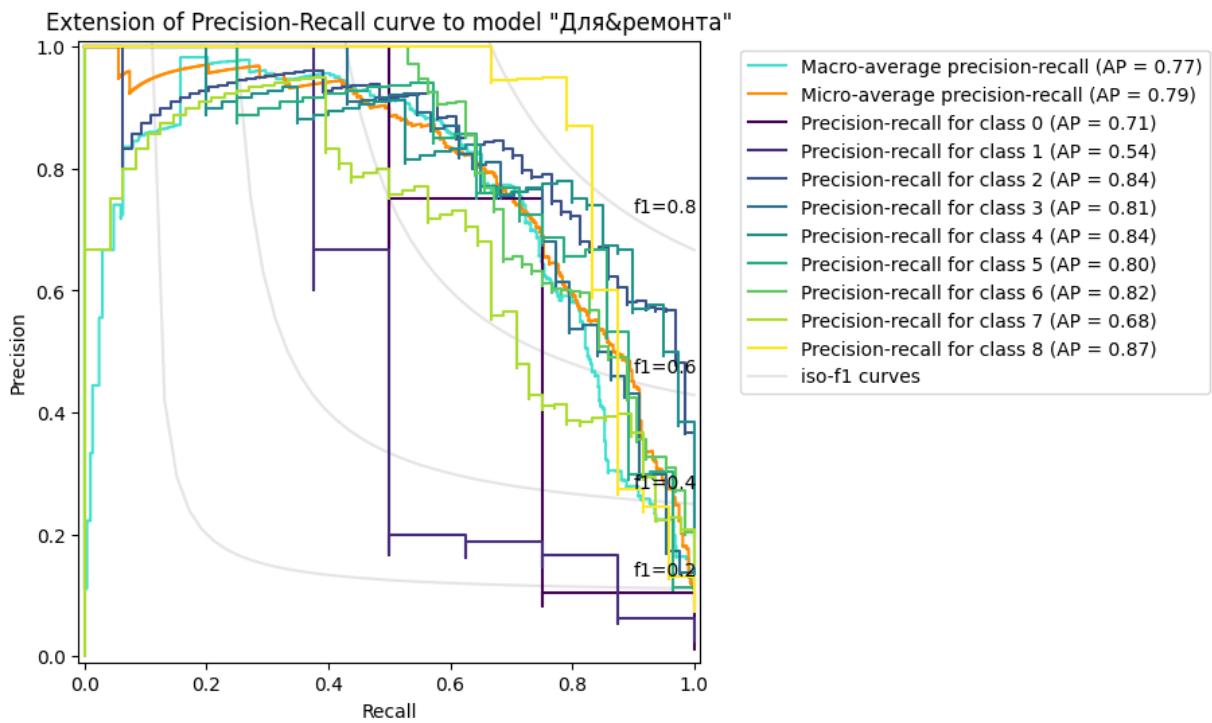


Рис. В.6: PR-curves для модели «Для&ремонта».

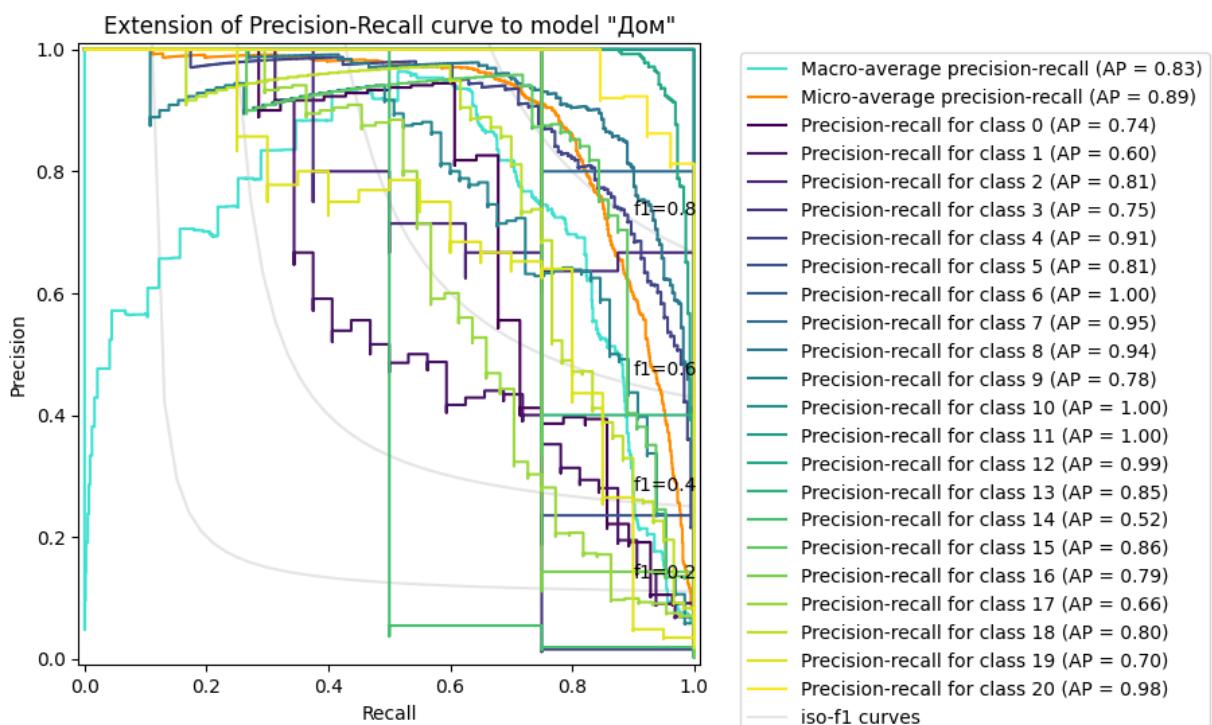


Рис. В.7: PR-curves для модели «Дом».

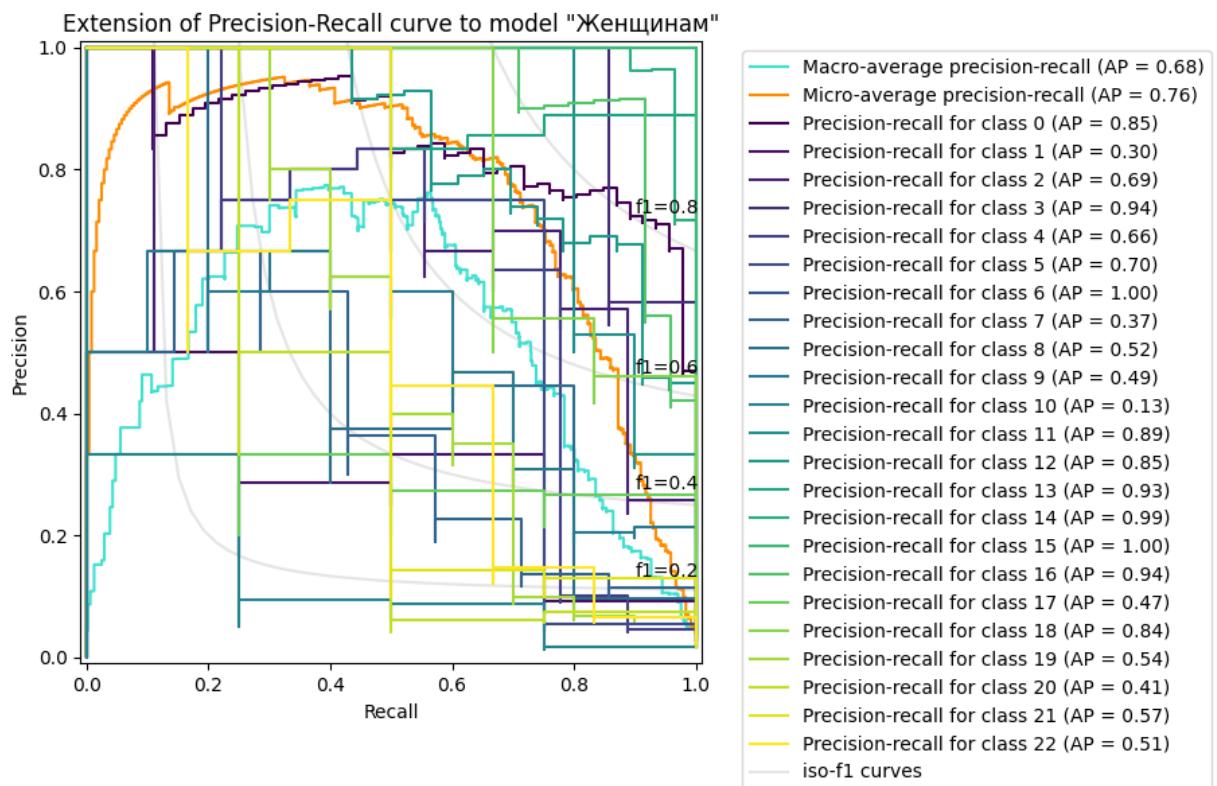


Рис. В.8: PR-curve для модели «Женщинам».

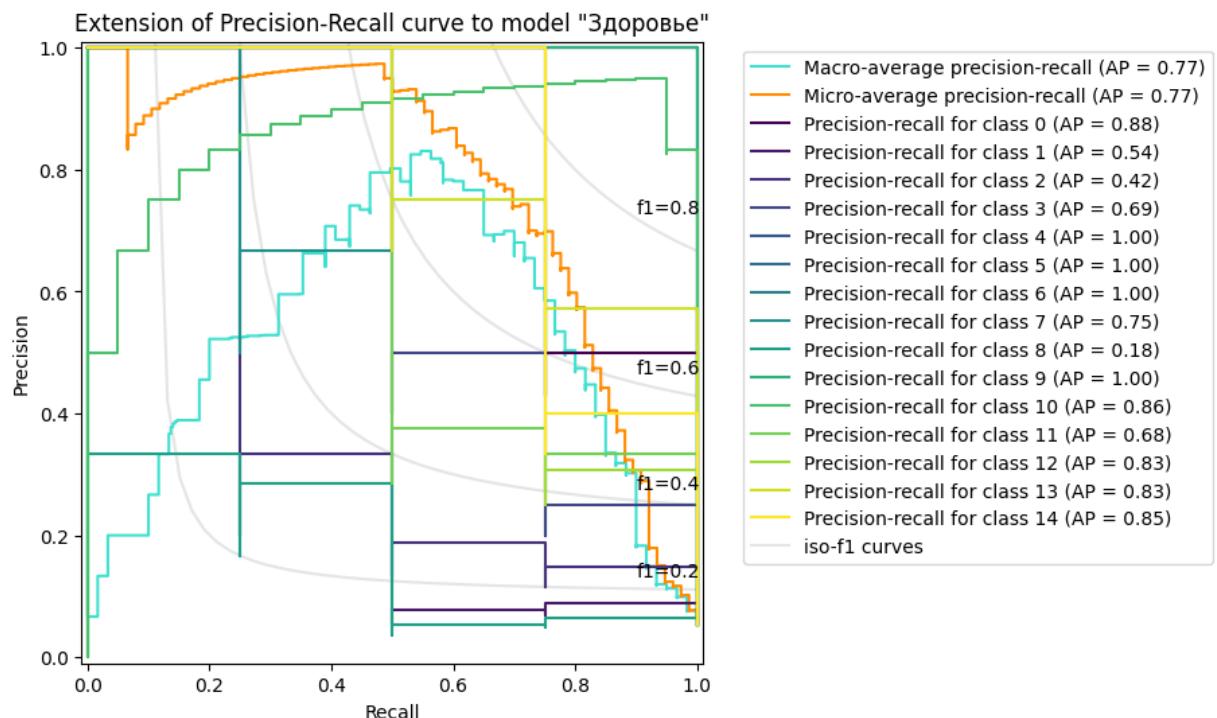


Рис. В.9: PR-curve для модели «Здоровье».

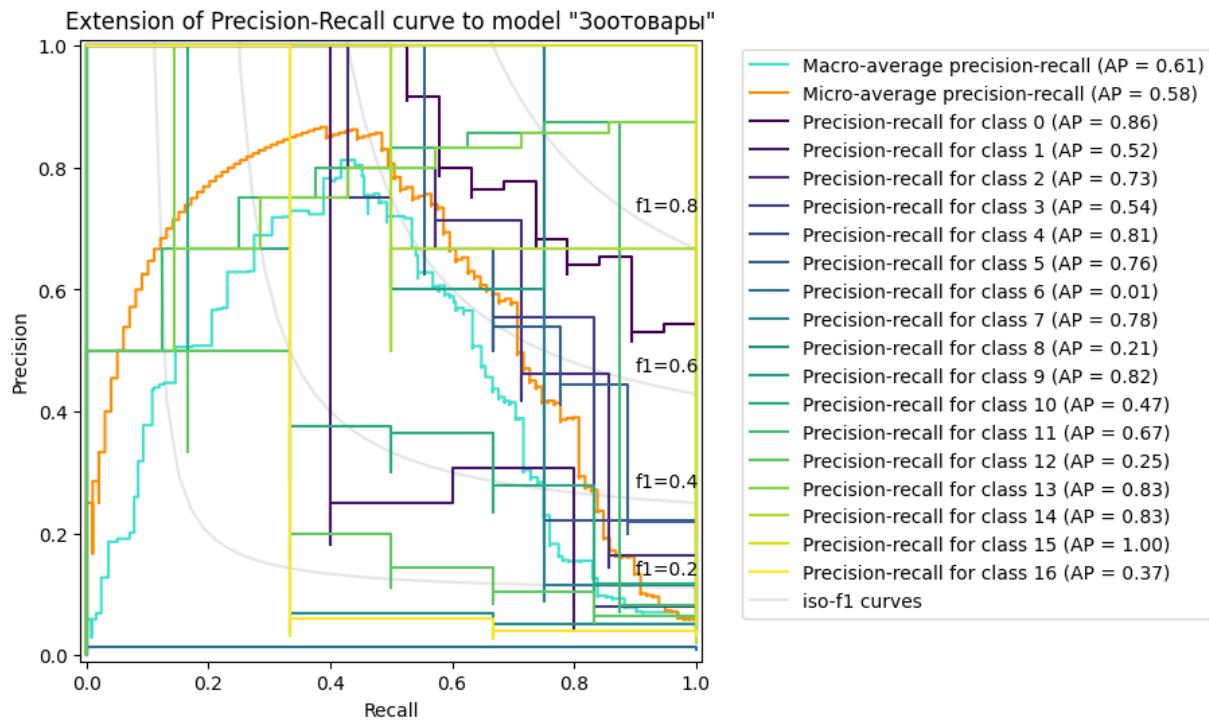


Рис. B.10: PR-curves для модели «Зоотовары».

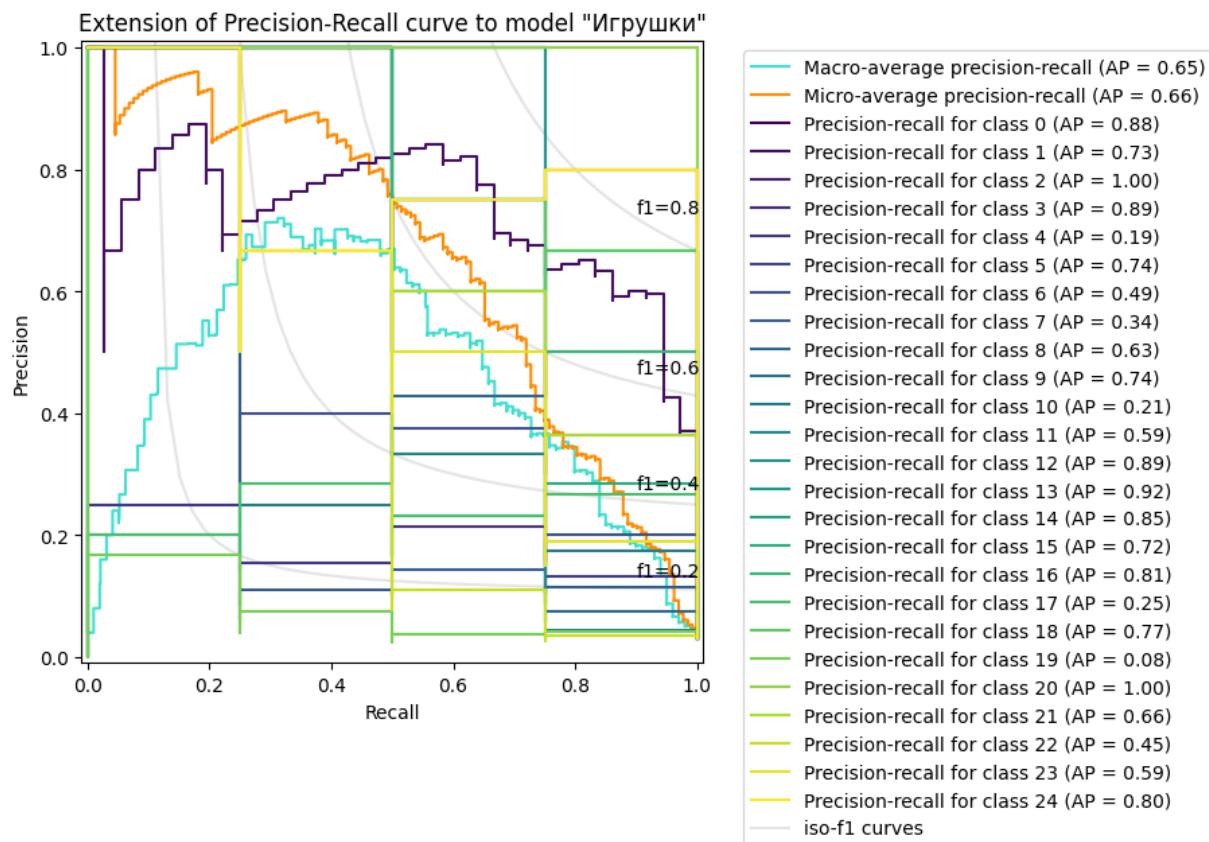


Рис. B.11: PR-curves для модели «Игрушки».

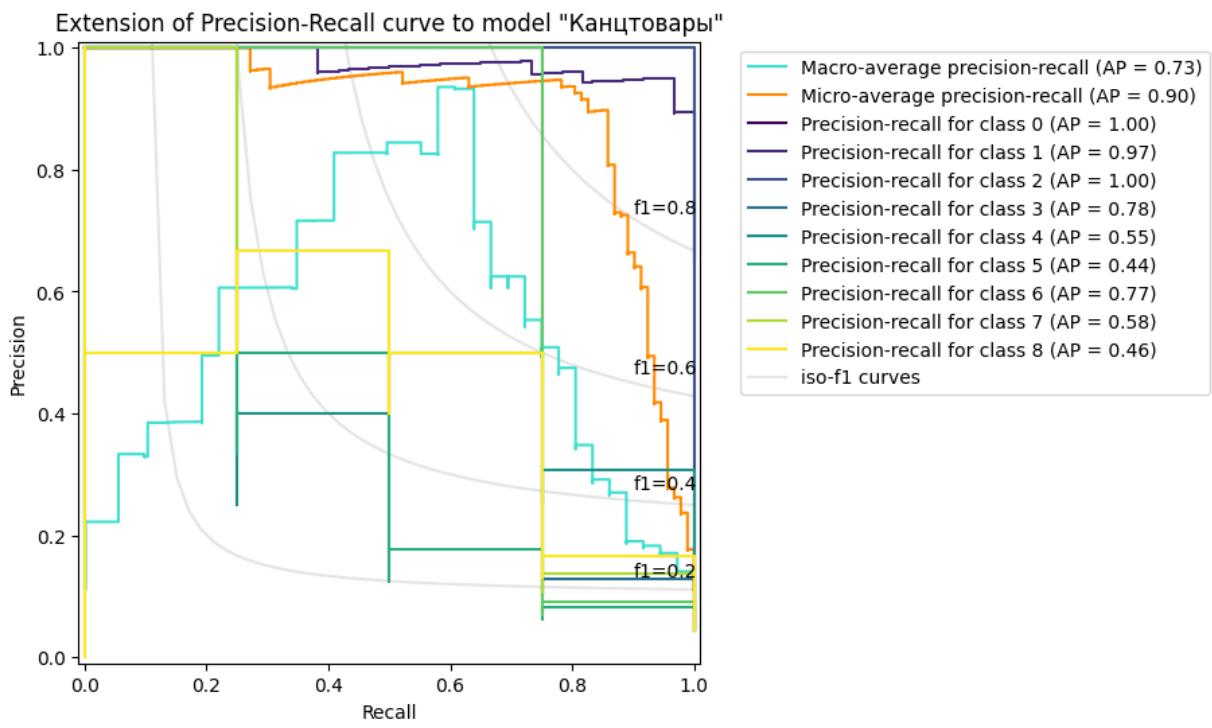


Рис. B.12: PR-curves для модели «Канцтовары».

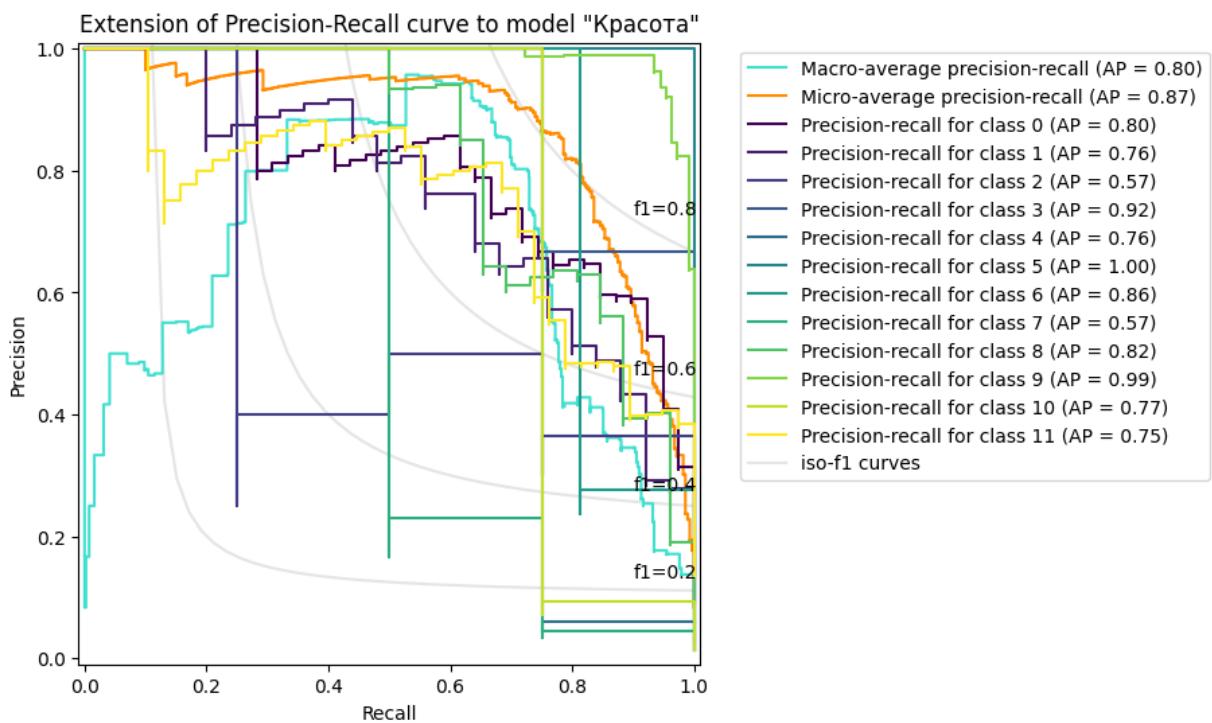


Рис. B.13: PR-curves для модели «Красота».

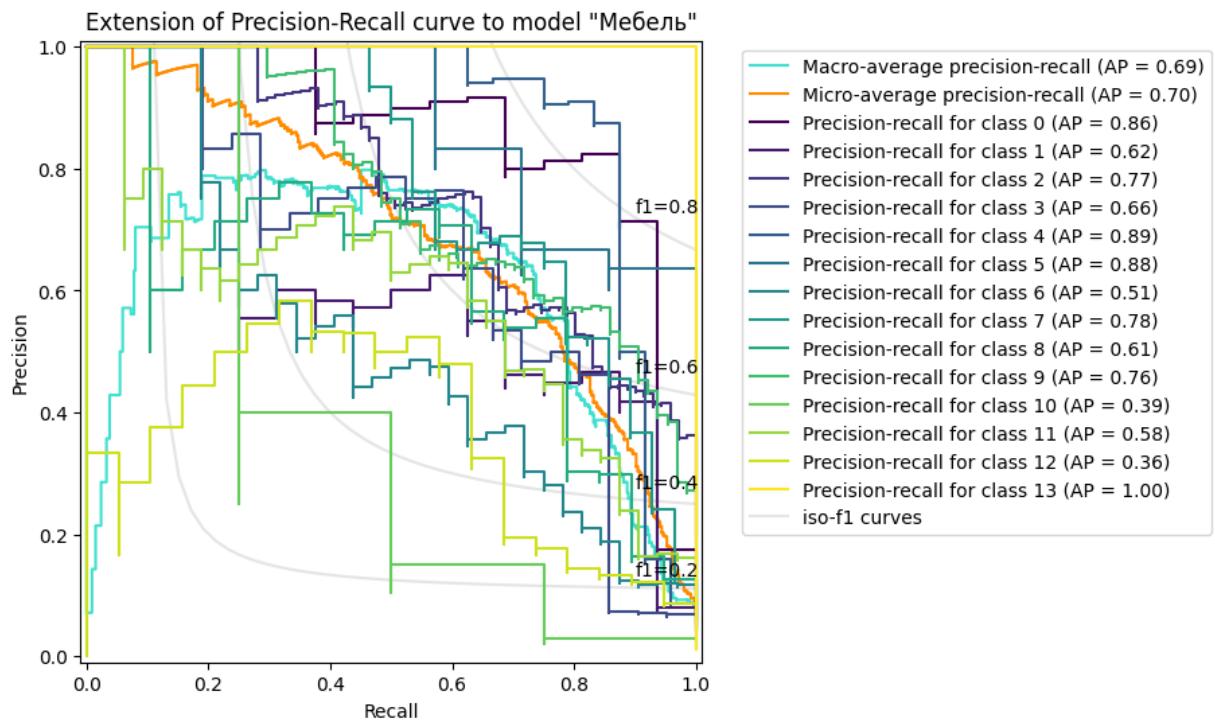


Рис. В.14: PR-curves для модели «Мебель».

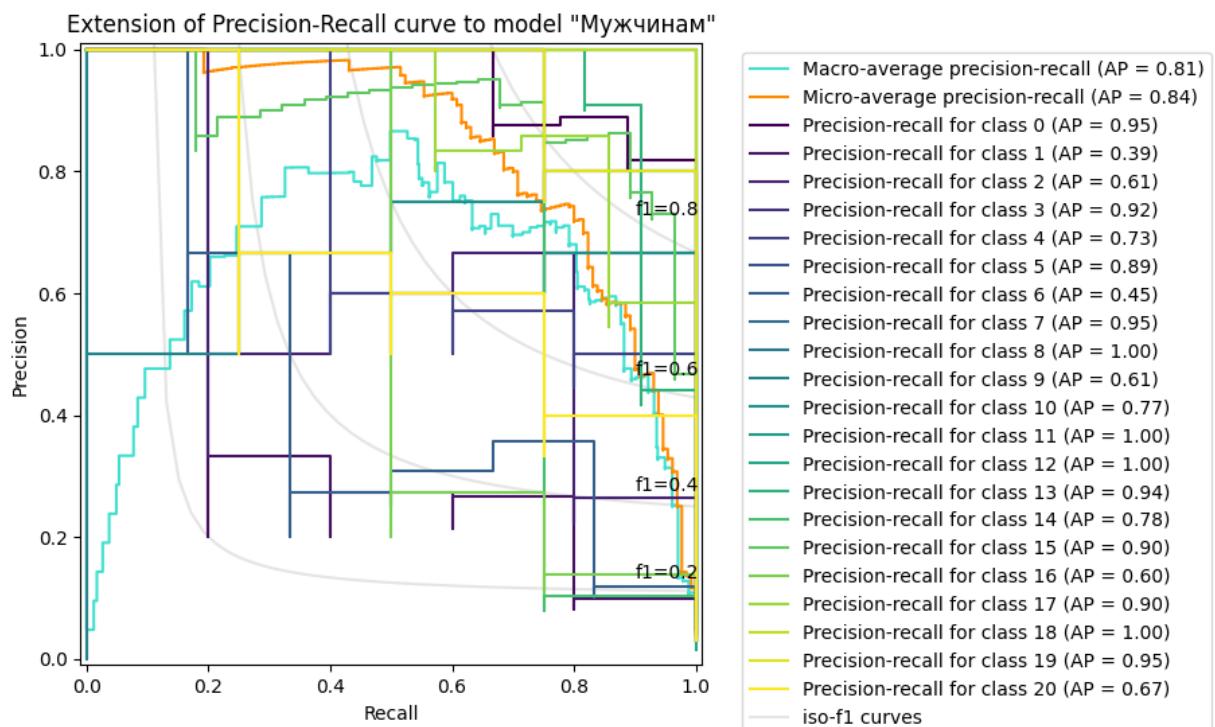


Рис. В.15: PR-curves для модели «Мужчинам».

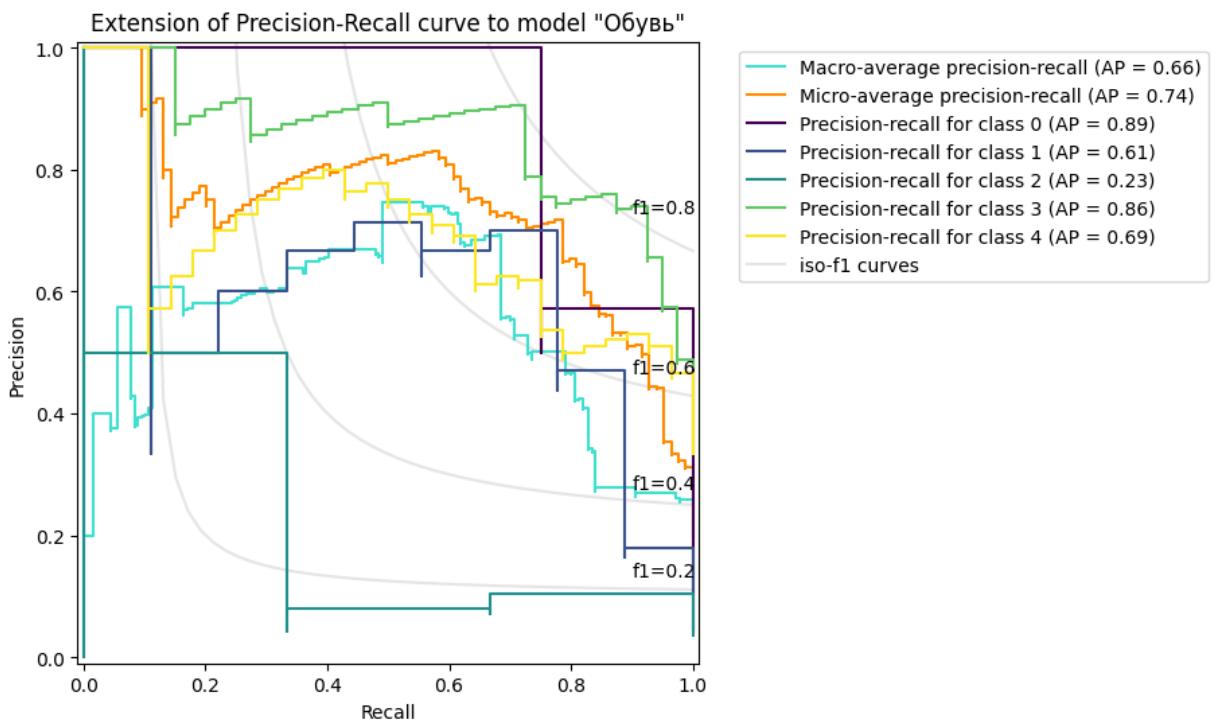


Рис. В.16: PR-curves для модели «Обувь».

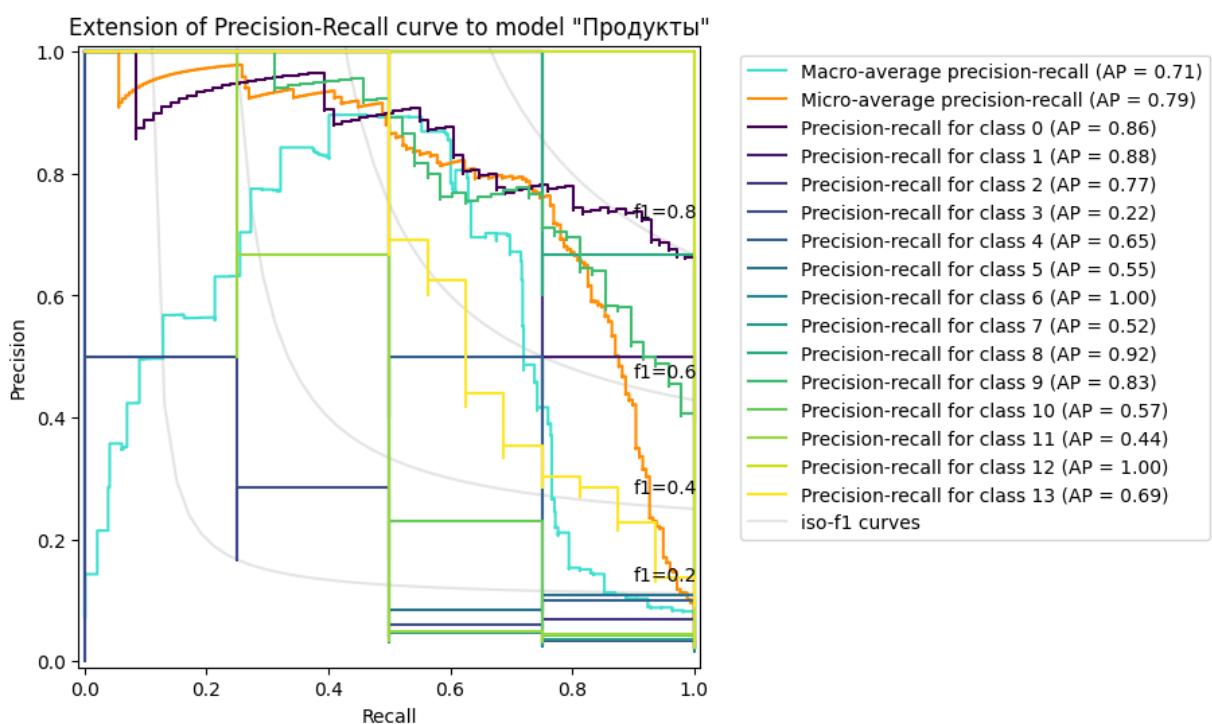


Рис. В.17: PR-curves для модели «Продукты».

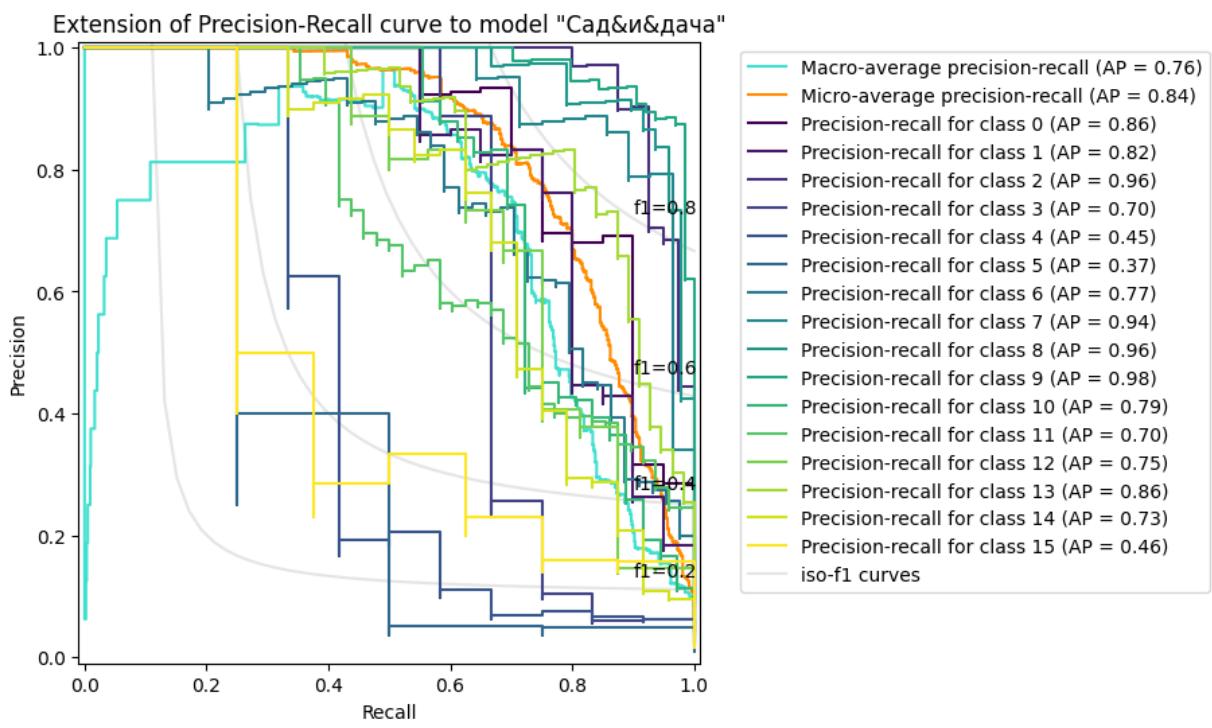


Рис. B.18: PR-curves для модели «Сад&и&дача».

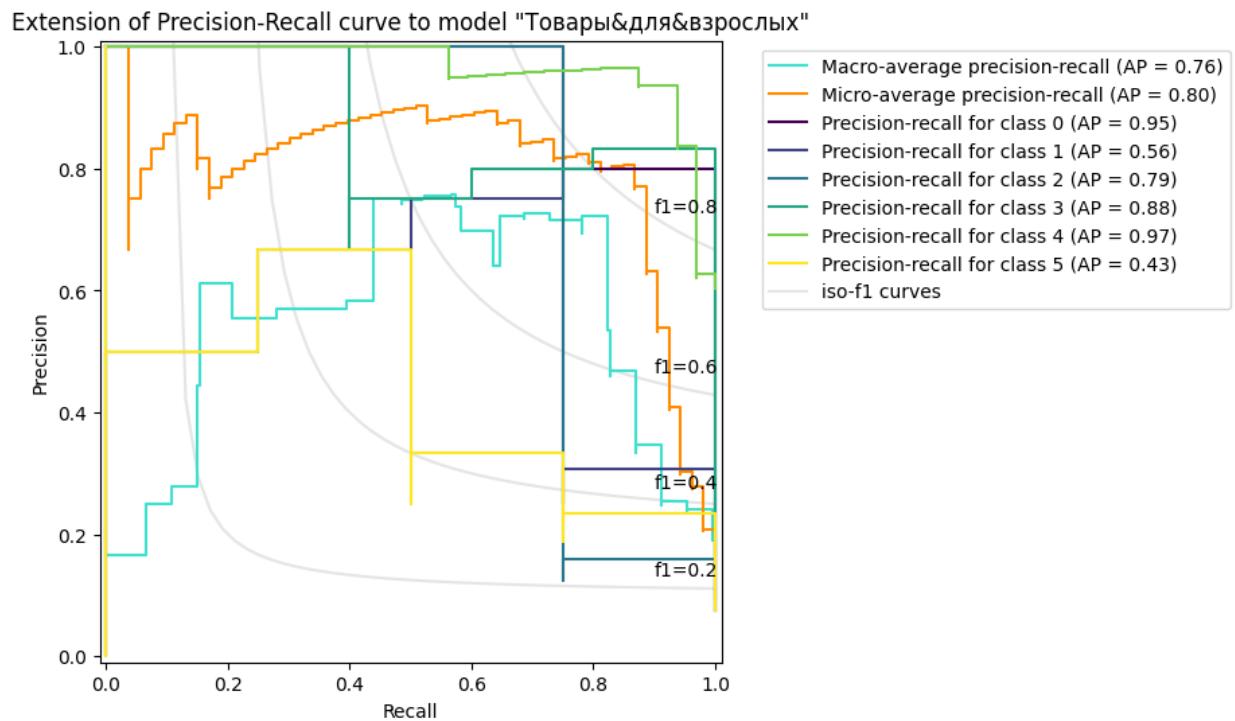


Рис. B.19: PR-curves для модели «Товары&для&взрослых».

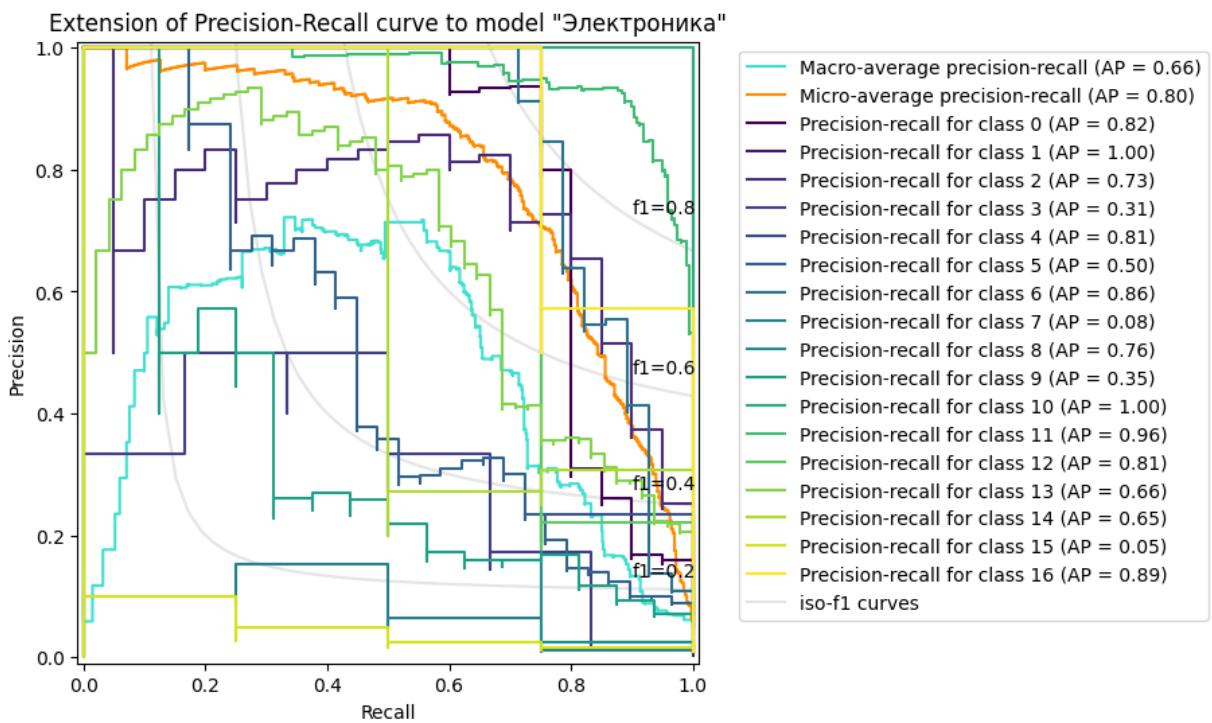


Рис. B.20: PR-curves для модели «Электроника».

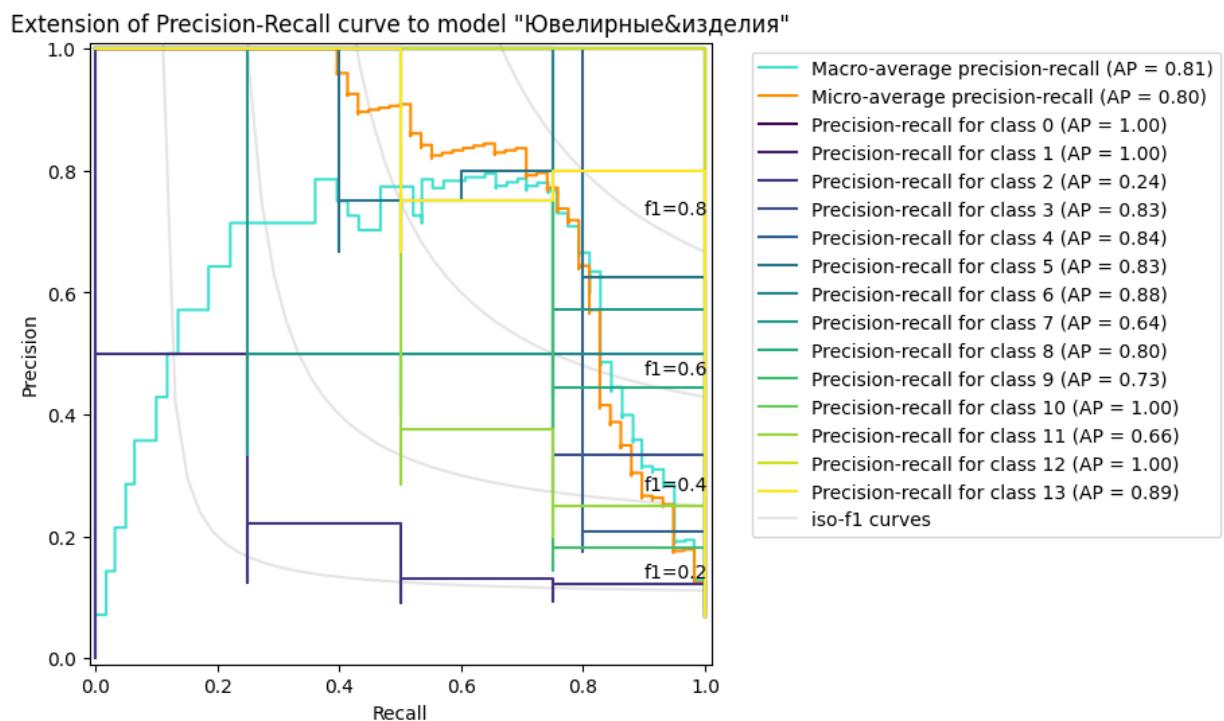


Рис. B.21: PR-curves для модели «Ювелирные&изделия».

## C Приложение 3

ROC кривые, построенные для каждой классификационной модели.

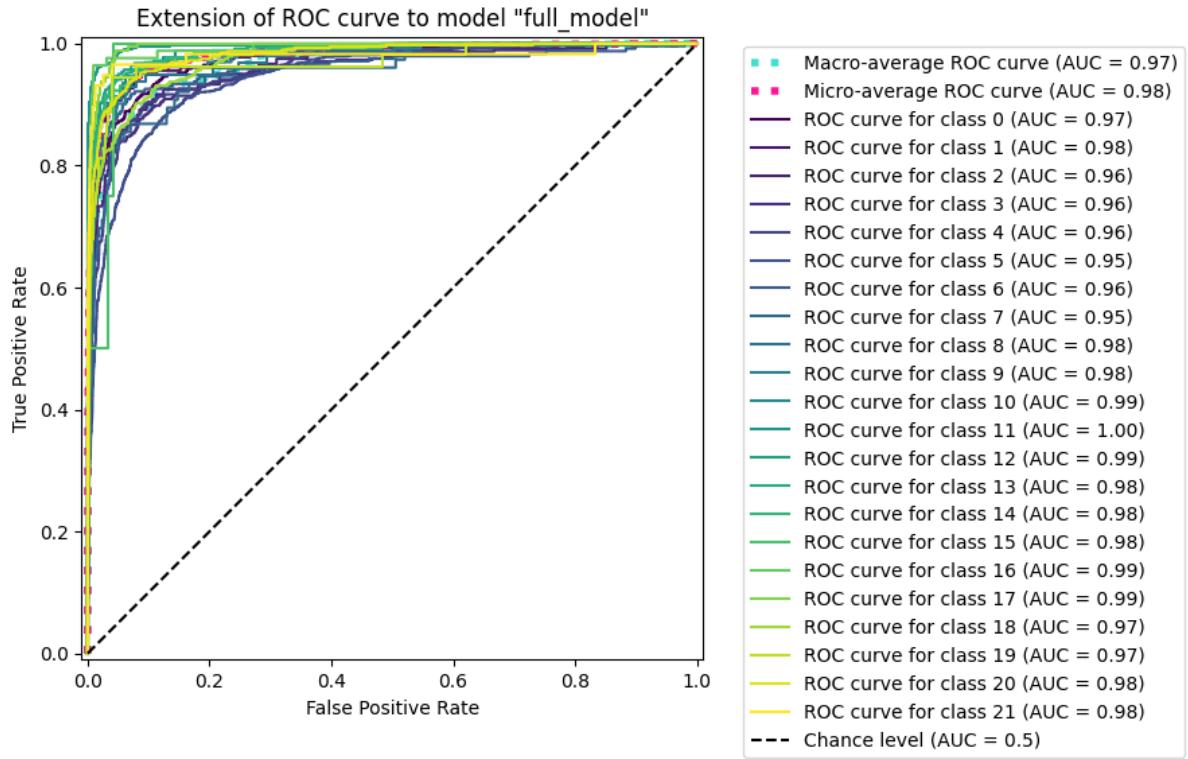


Рис. C.1: ROC-curves для модели "full\_model".

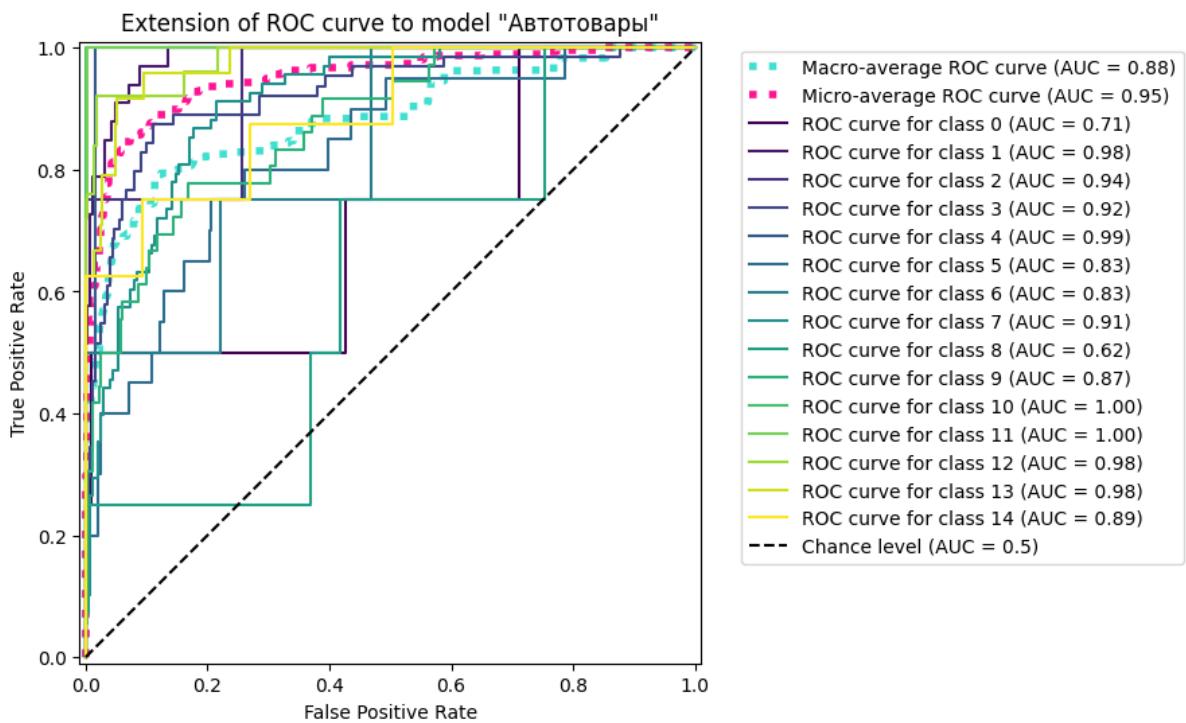


Рис. С.2: ROC-curves для модели «Автотовары».

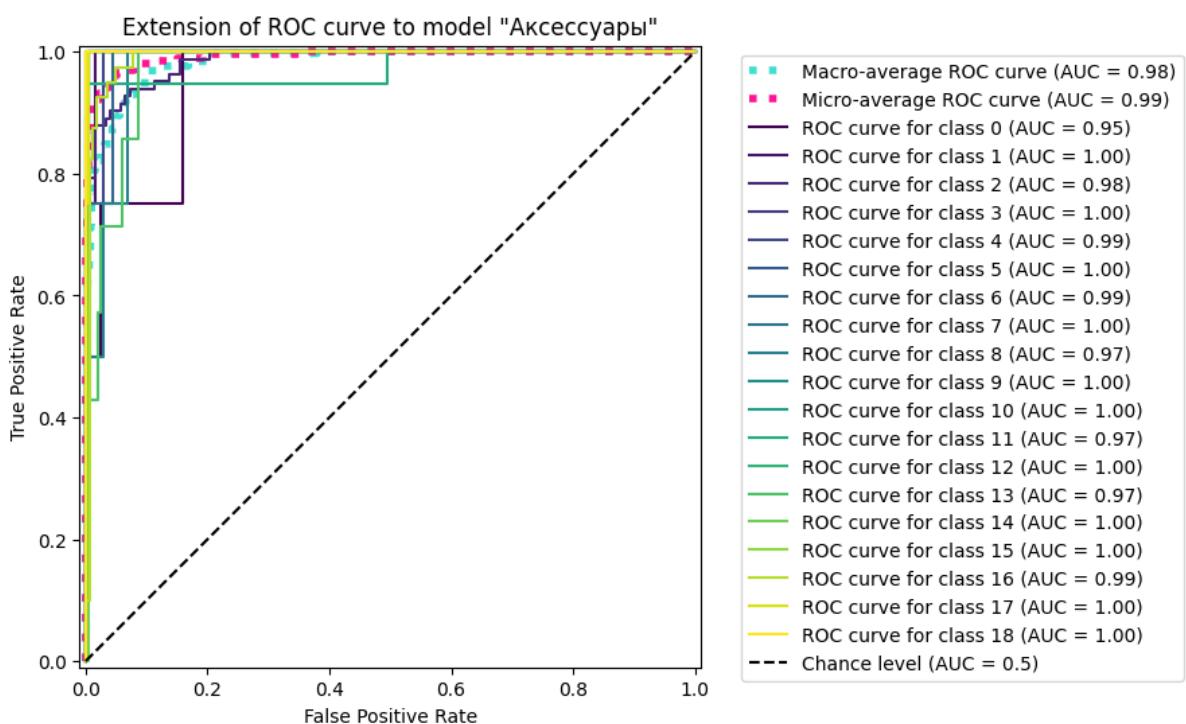


Рис. С.3: ROC-curves для модели «Аксессуары».

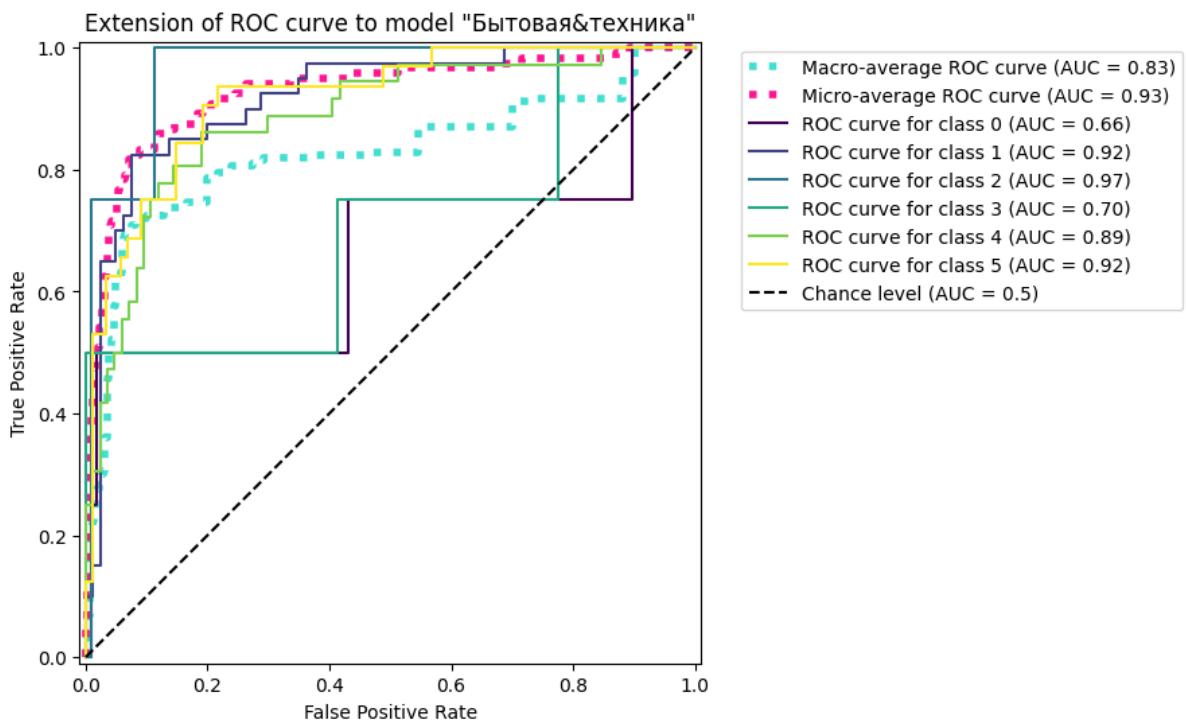


Рис. С.4: ROC-curves для модели «Бытовая&техника».

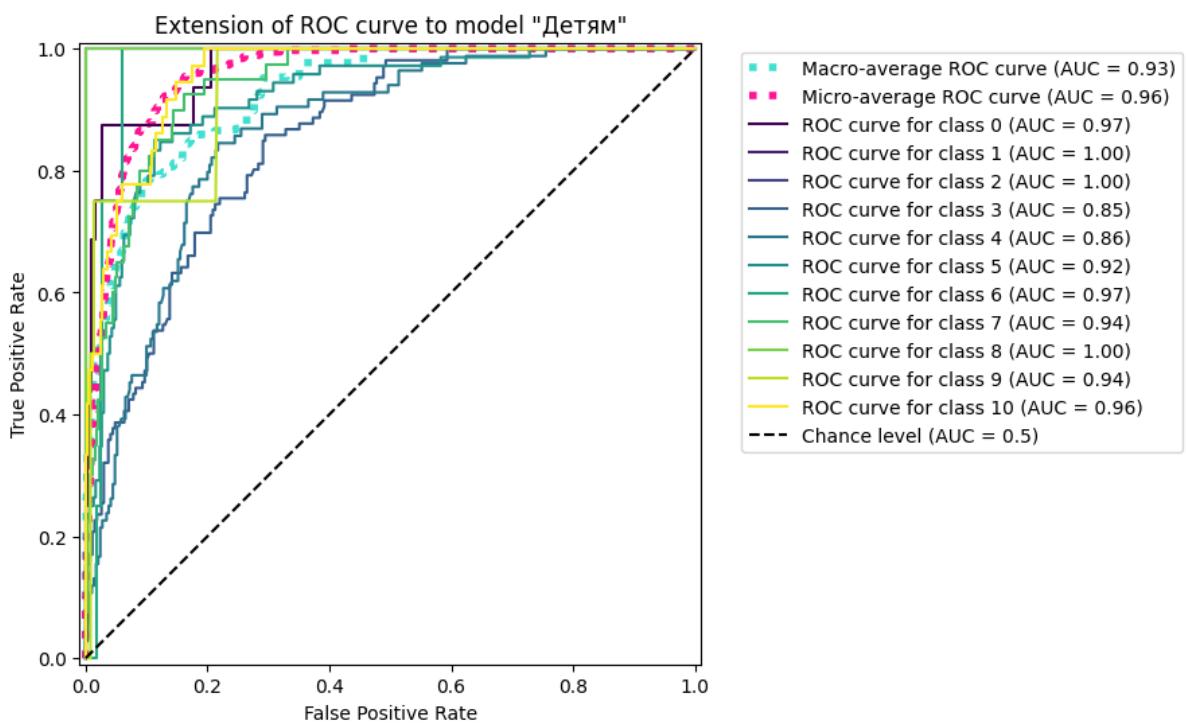


Рис. С.5: ROC-curves для модели «Детям».

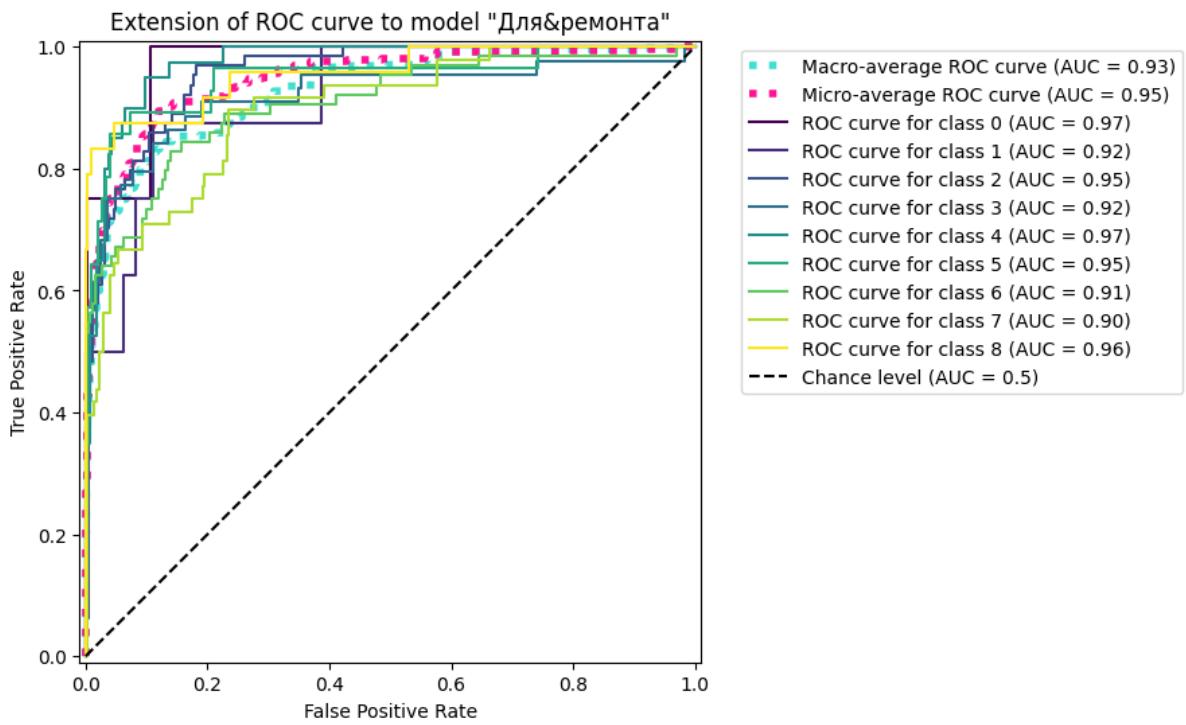


Рис. С.6: ROC-curve для модели «Для&ремонта».

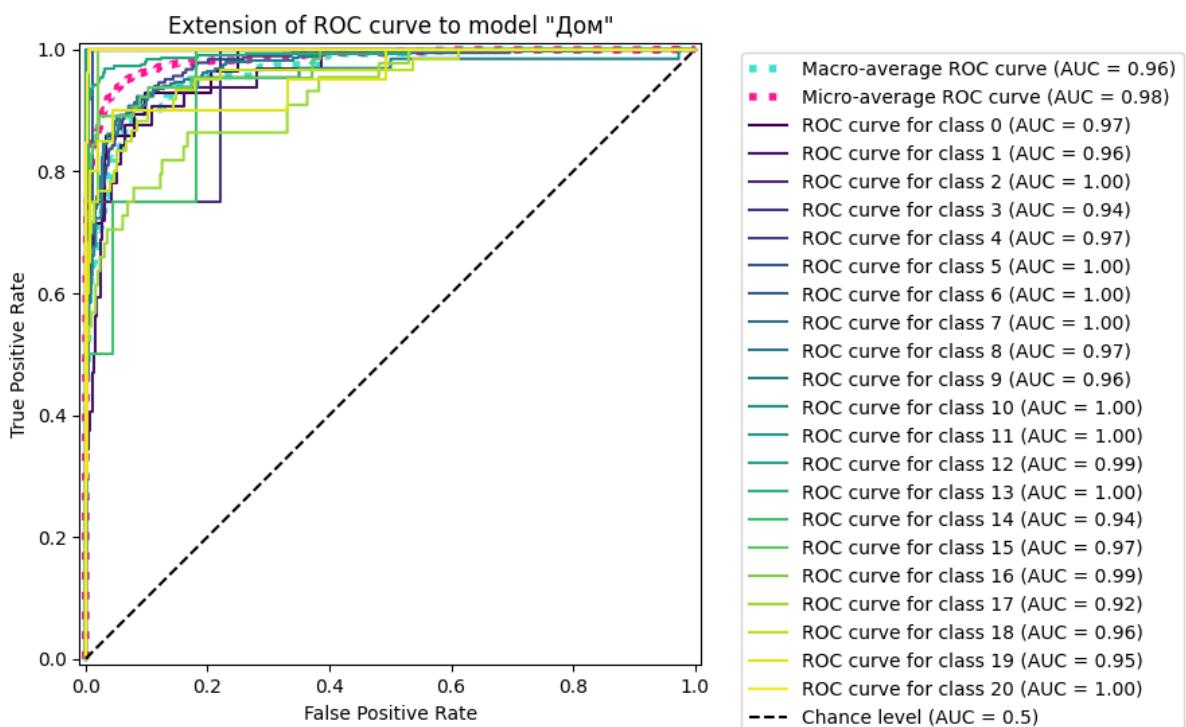


Рис. С.7: ROC-curves для модели «Дом».

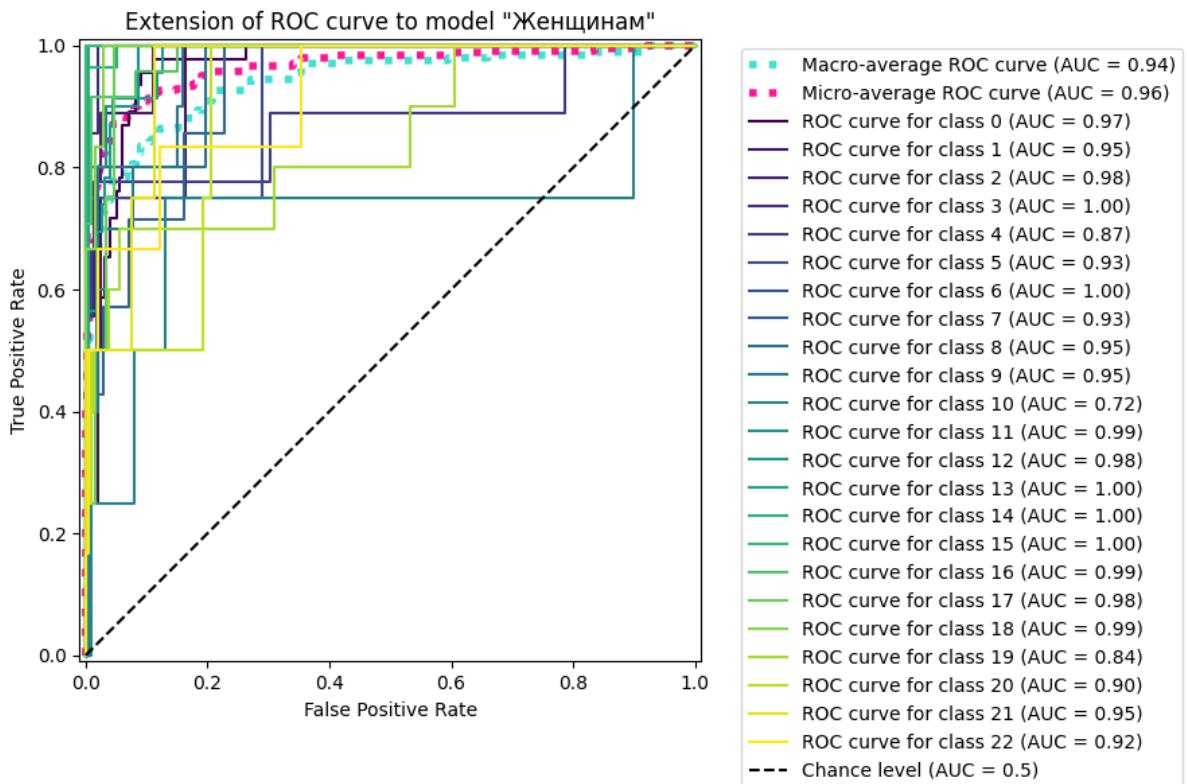


Рис. С.8: ROC-curve для модели «Женщинам».

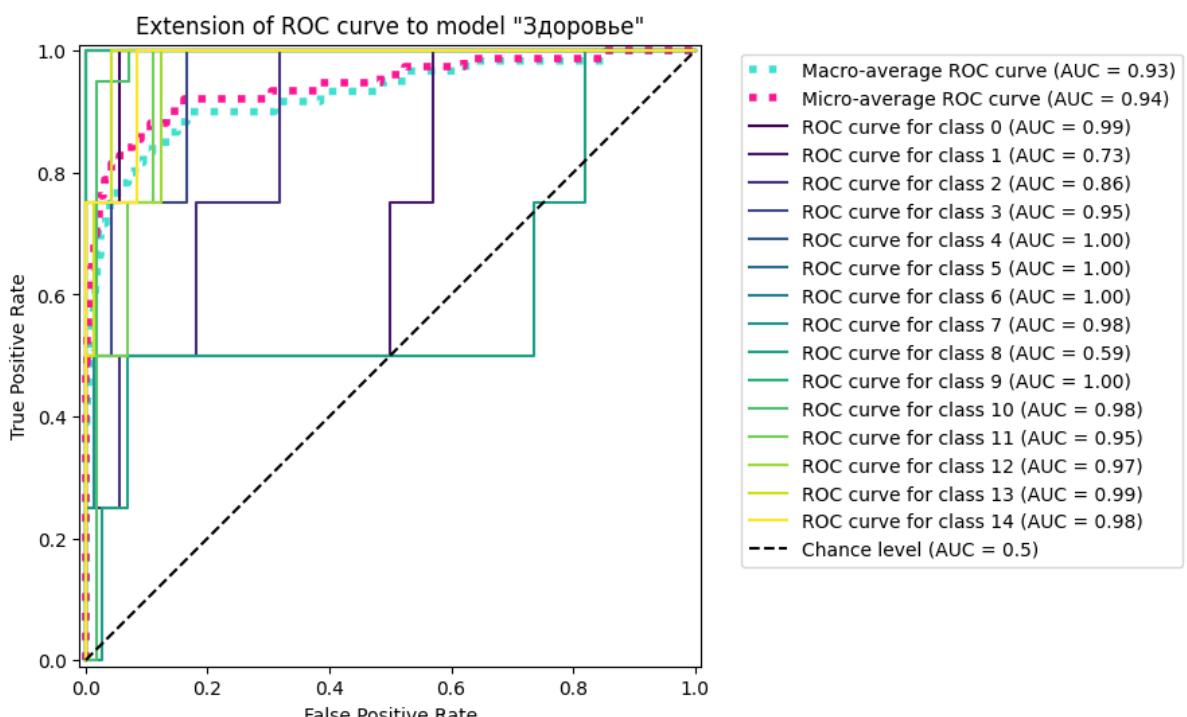


Рис. С.9: ROC-curves для модели «Здоровье».

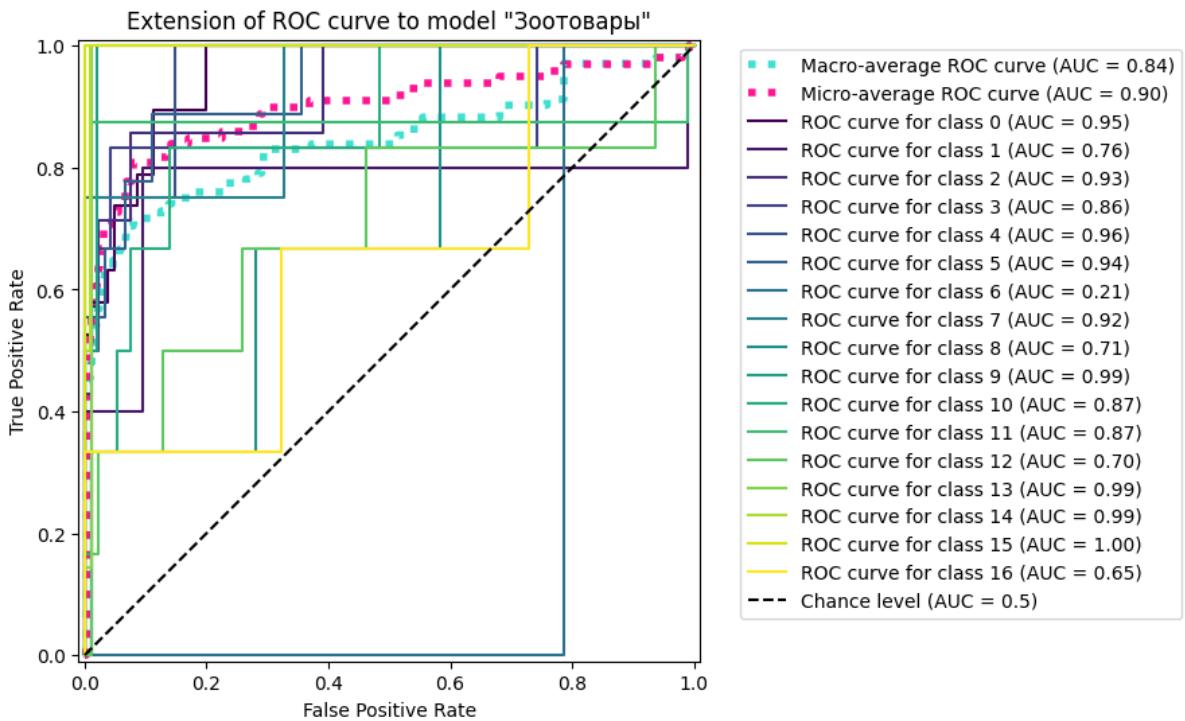


Рис. С.10: ROC-curves для модели «Зоотовары».

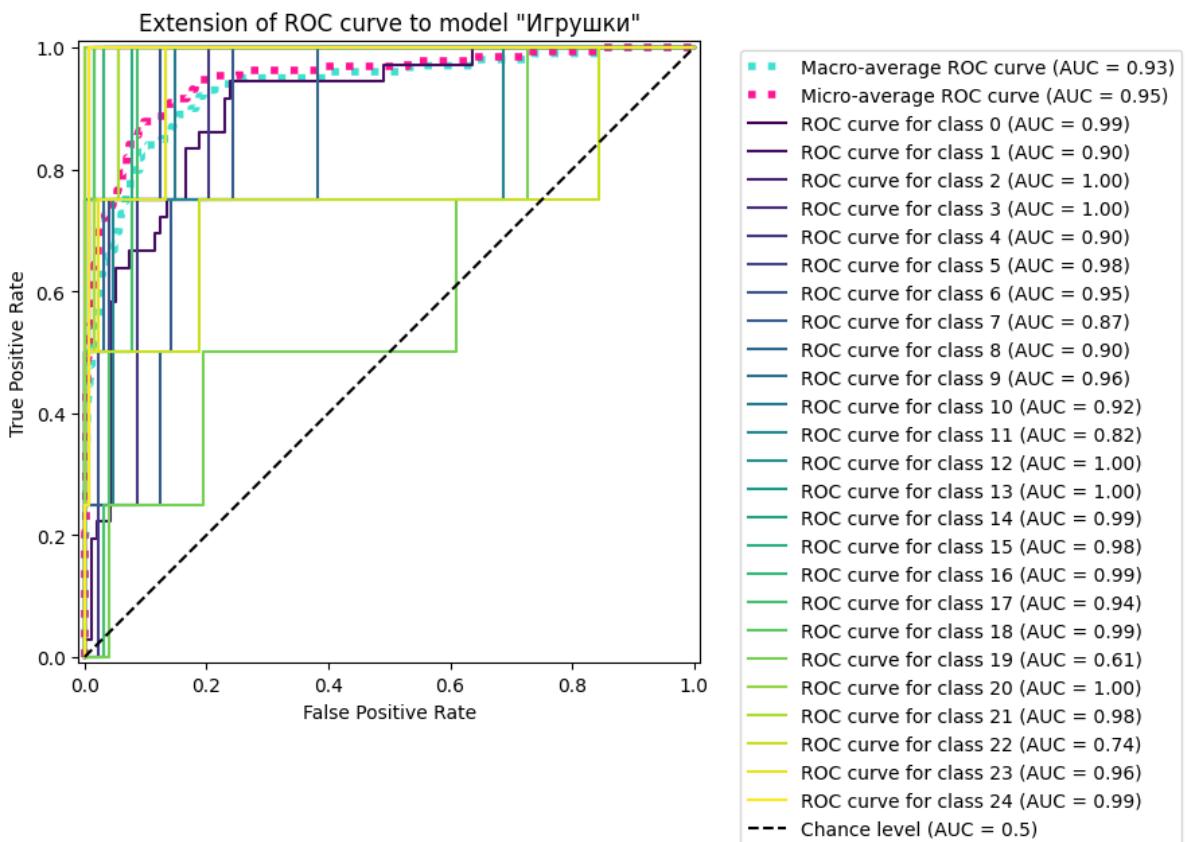


Рис. С.11: ROC-curve для модели «Игрушки».

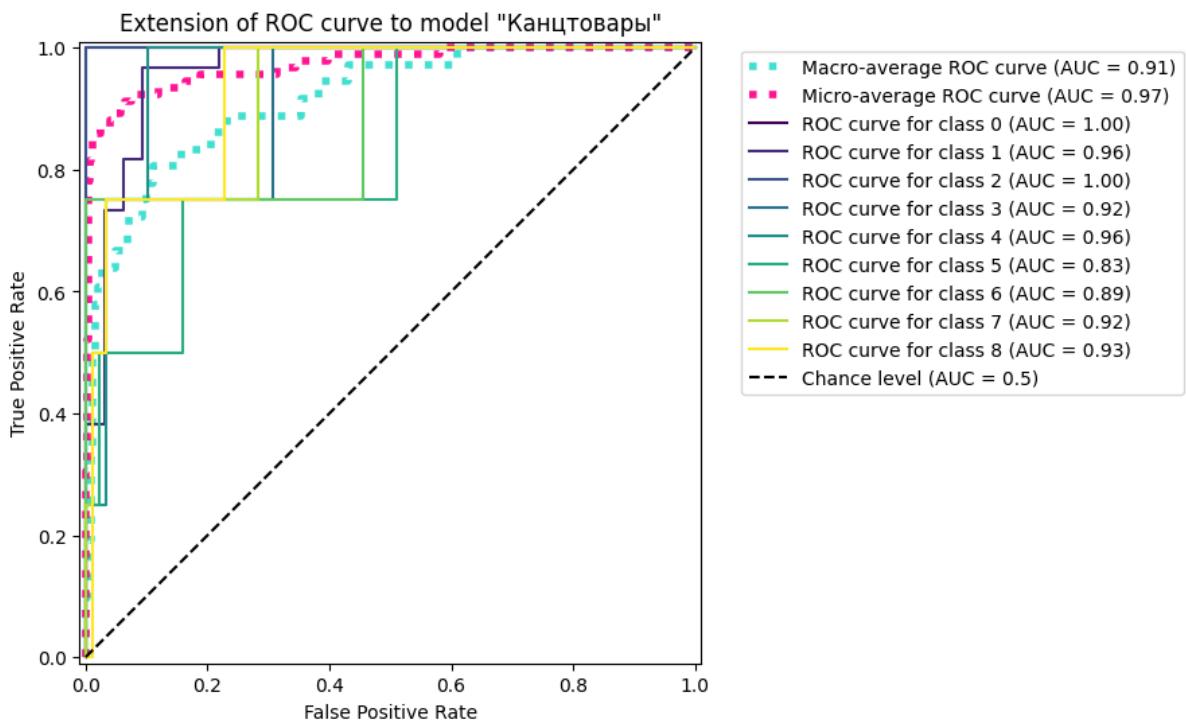


Рис. С.12: ROC-curves для модели «Канцтовары».

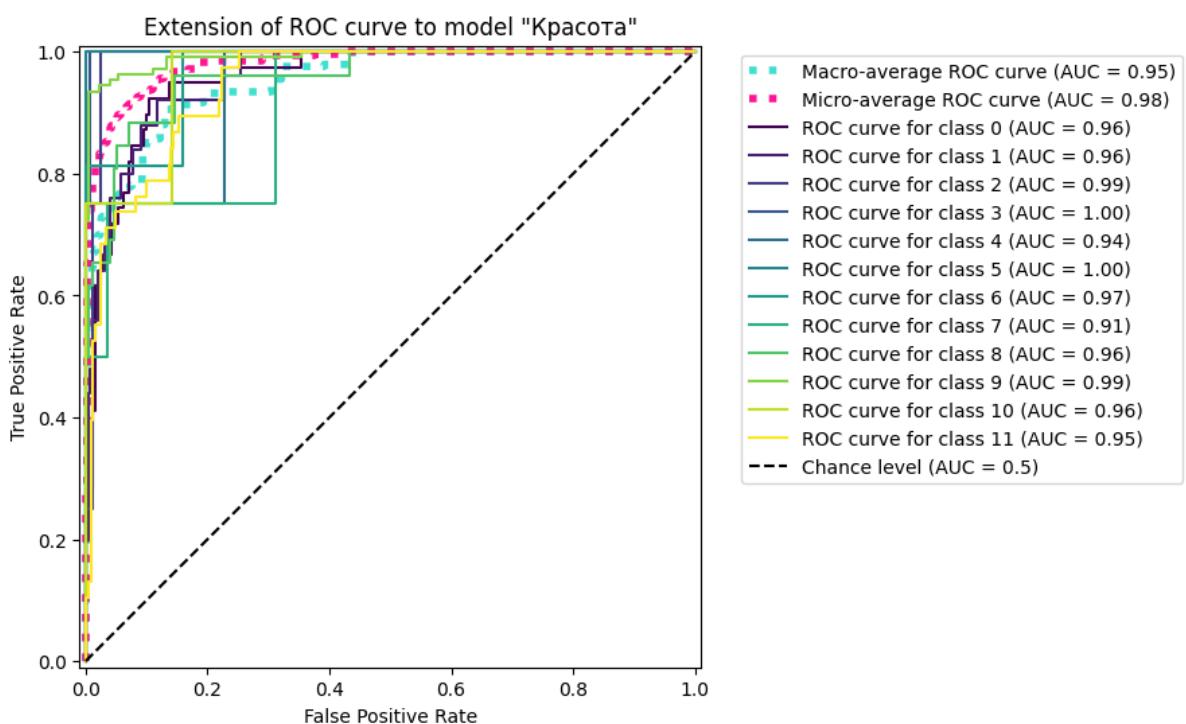


Рис. С.13: ROC-curves для модели «Красота».

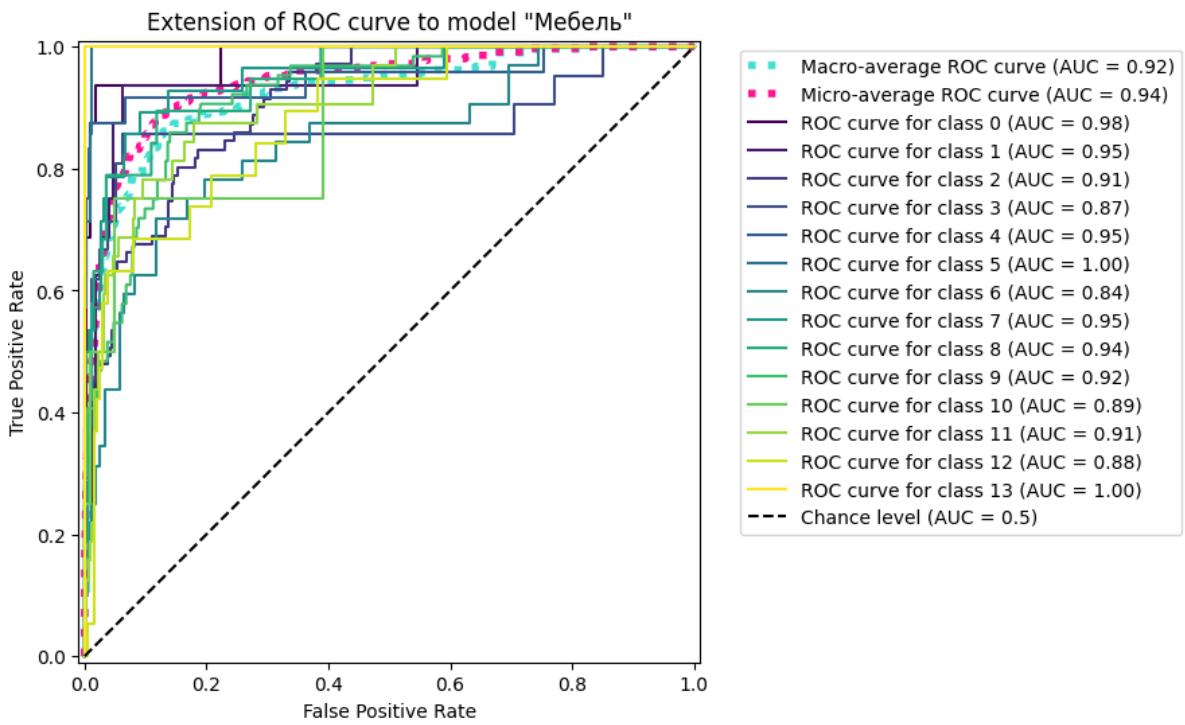


Рис. С.14: ROC-curves для модели «Мебель».

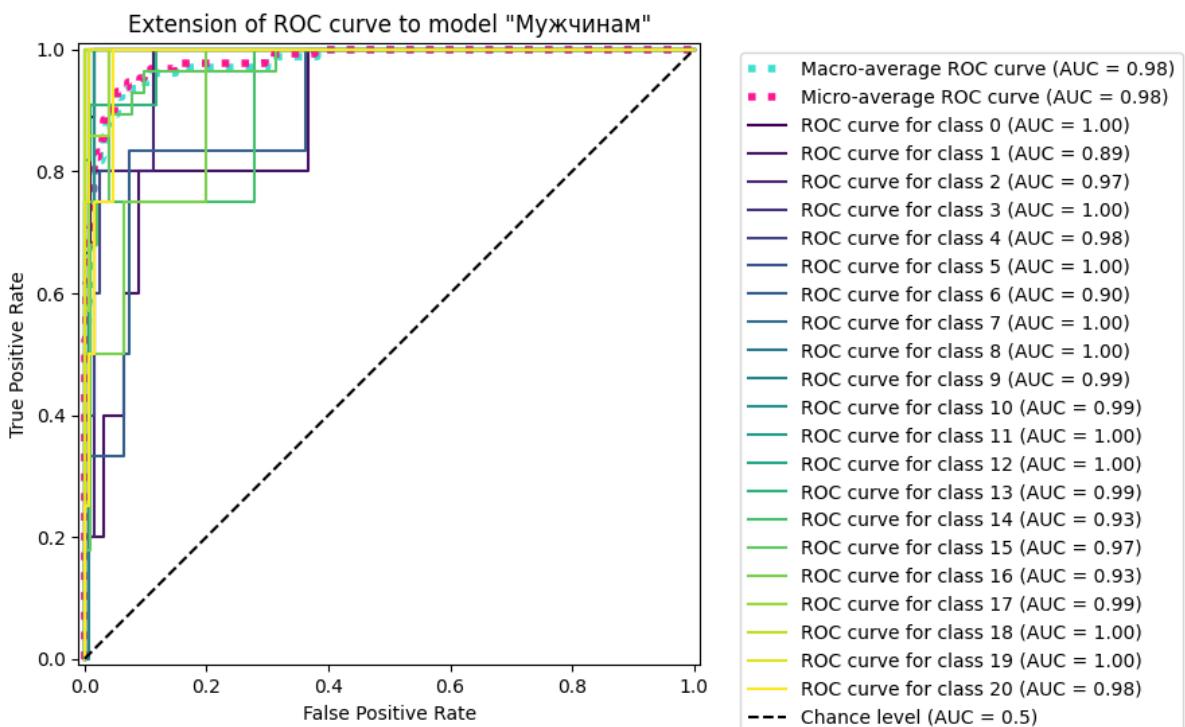


Рис. С.15: ROC-curves для модели «Мужчинам».

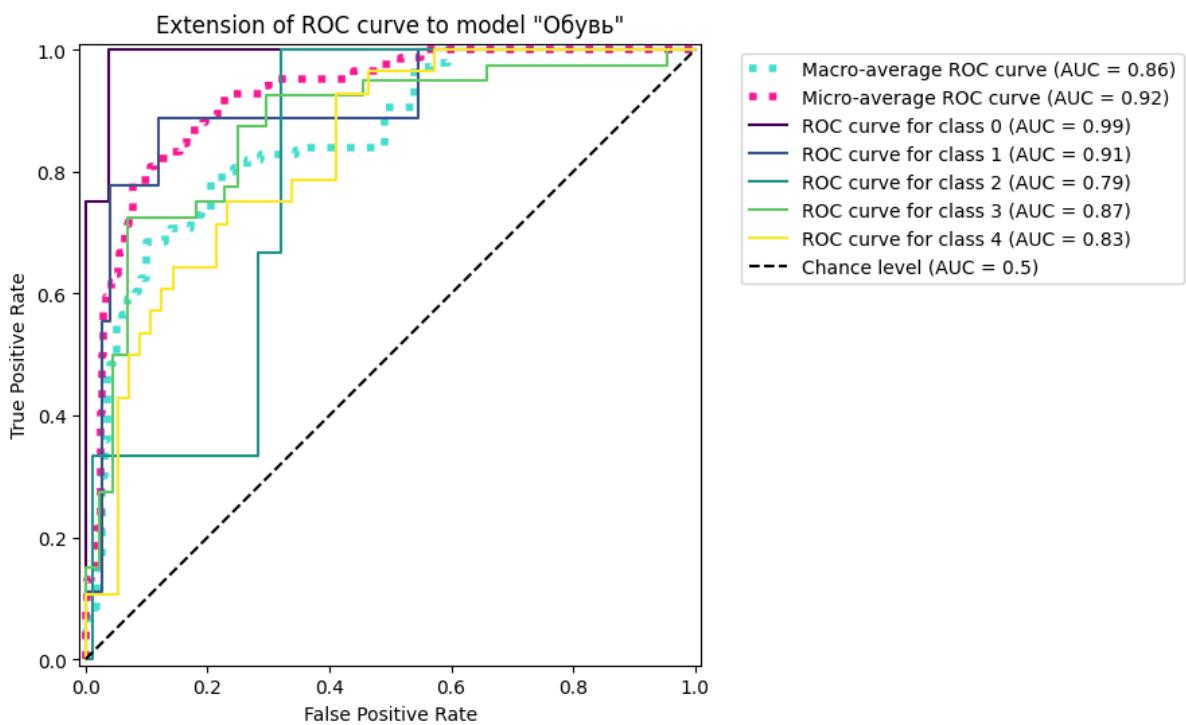


Рис. С.16: ROC-curves для модели «Обувь».

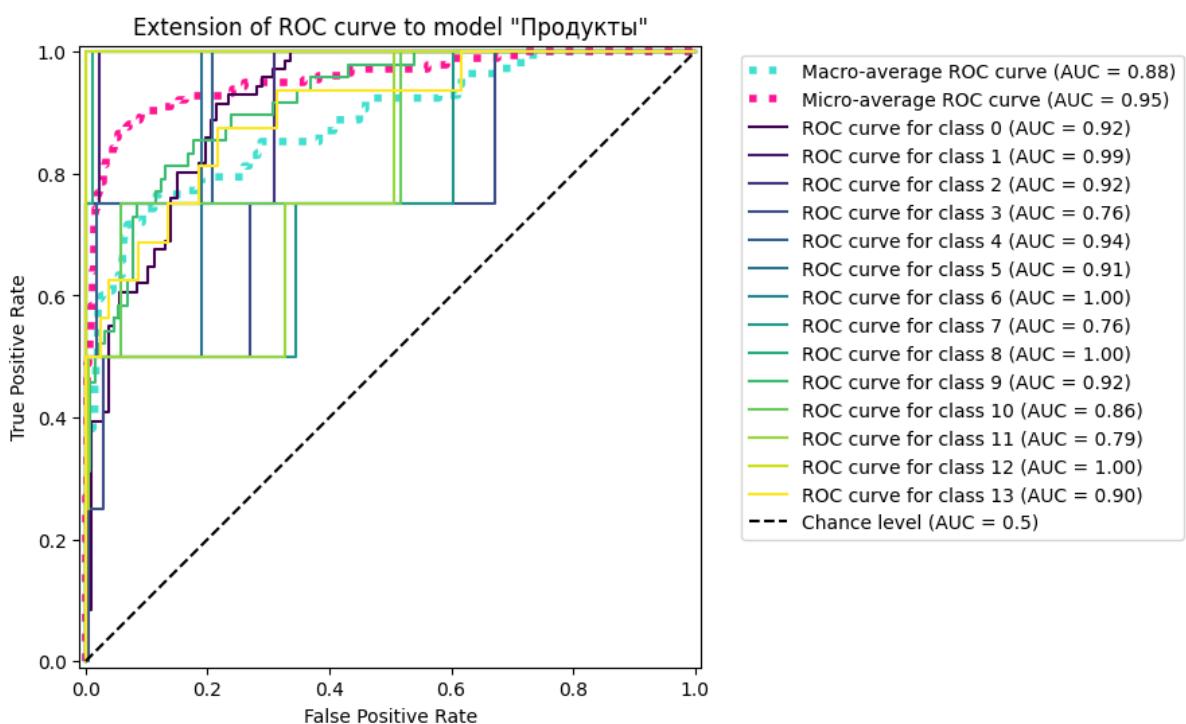


Рис. С.17: ROC-curves для модели «Продукты».

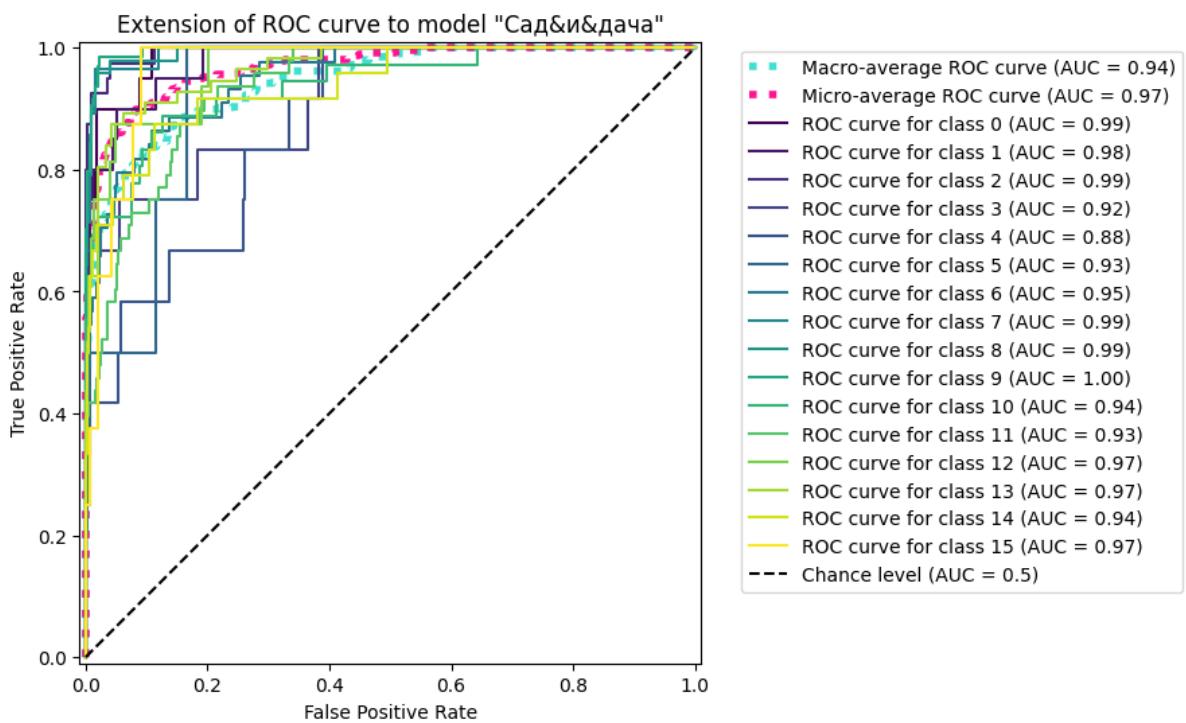


Рис. С.18: ROC-curves для модели «Сад&и&дача».

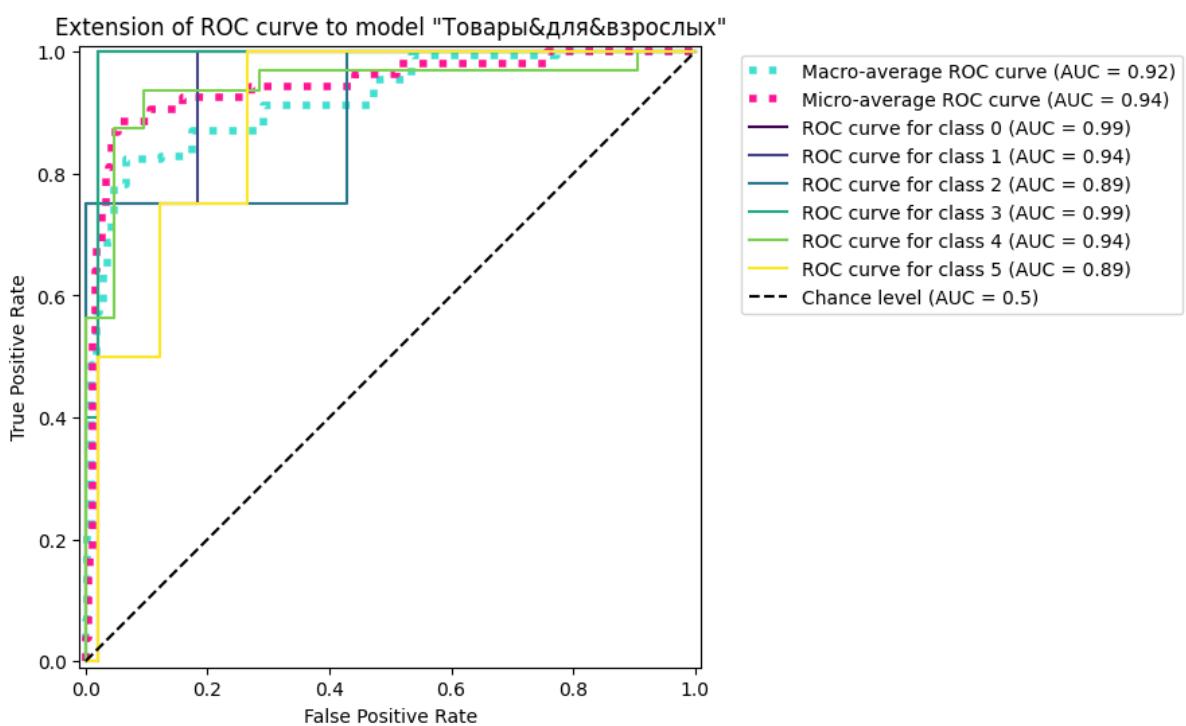


Рис. С.19: ROC-curves для модели «Товары&для&взрослых».

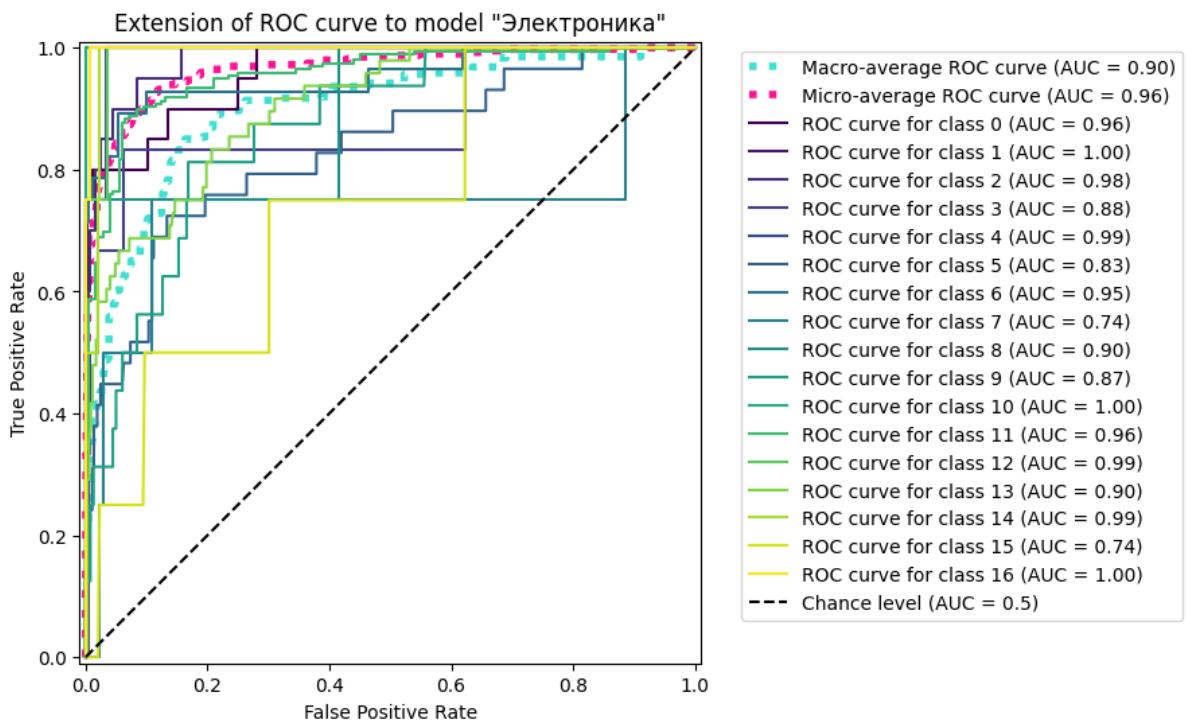


Рис. С.20: ROC-curves для модели «Электроника».

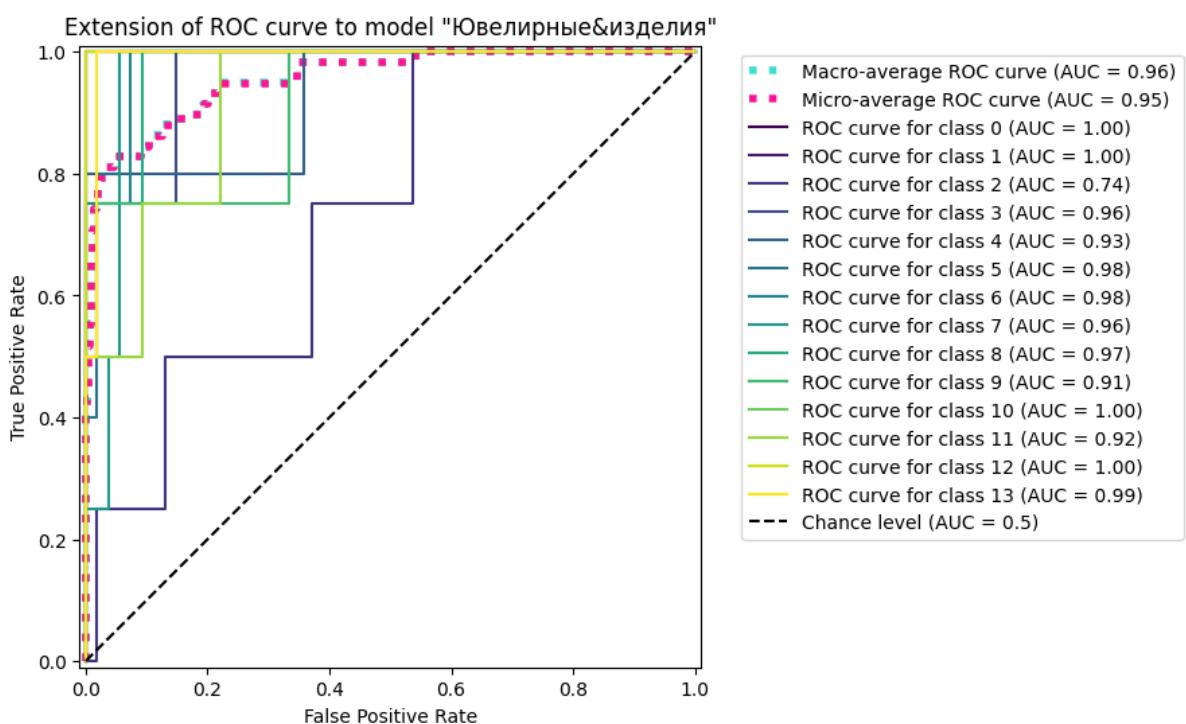


Рис. С.21: ROC-curves для модели «Ювелирные&изделия».